

企业 AI 部署偏好与治理机制：完整机器学习案例

本项目把官方数据、机器学习验证和可复现展示合成一个完整课程案例。

证据对象

12.77M official source rows; 5,814 Stage 2 modeling rows; Stage 2 R2=0.7245.

边界说明

本页图片是 GPT image 2 概念视觉，不作为统计证据。

12.77M

官方源数据行

5,814

Stage 2 建模行

0.7245

Stage 2 R²



视觉素材来源：GPT image 2 概念图

主证据从问卷/Kaggle 升级为官方数据


研究主证据采用 Eurostat 官方企业 ICT 数据，问卷和访谈只作为辅助说明。

证据对象

Eurostat source manifests, SHA256 records, data/raw and data/processed.

边界说明

不得把问卷星聚合统计写成逐样本原始数据库。



视觉素材来源：GPT image 2 概念图

数据生命周期每一步都有仓库证据

从源数据、清洗、建模到展示，每一步都能在仓库中追踪。

证据对象

data/raw/manifest*.jsonl, data/processed/*.csv, src/, outputs/.

边界说明

展示只讲公开复现材料，不暴露私密论文包。



视觉素材来源：GPT image 2 概念图

Stage 1 解释 SME 机制，Stage 2 验证行业/区域泛化

两阶段数据承担不同角色，不能把 Stage 2 写成 SME-only。

证据对象

Stage 1: 553 / 544 / 36; Stage 2: 5,814 / 36 / 50; years 2021, 2023-2025.

边界说明

Stage 2 是行业/区域外部验证层，不是中小企业专属样本。

553/544/36


Stage 1

5,814/36/50

Stage 2

2021, 2023-2025

年份范围



视觉素材来源：GPT image 2 概念图

1277 万源数据行不是直接训练样本

千万级官方数据经扫描、筛选和面板聚合后进入建模。

证据对象

12,770,332 raw rows -> 12,341,630 scanned rows -> 856,880 feature-filtered rows -> 5,814 modeling rows.

边界说明

禁止写成千万样本直接训练。

12,770,332


源数据行

856,880

候选特征行

5,814

建模面板行



视觉素材来源：真实数据图表

监督学习任务围绕官方 AI workflow指标展开


模型任务围绕官方 AI workflow/流程自动化指标，而不是训练大语言模型。

证据对象

target_workflow_automation; Ridge and ExtraTrees; leakage-controlled features.

边界说明

LLM/Agent 负责组织回答，表格模型负责可复现预测和解释。



视觉素材来源：GPT image 2 概念图

GroupKFold 按国家分组降低泄漏

用国家分组验证降低同一国家信息在训练和测试间泄漏的风险。

证据对象

Stage 1 R2=0.8680; Stage 2 R2=0.7245; time holdout as boundary check.

边界说明

模型验证说明泛化能力，不证明因果关系。

0.8680


Stage 1 R²

0.7245

Stage 2 R²

GroupKFold

主验证口径



视觉素材来源：真实数据图表

Stage 1 Ridge 支撑 SME 机制解释

Stage 1 用 Ridge 给出更稳定、可解释的机制层结果。

证据对象

553 panel rows, 544 modeling rows, 36 geo groups; R2=0.8680; MAE=1.8342.

边界说明

Stage 1 是 SME 机制解释层，不直接替代 Stage 2 外部验证。

553


面板行

544

可建模样本

1.8342

MAE



视觉素材来源：真实数据图表

Stage 2 ExtraTrees 支撑行业/区域外部验证

Stage 2 在行业和区域层面检验模型是否能跨情境保持解释力。

证据对象

5,814 modeling rows, 36 geo groups, 50 industries; R2=0.7245; MAE=1.9646.

边界说明

不把 Stage 2 说成 SME-only，不夸大因果识别。

5,814


建模行

50

行业

1.9646

MAE



视觉素材来源：真实数据图表

特征重要性服务机制解释，不写成因果证明


特征重要性用于解释部署准备度、数字基础和治理约束的相对作用。

证据对象

feature importance table and mechanism interpretation.

边界说明

重要性排序不等于因果效应。



视觉素材来源：真实数据图表

Agent 原型把证据约束转成可演示工具

Agent 原型只基于仓库证据回答，并在缺少模型二进制时安全返回 unavailable。

证据对象

10_Agent系统 tests and reports; 8 unit tests pass.

边界说明

公开仓库不提交 .joblib/.pkl 模型二进制。

8


单元测试

unavailable

安全降级

0

模型二进制公开



视觉素材来源：GPT image 2 概念图

公开仓库只保留课程复现材料

公开仓库保留课程案例和复现工程，私密论文与问卷/访谈材料不公开。

证据对象

Public: data/code/outputs/PPT; private: manuscript/questionnaire/interview; no .env/.joblib/.pkl.

边界说明

不得把 private_research_archive 或投稿包推到 GitHub。



视觉素材来源：GPT image 2 概念图

边界说清楚，比把结论写满更专业

准确说明数据边界能提高课程展示和后续研究可信用度。

证据对象

source-chain wording; no causal overclaim; questionnaire is aggregate only.

边界说明

禁止机器学习证明因果、千万样本直接训练、问卷逐样本数据库等越界表述。



视觉素材来源：GPT image 2 概念图

真实数据、严格验证、可复现展示

最终展示交付包括 PPTX、PDF、预览、证据映射和 QA 报告。

证据对象

Final PPTX/PDF; 14 previews; contact sheet; slide_to_evidence_map.

边界说明

课程展示版不是投稿论文终稿。

PPTX/PDF

最终交付

14

逐页预览

QA

质量门禁



视觉素材来源：GPT image 2 概念图