

数据挖掘与机器学习第一次作业

南京工业大学张新通 | 202321054027

课后作业要求

1. 阅读《参考教材1》第1-2章、4-5章。
2. 阅读《白话机器学习算法》第1章，整理读书笔记。
3. 整理本章上页 PPT “本章概念汇总”，形成笔记。

大数据的基本认知

大数据

规模巨大、类型复杂、增长快速的数据集合。

核心不只是“大”，而是能从数据中发现价值。

对管理决策而言，数据越多越需要方法筛选信息。

4V 特征

Volume: 数据量大

Variety: 类型多样

Velocity: 产生和处理速度快

Value: 价值密度低但潜在价值高

数据价值

通过分析规律支持预测、决策和优化。

价值往往隐藏在大量噪声和碎片信息中。

数据挖掘的任务就是把隐含规律转化为可用知识。

数据挖掘的概念

概念

任务

决策

数据挖掘是从大量、不完全、有噪声、模糊、随机的数据中，提取隐含的、事先未知的、潜在有用信息和知识的过程。

它不是简单查询，也不是只做统计描述，而是发现规律、建立模型并服务决策。

常见任务包括关联、回归、分类、聚类、预测和诊断。

本质上，数据挖掘连接了“原始数据”和“管理知识”：先处理数据，再建模解释，最后服务实际问题。

数据挖掘的基本过程



六阶段模型强调：先明确业务问题，再处理数据，最后让模型真正进入应用。
数据准备和探索往往占用最多时间，也是结果可靠性的基础。

教材截图标注：数据挖掘要点

标注重点

课后作业要求整理“数据挖掘的几个要点”（J p20-p21），本页对应教材中这一部分。

教材强调数据挖掘不是孤立算法，而是围绕目标、数据准备、模型建立和业务应用展开。

作业中应抓住三层逻辑：数据规模扩大、挖掘目标明确、结果服务业务决策。

这一页可作为“概念笔记”的依据：先写清数据来源，再写处理过程，最后说明输出知识如何产生价值。

J p20

管水平的目的。建设大数据中心，加强政务数据的获取、组织、分析、决策，通过云计算技术实现大数据对政务信息资源的统一管理，依据法律法规和各部门的需求进行政务资源的开发和利用，可以提高设备资源利用率、避免重复建设、降低维护成本。

大数据也将进一步提高决策的效率，提高政府决策的科学性和精准性，提高政府预测预警能力以及应急响应能力，节约决策的成本。以财政部门为例，基于云计算、大数据技术，财政部门可以按需掌握各个部门的数据，并对数据进行分析，作出的决策可以更准确、更高效。另外，也可以依据数据推动财政创新，使财政工作更有效率、更加开放、更加透明。2008年，法国总统萨科齐组建了一个专家组，成员包括以诺贝尔经济学奖获得者约瑟夫·斯蒂格利茨和阿玛蒂亚·森在内的20多名世界知名专家，进行了一项名为“幸福与测度经济进步”的研究。该研究将国民主观幸福感纳入了衡量经济表现的指标，以主观幸福度、生活质量及收入分配等指标来衡量经济发展。

1.5 大数据挖掘的要点

虽然大数据挖掘与一般的数据挖掘在挖掘过程、算法等方面差异不大，但由于大数据在广度和量度上的特殊性，对大数据的挖掘在实现上也会有些不同。要做好大数据的挖掘，除了掌握一般的数据挖掘方法，另外还要把握以下几个大数据挖掘的要点：

（1）大数据思维

大数据思维的核心是要具有利用数据的意识，无论量小还是量大。当我们处理的业务中涉及数据，尤其是有大量数据时，我们要想到是否可以利用这些数据处理碰到的新问题，这就是大数据思维。大数据思维也同时要求思维是开放的、包容的。在数据分享、信息公开的同时，也在释放善意，取得互信，在数据交换的基础上产生合作，这将打破传统封闭与垄断，形成开放、共享、合作思维。创造性思维是大数据思维方式的特性之一，通过对数据的重组、扩展和再利用，突破原有的框架，开拓新领域、确立新决策，发现隐藏在表面之下的数据价值，数据也创造性地成为可重复使用的“再生性”资源。

（2）大数据的收集与集成

大数据是客观存在的，但必须要对它进行控制和操作后才会进行更有意义的挖掘，而操作大数据的第一步就是大数据的收集和集成。

大数据挖掘在收集数据方面的要点就是理清和挖掘与目标可能有关联的数据，然后将这些关联数据收集起来。在当前，两个技术使得大数据的收集开始变得容易：一是各种传感器的廉价化和部署覆盖率的大大提高。比如，我们最熟悉的就是遍布身边的摄像头，不到10年的时间，城市里的任何一个角落放眼望去就全部是摄像头了。二是互联网，随着互联网技术的大发展，能够接入互联网的终端越来越便宜，在人群中的覆盖率不断提高，以致于我们拥有了一个可以覆盖大部分人口的传感器网络。比如，淘宝网每天有亿级别的用户访问、购物。在传统的工业时代，我们永远无法知道一个人在超市做了什么，也很难分析每个人在超

数据准备与预处理

为什么要预处理

原始数据常见问题：缺失、异常、重复、格式不一致。

不处理会导致模型偏差，甚至让算法无法运行。

数据准备是六阶段模型中最耗时的一环，也是后续分析可靠性的基础。

例如收入、年龄、购买次数等变量量纲不同，直接比较会影响距离或系数。

常见处理

数据清洗：修正错误、缺失和重复记录。

标准化/归一化：让不同量纲变量可比较。

衍生变量：根据业务含义构造新特征。

数据划分：保留测试集，避免只在训练数据上评价模型。

概念整理：大数据与数据挖掘

大数据 Big Data

指规模巨大、类型多样、产生速度快的数据集。

教材强调大数据的意义不只在“量大”，更在于通过分析发现隐藏价值。

典型特征可概括为 4V: Volume、Variety、Velocity、Value。

数据挖掘 Data Mining

从大量、不完全、有噪声的数据中，发现隐含、未知但有用的信息和知识。

它不是简单查询，而是经过数据准备、探索、建模、评估和应用的过程。常见任务包括关联、回归、分类、聚类、预测和诊断。

二者关系

大数据提供数据资源，数据挖掘提供发现规律的方法。

没有挖掘方法，大数据容易停留在存储层面。

没有高质量数据，模型也难以产生可靠知识。

概念整理：学习方式与数据形态

概念	含义	典型例子
有监督	训练数据带标签	分类、回归
无监督	训练数据无标签	聚类、降维
结构化	表格化、字段固定	数据库表
半结构化	有结构但不完全固定	XML、JSON
非结构化	缺少统一字段结构	文本、图片、视频

有监督学习关注“已知答案下学习映射关系”，无监督学习关注“没有标签时发现内部结构”。
数据形态决定了处理方法：结构化数据可直接建表分析，半结构化数据需解析字段，非结构化数据通常要先做特征提取。

概念整理：数据降维

数据降维

在尽量保留主要信息的前提下，减少变量数量或降低特征空间维度。

作用是降低计算复杂度、减少噪声、便于可视化和理解数据结构。

PCA 主成分分析

通过线性变换把原变量组合成少数主成分。

主成分按照解释方差大小排序，前几个主成分保留主要信息。

适合连续数值型变量的压缩和可视化。

t-SNE

用于高维数据的低维可视化，强调保持局部邻近关系。

常把复杂高维样本映射到二维平面观察群组结构。

更适合展示分布，不宜直接当作预测模型。

概念整理：数据处理与变量构造

概念	含义	作用
数据预处理	建模前的数据整理	提高数据可用性
数据清洗	处理缺失、异常、重复	减少错误和噪声
标准化	转成均值0、标准差1	消除量纲影响
归一化	缩放到固定区间	便于距离计算
衍生变量	由原始变量加工得到	增强业务解释力

数据预处理是总称，数据清洗是其中重要步骤。
标准化更强调按统计分布转换，归一化更强调把数值压缩到同一范围。
衍生变量来自业务理解，例如由购买时间生成“最近一次购买间隔”，由收入和负债生成“负债率”。

《白话机器学习》第1章读书笔记

教材3 p7

无监督学习	主成分分析 关联规则 社会网络分析
监督学习	回归分析 k 最近邻 支持向量机 决策树 随机森林 神经网络
强化学习	多臂老虎机

1.2.1 无监督学习

任务目标：指出数据中隐藏的模式。

当希望找出数据集中隐藏的模式时，可以使用 均值聚类、主成分分析、关联规则、社会网络分析等无监督学习算法。之所以称之为无监督学习算法，是因为我们不知道要找的模式是什么，而是要依靠算法从数据集中发现模式。

以表 1-1 中的数据为例，可以应用无监督学习模型找出哪些商品是顾客经常搭配购买的（其中会用到第 4 章讲解的关联规则算法），或者根据购买的商品对顾客进行分类（第 2 章将进行讲解）。

通过间接手段，可以对无监督学习模型输出的结果进行验证，比如检查得到的顾客分类是否与我们熟悉的分类（如食草动物和食肉动物）相符合。

1.2.2 监督学习

任务目标：使用数据中的模式做预测。

当需要做预测时，就会用到回归分析、k 最近邻、支持向量机、决策树、随机森林、神经网络等监督学习算法。之所以称之为监督学习算法，是因为它们的预测都基于已有的模式。

以表 1-1 中的数据为例，监督学习模型可以根据“顾客类别”以及“是否买鱼”（二者皆为预测变量）来预测“水果购买量”。

通过输入非表中顾客的预测变量值（“顾客类别”和“是否买鱼”），并且对比预测结果和实际的“水果购买量”，可以直接评估监督学习模型的准确度。

像“水果购买量”这样的整型数值或连续数值的预测过程，实际上是在解决回归问题，如图 1-1a 所示。二元值或分类值的预测过程，如预测是否会下雨，则是在解决分类问题，如图 1-1b 所示。尽管如此，大部分分类算法也可以生成连续的概率值，比如预测“降水概率是 75%”，这种预测精度更高。

教材图像说明

截图展示了机器学习基础章节中的数据、变量和算法选择内容。

读书时不能只记算法名称，还要先判断数据类型、变量含义和任务目标。

如果变量选择不合理，后面的模型再复杂也很难得到可信结果。

我的理解

第1章像是机器学习的“总入口”。

准备数据、选择算法、调参、评价模型是一条完整链路。

它和参考教材1的数据挖掘六阶段模型可以对应起来理解。

学习小结

第一讲建立了数据挖掘的整体框架：数据、任务、过程和应用。

理解“从数据到知识”的流程，比记住单个算法更重要。

本章概念可以串成一条主线：先认识数据形态，再清洗和转换数据，接着选择监督或无监督方法，最后评价结果能否服务决策。

后续回归、分类、聚类、关联规则都可以放入六阶段模型中理解：它们只是模型建立阶段的不同方法。

读书笔记的重点不是摘抄概念，而是把概念放入实际问题中解释，例如如何从企业数据中发现客户、风险或市场规律。

数据挖掘与机器学习第二次作业

南京工业大学张新通 | 202321054027

课后作业要求

1. 整理数据回归方法的基本方法、步骤。
2. 整理一元线性回归和多元线性回归的基本数学模型。
3. 整理 Logistic 回归模型，说明它与普通回归的联系和区别。
4. 阅读《白话机器学习》第六章“回归”，完成读书笔记。

回归方法的基本思想

目标变量 y

解释变量 x

参数估计 b


回归用于研究变量之间的数量关系，并根据已知变量预测连续型结果。

核心任务是找到一个函数，使预测值尽量接近真实值。

建模时通常需要：确定目标变量、选择解释变量、估计参数、评价模型效果。

在数据挖掘流程中，回归既可以用于预测，也可以用于解释变量影响方向。

数据回归的基本步骤



收集数据后要先明确因变量 y 和解释变量 x ，避免把无关变量直接塞进模型。

训练集用于估计参数，测试集用于观察模型对新数据的表现。

检验效果时既看 R^2 、误差，也要看残差是否存在明显规律。

如果只看训练结果，容易高估模型能力；预测应用前应确认模型具有可解释性和稳定性。

一元线性回归模型

$$y = b_0 + b_1x + e$$

y 是因变量, x 是自变量。

b_0 表示截距, b_1 表示 x 每增加 1 个单位时 y 的平均变化量。

e 表示随机误差, 用来表示模型无法解释的部分。

教材截图标注：一元线性回归

标注重点

本页对应一元线性回归模型，是回归方法中最基础的形式。

整理时重点写清：一个自变量、一个因变量、截距 b_0 、斜率 b_1 和误差项 e 的含义。

b_1 的解释要结合变量单位： x 每增加 1 个单位， y 的平均变化量为 b_1 。

公式页后接截图页，既说明内容来自教材，也能把抽象模型和教材原文对应起来。

J p126

一元性：一元线性、一元非线性、多元线性、多元非线性。另外还有两种特殊的回归方式，一种在回归过程中可以调整变量数的回归方法，称为逐步回归，另一种是以指数结构函数作为回归模型的回归方法，称为 Logistic 回归。本章将逐一介绍这几个回归方法。

7.1 一元回归

7.1.1 一元线性回归

设 Y 是一个可观测的随机变量，它受到一个非随机变量因素 x 和随机误差 ε 影响。若 Y 与 x 有如下线性关系：

$$Y = \beta_0 + \beta_1 x + \varepsilon$$

且 ε 的均值 $E(\varepsilon) = 0$ ，方差 $\text{var}(\varepsilon) = \sigma^2 (\sigma > 0)$ ，其中 β_0 、 β_1 是固定的未知参数，称为回归系数， Y 称为因变量， x 称为自变量，则称此 Y 与 x 之间的函数关系表达式为一元线性回归模型。

对于实际问题，要建立回归方程，首先要确定能否建立线性回归模型，其次确定如何对模型中的未知参数 β_0 、 β_1 进行评估。

通常，我们首先对总体 (x, Y) 进行 n 次独立观测，获得 n 组数据（称为样本观测值）：

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$$

然后在直角坐标系 xOy 中画出数据点 $(x_i, y_i), (i = 1, 2, \dots, n)$ ，该图形称为数据的散点图。如果这些点大致地位于同一条直线的附近，或者说，散点图呈现线性形状，则认为 Y 与 x 之间的关系符合线性关系。此时，利用最小乘法可以得到回归模型参数 β_0 、 β_1 的最小二乘估计 $\hat{\beta}_0$ 、 $\hat{\beta}_1$ ，估计公式为：

$$\begin{cases} \hat{\beta}_0 = \bar{y} - \bar{x} \hat{\beta}_1 \\ \hat{\beta}_1 = \frac{L_{xy}}{L_{xx}} \end{cases}$$

$$\text{其中，} \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i, L_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2, L_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})。$$

于是就可以建立经验模型：

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

对于得到的回归方程形式，通常需要进行回归效果的评价，当有几种回归结果后，还通常要加以比较以选出较好的方程，常用的准则有：

1) 决定系数 R^2 ，其数学定义为：

$$R^2 = 1 - \frac{\text{SSE}}{\text{SST}}$$

R^2 称为决定系数。显然 $R^2 \leq 1$ ， R^2 大表示观测值 y_i 与拟合值 $\hat{y}_i$ 比较靠近，也就意味着

多元线性回归模型

$$y = b_0 + b_1x_1 + b_2x_2 + \dots + b_nx_n + e$$

多元线性回归同时考虑多个解释变量，更接近真实问题。

每个系数表示在其他变量不变时，该变量对 y 的边际影响。

变量间相关性过强时，可能影响系数解释，出现多重共线性问题。

建模时应关注变量含义、显著性、方向是否符合业务常识，而不是只追求拟合度。

Logistic 回归模型

$$P(y=1) = 1 / (1 + e^{-(b_0+b_1x_1+\dots+b_nx_n)})$$

Logistic 回归输出的是某一类别发生的概率。
通过 Sigmoid 函数把线性组合压缩到 0-1 之间。
常用于二分类问题，如是否违约、是否购买、是否流失。

教材截图标注： Logistic 回归

标注重点

本页对应 Logistic 回归数学模型。

它先形成线性组合，再通过 Sigmoid 函数转换为 0-1 之间的概率。

它看起来像回归，但输出可解释为“属于某类”的概率，因此常用于二分类问题。

它是“回归方法”和“分类任务”的连接点：参数估计类似回归，任务目标更接近分类。

J p144

31,22,44;2,54,18,22;21,47,4,26;1,40,23,34;11,66,9,12]; %自变量数据
Y=[78.5,74.3,104.3,87.6,95.9,109.2,102.7,72.5,93.1,115.9,83.8,113.3]; %因变量数据
Stepwise (X,Y,[1,2,3,4],0.05,0.10) % in=[1,2,3,4]表示 X1、X2、X3、X4 均保留在模型中
程序执行后得到下列逐步回归的窗口，如图 7-6 所示。




图 7-6 逐步回归操作界面

图 7-6 显示变量 X1、X2、X3、X4 均保留在模型中，窗口的右侧按钮上方提示：将变量 X3 剔除回归方程（Move X3 out），单击“Next Step”按钮，即进行下一步运算，将第 3 列数据对应的变量 X3 剔除回归方程。单击“Next Step”按钮后，剔除的变量 X3 所对应的行用红色表示，同时又得到提示：将变量 X4 剔除回归方程（Move X4 out），单击“Next Step”按钮，这样一直重复操作，直到“Next Step”按钮变灰，表明逐步回归结束，此时得到的模型即为逐步回归最终的结果。

7.4 Logistic 回归

7.4.1 Logistic 模型

在回归分析中，因变量 y 可能有两种情形：① y 是一个定量的变量，这时就用通常的 regress 函数对 y 进行回归；② y 是一个定性的变量，比如 $y = 0$ 或 1 ，这时就不能用通常的 regress 函数对 y 进行回归，而是使用所谓的 Logistic 回归。Logistic 方法主要应用在研究某些现象发生的概率 p ，比如股票涨还是跌，公司成功或失败的概率。除此之外，本章还讨论概率 p 与哪些因素有关。Logistic 回归模型的基本形式为：

$$p(Y=1|x_1,x_2,\dots,x_k)=\frac{\exp(\beta_0+\beta_1x_1+\dots+\beta_kx_k)}{1+\exp(\beta_0+\beta_1x_1+\dots+\beta_kx_k)}$$

其中， $\beta_0, \beta_1, \dots, \beta_k$ 为类似于多元线性回归模型中的回归系数。

Logistic 与线性回归的联系和区别

项目	线性回归	Logistic 回归
输出	连续数值	类别概率
任务	预测数量	预测类别
函数	线性函数	Sigmoid 函数
评价	误差 / R^2	准确率 / 混淆矩阵

二者都通过变量和系数建立模型，变量选择、参数解释和模型检验都很重要。
区别在于输出含义不同：线性回归直接预测数值，Logistic 回归预测概率并根据阈值转成类别。
因此 Logistic 回归虽然名字中有“回归”，但在数据挖掘任务中经常服务于分类。

模型评价：R² 和误差

R²

误差

泛化

解释性

R² 越接近 1，说明模型对数据波动的解释能力越强。

误差越小，说明预测值越接近真实值。

实际建模不能只看一个指标，还要看数据质量、变量含义和模型稳定性。

如果训练集效果很好、测试集效果变差，可能存在过拟合，需要重新检查变量和模型复杂度。

《白话机器学习》第六章读书笔记

教材3 p30




图 6-2 房价和低收入居民占比的关系

经过观察可以发现，相比于图 6-1，图 6-2b 中有更多数据点集中在趋势线附近，这说明周围居民的富裕程度对房价的影响要比房间数的影响大。

为了提高房价预测结果的准确度，可以把房间数和周围居民的富裕程度结合起来并将其作为一个预测变量使用。不过，由于后者对房价的影响要比前者大，因此把两者简单地加起来并不合理。合理的做法是给予周围居民富裕程度所做的预测赋予更高的权重，如图 6-3 所示。




图 6-3 房价和带权重的组合预测变量的关系，组合预测变量由房间数和周围居民的富裕程度组合而成

图 6-3 反映的是房价和带有最优权重的组合预测变量的关系。该组合预测变量由房间数和周围居民的富裕程度这两个预测变量组合而成。请注意，相比之前，图中的数据点离趋势线更近，因此通过这条趋势线所做的预测可能是最准确的。为了验证这一点，可以比较使用 3 条趋势线所得到的平均预测误差，如表 6-1 所示。

表 6-1 使用 3 条趋势线所得到的平均预测误差

教材图像说明

截图中的散点图和趋势线展示了回归的直观含义：用一条线刻画变量间的整体变化趋势。

点越围绕趋势线分布，线性关系越明显。

离趋势线较远的点会增加误差，也可能提示异常值或遗漏变量。

我的理解

回归不是把所有点都连起来，而是寻找整体规律。

模型好坏要看预测误差，也要看变量是否有现实含义。

在作业案例中， R^2 可以作为直观评价指标，但不能替代业务解释。

梯度下降与参数调整

教材3 p32




图 6-5 凹坑（绿色三角形）可能会被误认为是最优点，而真实的最优点在更下方（绿色水平线）

为了降低陷入这种凹坑的风险，可以使用另外一种方法——**随机梯度下降法**。在这种方法中，每次迭代并不是采用所有数据点，而是只从其中选取一个来调整参数。这样做就引入了多变性，有助于算法逃离凹坑。虽然从这个随机过程中得到的最终参数值可能不是最优的，但与最优值很接近，精度还是相当不错的。

梯度下降法的这个缺点通常只出现在更为复杂的模型中，做回归分析时根本无须担心这一点。

6.4 回归系数

在为回归预测变量求得最佳权重之后，需要对它们进行解释。

回归预测变量权重的正式名称是**回归系数**，它表示某个预测变量相比于其他预测变量的影响大小。换言之，它表示相关预测变量的增加值，而非绝对预测强度。

举例来说，如果使用房屋的建筑面积和房间数来预测房价，那么房间数的权重也许可以忽略不计。因为房间数在衡量房屋大小方面的作用与建筑面积有重叠，所以它对整个预测能力的贡献很小。

预测变量的度量单位不同也会影响对回归系数的解释。比如，对于同一个预测变量，以米为度量单位时的权重是以厘米为度量单位时的 100 倍。为了避免这个问题，应该在回归分析之前先对预测变量的度量单位进行标准化。标准化类似于统一使用百分位数来表示每个变量。经过标准化之后，预测变量的系数被称为**标准化回归系数**，可以用来做更准确的比较。

在预测房价的例子中，两个预测变量（房间数和周围低收入居民所占比例）都经过了标准化，权重比为 2.7 : 6.3。这意味着在预测房价时，周围低收入居民所占比例比房间数起更大的作用。回归方程如下所示。

$$\text{房价} = 2.7(\text{房间数}) - 6.3(\text{低收入居民所占比例})$$

请注意，在这个方程中，低收入居民所占比例的权重前面有一个负号，这表示权重为负。这是因为该预测变量和房价是负相关关系，这一点可以从图 6-2 中向下倾斜的趋势线看出来。

6.5 相关系数

当只存在一个预测变量时，该预测变量的**标准化回归系数**也被称为**相关系数**，记作 r ，如图 6-6 所示。相关系数的取值范围为 -1 到 1，它提供了两部分信息。

教材图像说明

教材图像展示了损失函数曲线和参数更新方向。

梯度下降的思想是沿着使误差减小最快的方向逐步调整参数。

学习率过大可能越过最优点，过小则收敛速度慢。

我的理解

b_0 、 b_1 不是凭空得到，而是通过优化过程估计出来。

理解梯度下降有助于明白“训练模型”具体在做什么。

这也解释了为什么数据规模、变量尺度会影响模型训练。

学习小结

线性回归解决连续值预测，Logistic 回归解决分类概率预测。

回归建模的重点是变量选择、参数估计和结果评价。

一元线性回归适理解单一变量关系，多元线性回归适合处理多因素影响，Logistic 回归适合把概率转换为类别判断。

模型不是越复杂越好，能解释、能泛化、能用于决策才有意义。

本次作业的关键是把数学模型、代码运行结果和评价指标联系起来，而不是只列公式。

数据挖掘与机器学习第三次作业

南京工业大学

张新通 | 202321054027

分类定义

什么是分类 (Classification)?

对现有的数据进行学习，得到一个**目标函数或模型（分类器）**。

该模型能把**未知类别**的样本映射到给定的类别中。

注意：分类是一种**预测**，不是肯定。

不能期待准确率达到 100%，但总是致力于筛选出准确率最高的模型。

154 ❖ 第二篇 技术篇

类。尽管这些未来的测试数据的类标签是未知的，我们仍可以由此预测这些新数据所属的类。注意是预测，而不能肯定，因为分类的准确率不能达到百分之百。我们也可以由此对数据中的每一个类有更好的理解。也就是说：我们获得了对这个类的知识。

所以分类 (Classification) 也可以定义为：

对现有的数据进行学习，得到一个目标函数或规则，把每个属性集 x 映射到一个预先定义的类标号 y 。

目标函数或规则也称分类模型 (Classification Model)，分类模型有两个主要作用：一是描述性建模，即作为解释性的工具，用于区分不同类中的对象；二是预测性建模，即用于预测未知记录的类标号。

但是总能筛选出准确率最高的模型

图：作业笔记关于分类定义的原文截图

基本概念



分类器

能够解释原始数据，能够预测新数据的模型。



训练集

用来训练模型的原始数据（划分出的一部分）。



测试集

用来测试模型的原始数据（划分出的一部分）。




类标签

原始数据中已经给每个记录（对象）标记的类别。



开放集

使用训练好的模型（分类器）进行分类工作的新数据。



k-NN 方法



k-NN 算法步骤

- 1 初始化距离
设定最大值作为初始距离
- 2 计算与更新 (遍历)
计算距离 dist
比较并更新 K 个最近邻
- 5 遍历结束
完成所有训练样本的计算
- 6 统计频次
统计 K 近邻中各类别次数
- 7 输出预测
选择频率最高的类别


算法步骤

图 8-4 一个实例的 1-最近邻、2-最近邻和 3-最近邻

KNN 算法具体步骤如下：


- 步骤 1：初始化距离为最大值。
- 步骤 2：计算未知样本和每个训练样本的距离 dist。
- 步骤 3：得到目前 K 个最近邻样本中的最大距离 maxdist。
- 步骤 4：如果 dist 小于 maxdist，则将该训练样本作为 K-最近邻样本。
- 步骤 5：重复步骤 2~步骤 4，直到未知样本和所有训练样本的距离都算完。
- 步骤 6：统计 K 个最近邻样本中每个类别出现的次数。
- 步骤 7：选择出现频率最大的类别作为未知样本的类别

根据 KNN 算法的原理和步骤可以看出，KNN 算法对 K 值的依赖较高，所以 K 值的选择非常重要。如果 K 太小，预测目标容



KNN 算法步骤

Undo



南京工业大学 | 张新通 | 202321054027

实际 Positive

预测 Negative

FN

实际 Negative

TN

$$(TP + TN) / All$$

TP / (TP + FP) 预测为正中正确的比例

TP / (TP + FN) 实际为正中被找出的比例

y

	0	1
0	1	1
1	1	1

第8章 分类方法

算法 → 评估

	No.	x_1, x_2, x_3	y	y
训练集:	1	x x x	0	0
测试集:	2	x x x	0	1
	3	x x x	1	1
	4	x x x	1	0

初始标签 预测标签

4) 训练 KNN 分类器

$Accuracy = \frac{1}{2}$
 $Precision = \frac{1}{2}$
 $Recall = \frac{1}{2}$

《白话机器学习》第七章读书笔记

k 最近邻 (k-NN) 算法，结合葡萄酒分类案例拆解核心知识点

核心原理上，k-NN 算法依据数据点周围 k 个邻居的类别进行分类，遵循少数服从多数原则；k 值选择是关键，过小易受噪声干扰，过大则忽略数据隐藏模式，需用交叉验证调优，二分类中取奇数避免平局。该算法不仅可用于分类，还能通过加权平均预测连续值，提升预测精度。

局限性与优化方向上，算法在类别不平衡时小类别易被掩盖，可采用加权投票法优化；多预测变量会增加计算量，需借助降维技巧筛选关键变量。整体而言，k-NN 算法简单易用，在低维、类别均衡的数据场景中表现优异。

最近邻算法


Pros

- 简单易懂
- 实用性强
- 异常检测

Cons

- 类别不平衡
- 预测变量过多
- 计算成本高

提高 k 最近邻算法的准确性



《白话机器学习》第七章读书笔记

应用场景方面，葡萄酒检测案例中，利用氯化物、二氧化硫等化学成分，k-NN 算法以超 98% 准确率区分红白葡萄酒，直观体现其效果；同时可用于异常检测，分类错误的异常点能帮助发现缺失变量、优化模型，移除异常数据还能减少噪声、提升模型准确度。




图 7-3 白葡萄酒（黑点）和红葡萄酒（红点）中氯化物和二氧化硫的含量

因为葡萄皮中的矿物质（比如氯化钠，与食盐成分一样）含量较高，所以红葡萄酒中这些成分的含量就相对较高，图中很好地反映出了这一点。葡萄皮还含有天然抗氧化剂，用来使葡萄保持新鲜。白葡萄酒不包含这种成分，所以需要使用更多的二氧化硫来充当防腐剂。正是这些原因使得红葡萄酒大都集中在图中的右下部分，白葡萄酒则主要集中在左上部分。





图 7-2 使用不同的 k 值进行拟合。黑色区域中的点被预测为白葡萄酒，红色区域中的点则被预测为红葡萄酒

如果 k 值太小，数据点只与最近的“邻居”匹配，并且随机噪声所产生的误差也会被放大，如图 7-2a 所示。如果 k 值太大，数据点会尝试与更远的“邻居”匹配，其中隐含的模式会被忽略，如图 7-2c 所示。

只有当 k 值恰到好处时，数据点才会参考合适数量的“邻居”，这使得误差相互抵消，有利于揭示数据中隐藏的趋势，如图 7-2b 所示。


《白话机器学习》第九章读书笔记

决策树的核心逻辑是通过一系列二元判定问题（仅含“是”“否”两个分支）实现预测，以根节点为起点，沿分支节点逐步迭代，最终抵达叶节点输出预测结果。该算法可适配分类任务（如性别区分）与连续值预测任务，其中连续值任务可通过离散化处理（如划分“高于平均值”“低于平均值”）转化为分类任务。在泰坦尼克号乘客生还预测案例中，决策树模型显示，男孩或女性乘客若不处于三等舱，其生还概率显著提升，直观验证了该算法的实践价值。



《白话机器学习》第九章读书笔记

决策树的挑战



决策树的生成核心是递归拆分过程：通过构建最优二元判定规则拆分数数据集，最大化各子数据集的同质性（即类内相似度），该过程可重复迭代，直至满足预设终止条件（包括叶节点内数据属于同一类别、叶节点样本量低于5个、进一步分支无法提升数据集同质性且超出预设阈值等）。决策树的核心优势的在于可解释性强、可视化程度高，对异常值具有较强的抗干扰能力，且不显著特征变量不会对预测结果产生影响。

决策树存在明显局限性，主要表现为模型稳定性差（数据集微小波动会导致决策树结构发生显著变化）、易出现过拟合现象、预测精度存在局限。针对上述问题，可通过决策树多样化策略进行改进，主流方法包括随机森林与梯度提升：随机森林通过随机选取判定规则生成多棵决策树，综合所有树的预测结果提升稳定性；梯度提升通过有策略地选取判定规则，逐步优化模型精度，最终以各预测结果的加权平均值作为最终输出。但此类改进方法结构复杂，难以实现可视化，属于“黑盒模型”。整体而言，决策树因具备较强的可解释性与可视化优势，仍是机器学习领域中应用广泛的基础分析工具。

数据挖掘与机器学习第四次作业

南京工业大学张新通 | 202321054027

课后作业要求

1. 整理簇的概念。
2. 整理类度量的两种基本方法：欧式距离、余弦距离。
3. 整理 K-means 算法的原理和步骤。
4. 整理 HC 算法的过程。
5. 掌握 PPT 第26页 HC 聚类结果图。
6. 阅读《白话机器学习》K-means 章，整理读书笔记。

簇的概念

簇内相似

簇间差异

无监督

簇是由相似对象组成的集合。

同一簇内的数据对象应尽可能相似，不同簇之间应尽可能不同。

聚类属于无监督学习，事先没有给定类别标签。

因此聚类结果不是“标准答案”，而是根据相似性度量得到的一种结构解释。

类度量：欧式距离

$$d(x,y)=\text{sqrt}((x_1-y_1)^2 + \dots + (x_n-y_n)^2)$$

欧式距离衡量两个样本在空间中的直线距离，是聚类中最常用的距离之一。

距离越小，样本越相似；距离越大，样本差异越明显。

不同变量量纲不一致时，应先进行标准化或归一化，否则量纲大的变量会主导距离。

欧式距离适合数值型、连续型特征，例如花萼长度、收入、消费次数等。

类度量：余弦距离

$$\cos(\theta) = (x \cdot y) / (||x|| ||y||)$$

余弦相似度关注向量方向是否一致，而不是绝对大小。

适合文本、偏好、行为模式等高维稀疏数据。

相似度越接近 1，两个对象方向越接近；越接近 0，方向差异越大。

与欧式距离相比，余弦度量更强调结构比例，例如两个用户购买总量不同但偏好结构相似。

K-means 算法思想

K-means 先指定 K 个簇，然后不断调整簇中心。

每个样本被分配给距离最近的中心点。

更新中心点后再次分配，直到结果基本稳定。

算法目标是让簇内距离尽量小、簇间差异尽量明显。

它适合较规则、近似球形的簇；如果数据形状复杂或异常值很多，结果可能不稳定。

教材截图标注：K-means 原理

标注重点

教材本页对应 K-means 的原理和步骤。

作业中应突出：先定 K、再分配样本、再更新中心、循环直到稳定。

K 值和初始中心都会影响聚类结果，因此实际使用中常需要多次运行或比较不同 K 值。

从作业角度看，不能只写“运行算法”，还要解释每一步为什么会改变簇中心和样本归属。

J p192

9.2 K-means 方法

K-均值聚类算法是著名的划分聚类分割方法。划分方法的基本思想是：给定一个有 N 个元组或者记录的数据集，分裂法将构造 K 个分组，每一个分组就代表一个聚类， $K < N$ 。而且这 K 个分组满足下列条件：①每一个分组至少包含一个数据记录；②每一个数据记录属于且仅属于一个分组；对于给定的 K ，算法首先给出一个初始的分组方法，以后通过反复迭代的方法改变分组，使得每一次改进之后的分组方案都较前一次好，而所谓好的标准就是：同一分组中的记录越近越好（已经收敛，反复迭代至组内数据几乎无差异），而不同分组中的记录越远越好。

9.2.1 K-means 原理和步骤

K-means 算法的工作原理：首先随机从数据集中选取 K 个点，每个点初始地代表每个簇的聚类中心，然后计算剩余各个样本到聚类中心的距离，将它赋给最近的簇，接着重新计算每一簇的平均值，整个过程不断重复，如果相邻两次调整没有明显变化，说明数据聚类形成的簇已经收敛。本算法的一个特点是在每次迭代中都要考察每个样本的分类是否正确。若不正确，就要调整，在全部样本调整完后，再修改聚类中心，进入下一次迭代。这个过程将不断重复直到满足某个终止条件，终止条件可以是以下任何一个：

- 1) 没有对象被重新分配给不同的聚类。
- 2) 聚类中心不再发生变化。
- 3) 误差平方和局部最小。

算法步骤：

- 1) 从 n 个数据对象中任意选择 k 个对象作为初始聚类中心；
- 2) 循环 3) 到 4) 直到每个聚类不再发生变化为止；
- 3) 根据每个聚类对象的均值（中心对象），计算每个对象与这些中心对象的距离；并根据最小距离重新对相应对象进行划分；
- 4) 重新计算每个聚类的均值（中心对象），直到聚类中心不再变化。这种划分使得下式最小：

$$E = \sum_{j=1}^k \sum_{x_i \in m_j} \|x_i - m_j\|^2$$

K-means 算法是很典型的基于距离的聚类算法，采用距离作为相似性的评价指标，即认为两个对象的距离越近，其相似度就越大。该算法认为簇是由距离靠近的对象组成，因此把得到紧凑且独立的簇作为最终目标。

K-means 算法：

输入：聚类个数 k ，以及包含 n 个数据对象的数据库。

输出：满足方差最小标准的 k 个聚类。


K-means 算法步骤



K 值不同会得到不同聚类结果。

初始中心可能影响最终结果，因此实际应用中常多次运行比较。

HC 层次聚类过程



HC 不一定需要预先指定类别数，可以通过树状图选择切分层级。
数据量较大时，层次聚类计算成本较高。

教材截图标注：HC 算法

标注重点

本页对应 HC 层次聚类过程。

重点是理解“逐步合并”和“树状图”的关系：从单个样本开始，把距离最近的类逐层合并。

树状图不是装饰图，而是确定聚类层级的重要依据。

与 K-means 相比，HC 更适合展示层次结构，但计算复杂度较高，通常更适合较小数据集。

J p198

9.2.4 K-means 特点

- 1) 在 K-means 算法中 K 是事先给定的，这个 K 值的选定是非常难以估计的。
- 2) 在 K-means 算法中，首先需要根据初始聚类中心来确定一个初始划分，然后对初始划分进行优化。
- 3) K-means 算法需要不断地进行样本分类调整，不断地计算调整后的新的聚类中心，因此当数据量非常大时，算法的时间开销是非常大的。
- 4) K-means 算法对一些离散点和初始 K 值敏感，不同的距离初始值对同样的数据样本可能得到不同的结果。

9.3 层次聚类

9.3.1 层次聚类原理和步骤

层次聚类算法，是通过将数据组织为若干组并形成一个相应的树来进行聚类的。根据层次是自底向上还是自顶向下形成，层次聚类算法可以进一步分为凝聚的聚类算法和分裂的聚类算法，如图 9-7 所示。一个完全层次聚类的质量由于无法对已经做的合并或分解进行调整而受到影响。但是层次聚类算法没有使用准则函数，它所含的对数据结构的假设更少，所以它的通用性更强。

在实际应用中一般有两种层次聚类方法：

- 1) 凝聚的层次聚类：这种自底向上的策略首先将每个对象作为一个簇，然后合并这些原子簇为越来越大的簇，直到所有的对象都在一个簇中，或者某个终结条件被达到要求。大部分的层次聚类方法都属于一类，它们在簇间的相似度的定义有点不一样。
- 2) 分裂的层次聚类：像这样的自顶向下的策略与凝聚的层次聚类有些不一样，它首先将所有对象放在一个簇中，然后慢慢地细分为越来越小的簇，直到每个对象自行形成一簇，或者直到满足其他的一个终结条件，例如满足了某个期望的簇数目，又或者两个最近的簇之间的距离达到了某一个阈值。

图 9-7 描述了一个凝聚的层次聚类方法 AGENES 和一个分裂的层次聚类方法 DIANA 在一个包括五个对象的数据的集合 {a,b,c,d,e} 上的处理过程。初始时，AGENES 将每个样本点自为一簇，之后这样的簇依照某一种准则逐渐合并，例如，例如簇 C1 中的某个样本点和簇 C2 中的一个样本点相隔的距离是所有不同类簇的样本点间欧几里得距离最近的，则认为簇 C1





图 9-7 凝聚的层次聚类和分裂的层次聚类处理过程

HC 聚类结果图怎么看

PPT 第26页

第四张图 (图9-10) (重点, 这个是需要掌握的)



图怎么看? (重点)

图9-10, 就是左图, 一定要会看了, 这个是HC聚类经常会用到的图。这个图怎么看, 关键就是怎么通过这个图确定类别, 就是我在左图中添加的红色线, 当这个线从上往下平移, 它与多少垂直线相交, 就分成了几个类。左边的就是本例的3类。

另外, 我跑出来的结果与教材有差别, 这不是错误, 没有关系。

还有一点很重要, 这个图是函数dendrogram (Ip200) 画出来的, 这个函数默认是最底下画30个节点, 这样出来的图就比较清晰了, 不会太拥挤。

图像说明

这张图是 HC 层次聚类常用的树状图, 由 dendrogram 函数画出。

纵轴表示样本或类合并时的距离, 高度越高, 说明被合并对象差异越大。

图中的红色虚线是一条水平切分线, 它与多少条垂直分支相交, 就可以理解为分成多少类。

截图中红线与 3 条垂直线相交, 所以左图解释为聚成 3 类。

作业回答

如果要聚成 5 类, 应把水平线继续向下平移, 直到它与 5 条垂直分支相交。

线画得越高, 类别越少; 线画得越低, 类别越多。

程序结果与教材略有差异不算错误, 关键是掌握树状图的读法。

《白话机器学习》K-means 读书笔记

教材3 p18



图 3-6 使用两个主成分绘图

对于图中以蓝色表示的肉类来说，主成分 1 的值较小，所以它们集中分布在左侧，而以橙色表示的蔬菜则集中分布在右侧。还可以看到，海产品（深蓝色）的脂肪含量较低，即主成分 2 的值较小，因而主要分布在图的左下角。同理，几种非叶类蔬菜（深橙色）的维生素 C 含量较低，所以大部分分布在图的右下角。

确定主成分数量

本例有 4 个主成分，这与数据集的原始变量个数一致。由于主成分来源于原始变量，因此用来区分数据点的可用信息会受到原始变量个数的制约。

然而，为了让结果更简单、更通用，应该只选择前几个主成分来进行可视化和后续分析。主成分按照其对数据点的区分效果进行排列，第 1 个主成分的区分效果最好。可以利用第 2 章讲过的陡坡图来确定合适的主成分数量。

从图 3-7 可以看出，随着个数增多，主成分区分数据点的效果会变差。根据经验，陡坡图曲线的拐弯处往往体现了最佳主成分数量。

教材图像说明

教材中的散点图展示了样本被分成不同群组的直观效果。

K-means 的结果依赖距离度量：离哪个中心更近，就被划到哪个簇。

图中颜色不是原始标签，而是算法根据相似性计算出的分组。


我的理解

聚类的重点不是“命名类别”，而是发现数据内部结构。

分好类以后，还要结合业务背景解释每一簇代表什么。

例如顾客分群时，需要把簇转化为高价值、价格敏感等可理解标签。

K 值选择与肘部法



教材图像说明

教材图像用曲线展示聚类数量增加后误差下降的趋势。

当 K 增大时，簇内距离通常会变小，但类别过多会降低解释性。

曲线出现明显转折的位置，可以作为选择 K 的参考。

我的理解

K 不是越大越好。

好的 K 值要兼顾数学指标和实际解释。

这和作业中改变 K 后观察聚类结果的要求是一致的。

学习小结

聚类的关键是“相似性度量”和“分组解释”。

欧式距离强调空间距离，余弦距离强调方向结构，应根据数据类型选择。

K-means 适合快速划分，HC 适合观察层次结构。

聚类没有标准答案，结果好不好要结合数据特征和应用目标判断。

本次作业中，K 值变化、树状图切分和聚类中心解释都属于“结果解释”，不能只停留在程序输出层面。

数据挖掘与机器学习第五次作业

南京工业大学张新通 | 202321054027

课后作业要求

1. 整理有关关联选股的背景知识。
2. 分析数据，清楚说明矩阵行与列的含义。
4. 分析结果，思考教材分析过程的含义，并指出教材中的错误。

关联规则的基本思想

$X \Rightarrow Y$

共现

筛选规则

业务解释

关联规则用于发现项目之间经常同时出现的关系。

典型形式为 $X \Rightarrow Y$ ，表示出现 X 时也倾向于出现 Y 。

在商业中常用于购物篮分析，在金融中可用于发现行业或股票之间的联动关系。

对行业关联选股而言，规则不是直接给出买卖结论，而是提供“哪些行业经常一起变化”的分析线索。

教材截图标注：Apriori 算法

标注重点

作业要求是“行业关联选股法”，核心算法是 Apriori。先把行业或股票表现转成事务矩阵，再寻找频繁共现组合。

Apriori 的关键不是暴力枚举所有组合，而是利用“频繁项集的子集也频繁”的思想进行剪枝。

截图页用于标注教材依据，正文页负责解释算法如何服务于行业联动分析。

Apriori

2) 基于规则中数据的抽象层次，可以分为单层关联规则和多层关联规则。

在单层的关联规则中，所有的变量都没有考虑到现实的数据是具有多个不同的层次的；而在多层的关联规则中，对数据的多层性已经进行了充分的考虑。例如：IBM 台式机 $\Rightarrow$ Sony 打印机，是一个细节数据上的单层关联规则；台式机 $\Rightarrow$ Sony 打印机，是一个较高层次和细节层次之间的多层关联规则。

3) 基于规则中涉及的数据的维数，关联规则可以分为单维的和多维的。

在单维的关联规则中，我们只涉及数据的一个维，如用户购买的物品；而在多维的关联规则中，要处理的数据将会涉及多个维。换句话说，单维关联规则是处理单个属性中的一些关系；多维关联规则是处理各个属性之间的某些关系。例如：啤酒 $\Rightarrow$ 尿布，这条规则只涉及用户购买的物品；性别=“女” $\Rightarrow$ 职业=“秘书”，这条规则就涉及两个字段的的信息，是两个维上的一条关联规则。

6.1.4 关联规则挖掘常用算法

关联规则挖掘算法是关联规则挖掘研究的主要内容，迄今为止已提出了许多高效的关联规则挖掘算法。最著名的关联规则发现方法是 R. Agrawal 提出的 Apriori 算法。Apriori 算法主要包含两个步骤：第一步是找出事务数据库中所有大于等于用户指定的最小支持度的数据项集；第二步是利用频繁项集生成所需要的关联规则，根据用户设定的最小置信度进行取舍，最后得到强关联规则。识别或发现所有频繁项目集是关联规则发现算法的核心。

关联规则挖掘另一个比较著名的算法是 J. Han 等提出的 FP-tree。该方法采用分而治之的策略，在经过第一遍扫描之后，把数据库中的频集压缩进一棵频繁模式树（FP-tree），同时依然保留其中的关联信息，随后再将 FP-tree 分化成一些条件库，每个库和一个长度为 1 的频集相关，然后再对这些条件库分别进行挖掘。当原始数据量很大时，也可以结合划分的方法，使得一个 FP-tree 可以放入主存中。实验表明，FP-Growth 对不同长度的规则都有很好的适应性，同时在效率上较之 Apriori 算法有巨大的提高。

在下面的章节中将重点介绍这两个算法。

6.2 Apriori 算法

6.2.1 Apriori 算法基本思想

关联规则的挖掘分为两步：①找出所有频繁项集；②由频繁项集产生强关联规则。而其总体性能由第一步决定。在搜索频繁项集时，最简单、基本的算法就是 Apriori 算法。算法的名字基于这样一个事实：算法使用频繁项集性质的先验知识。Apriori 使用一种被称作逐层搜索的迭代方法， k 项集用于探索 $(k+1)$ 项集。首先，通过扫描数据库，累积每个项的计数，并收集满足最小支持度的项，找出频繁 1 项集的集合。该集合记作 L_1 。然后， L_1 用于找频

支持度、置信度和提升度

支持度

规则涉及项目在全部分事务中共同出现的比例。

回答：这个组合常不常见？

在选股中可理解为某些行业共同满足条件的频率。

置信度

在 X 出现时 Y 也出现的条件概率。

回答：X 对 Y 的预测强不强？

置信度高不代表因果，只代表条件共现更明显。

提升度

规则相对随机共现的提升程度。

大于 1 通常说明存在正向关联。

它能帮助排除单纯由高频项目造成的假强规则。

Apriori 算法流程



Apriori 原理：如果一个项集是频繁的，它的所有非空子集也应是频繁的。
利用这一点可以减少候选组合数量，提高计算效率。

行业关联选股法背景

股市中不同行业并非完全独立，政策、周期、产业链和资金偏好会造成板块联动。关联选股不是直接预测涨跌，而是寻找行业或股票之间的共同变化模式。当某些行业频繁共同上涨或共同表现异常时，可作为组合观察和投资分析线索。

参考网站与背景归纳

筛选标准

行业逻辑

公司分析

数据补充

知乎问题 28778713：从大量股票中筛选目标，需要先建立选择标准，而不是随机挑选。
雪球文章 82720628：行业深度分析强调基本面逻辑，说明行业选择具有现实意义。
搜狐文章 198291969_611347：选股先看行业，再看公司，体现行业层面分析的重要性。
因此，行业关联选股法可以作为“行业之间联动关系”的数据化补充。

矩阵行、列和元素的含义

对象	含义	示例
行	交易日或观察样本	某一天
列	行业或股票	银行、证券、地产
元素	是否满足条件	上涨=1，否则=0
规则	行业间关联	证券 => 银行

矩阵把连续市场表现转化为 0/1 事务数据，便于 Apriori 算法处理。
行表示一次观察，列表示一个可参与关联分析的项目，元素表示该项目是否在该观察中出现。
如果阈值设置不同，矩阵也会变化，因此结果分析必须说明数据转化规则。

《白话机器学习》关联规则读书笔记

教材3 p21

	   
交易 2	  
交易 3	 
交易 4	 
交易 5	   
交易 6	  
交易 7	 
交易 8	 

置信度 表示当 X 项出现时 Y 项同时出现的频率，记作 $[X \rightarrow Y]$ 。换言之，置信度指同时包含 X 项和 Y 项的交易数与包含 X 项的交易数之比（如图 4-2 所示）。在表 4-1 中，{ 苹果 $\rightarrow$ 啤酒 } 的置信度为 3/4，即 75%。

$$\text{置信度} \{ \text{苹果} \rightarrow \text{啤酒} \} = \frac{\text{支持度} \{ \text{苹果}, \text{啤酒} \}}{\text{支持度} \{ \text{苹果} \}}$$

图 4-2 置信度指标

这个指标有一个缺点，那就是它可能会错估某个关联规则的重要性。图 4-2 中的例子只考虑了苹果的购买频率，而并未考虑啤酒的购买频率。如果啤酒也很受欢迎（正如表 4-1 所示），那么包含苹果的交易显然很有可能也包含啤酒，这会抬高置信度指标。然而，借助第 3 个指标，我们可以同时把苹果和啤酒出现的基础频率考虑在内。

提升度 指 X 项和 Y 项一同出现的频率，但同时要考虑这两项各自出现的频率（如图 4-3 所示）。

因此，{ 苹果 $\rightarrow$ 啤酒 } 的提升度等于 { 苹果 $\rightarrow$ 啤酒 } 的置信度除以 { 啤酒 } 的支持度。

$$\text{提升度} \{ \text{苹果} \rightarrow \text{啤酒} \} = \frac{\text{支持度} \{ \text{苹果}, \text{啤酒} \}}{\text{支持度} \{ \text{苹果} \} \times \text{支持度} \{ \text{啤酒} \}}$$

图 4-3 提升度指标

根据表 4-1，{ 苹果 $\rightarrow$ 啤酒 } 的提升度等于 1，这表示苹果和啤酒无关联。{ X $\rightarrow$ Y } 的提升度大于 1，这表示如果顾客购买了商品 X，那么可能会购买商品 Y；而提升度小于 1 则表示如果顾客购买了商品 X，那么不太可能再购买商品 Y。

4.3 示例：分析杂货店的销售数据

为了演示上述指标的用法，下面将对某个杂货店一个月（30 天）的销售数据进行分析。图 4-4 展示了多对杂货之间的关联关系，它们的置信度和提升度分别大于 0.9% 和 2.3。圆越大，支持度越高；颜色越红，则提升度越高。

教材图像说明

教材用购物篮案例说明：一张交易记录可以看成是一个事务，商品就是事务中的项目。

图中不同顾客购买的水果组合，对应关联规则中的“项集”。

关联规则从大量事务中寻找经常一起出现的项目组合。

这个思路迁移到行业选股时，交易日可看作事务，行业上涨或满足条件可看作项目。

我的理解

关联规则强调“共现”，不是因果。

支持度保证规则有足够样本基础。

置信度和提升度用于判断规则是否有分析价值。

结果分析要点

频率

条件概率

相对提升

行业解释

高支持度说明组合出现频繁，但不一定代表有投资价值。

高置信度说明前件出现时后件更可能出现，但要警惕样本偏差。

提升度大于 1 说明存在强于随机的正向关联。

最终解释必须结合行业基本面、产业链关系和市场环境。

如果规则只在少数极端行情中出现，实际参考价值会下降。

教材分析中的可能问题

如果只根据关联强度选股，容易忽略时间先后关系和因果关系。
关联规则发现的是共现模式，不等于“某行业上涨必然导致另一行业上涨”。
若没有说明阈值、样本区间和数据处理方式，结果可重复性不足。
如果教材把高置信度直接解释为投资确定性，就容易夸大关联规则的作用。
投资分析中还需要结合风险、流动性、估值和基本面因素。
因此，教材案例的合理用法应是辅助发现行业联动线索，而不是直接替代选股决策。

数据挖掘与机器学习第六次作业

南京工业大学

张新通 | 202321054027

1 (数据处理的小细节) 为什么X必须是列向量? 变成行向量会怎么样呢?

答: X 实际上是一个矩阵, 这个矩阵的大小是 25×1 , 25是行数, 1是特征数, 这样才可以运算! 如果有M行, N个变量 (属性/特征的话), 那么这个矩阵就是: $M \times N$

在 scikit-learn 里, 特征 X 必须是二维数组:

正确: $\begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$ (列向量, 二维)

错误: $[1, 2, 3]$ (行向量, 一维)


机器学习模型设计时:

每一行 = 一个样本

每一列 = 一个特征

如果你输入一维行向量, 模型会认为: 只有 1 个样本, 但有 N 个特征! 完全不符合数据逻辑, 直接报错。

2 如何显示生成的“熟模型”？ $y = b_0 + b_1 * x$, b_0 和 b_1 怎么获得？



• 2 b_0 和 b_1 怎么生成

```
b1 = regressor.coef_ # 系数
b1
[37] 0.0s Python
array([9.91065648])

b0 = regressor.intercept_ #截距 y = 2 + 9.9x
b0
[38] 0.0s Python
np.float64(2.0181600414346974)
```

3 如何评价结果的好坏？（代码） R^2 的结果是什么？

答： R^2 决定系数：越接近 1 越好

$R^2 = 1$ ：完美预测

$R^2 = 0$ ：跟瞎猜一样

$R^2 < 0$ ：模型烂到家了

- 3 评价结果的好坏 R^2

```
R2_train = regressor.score(X_train,Y_train)
R2_train
```

[39] ✓ 0.0s

... 0.9515510725211552

```
R2_test = regressor.score(X_test,Y_test)
R2_test
```

[40] ✓ 0.0s

... 0.9454906892105355

4 调整训练/测试的比例，对结果 (R^2) 有什么影响？试试看。

```
X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size = 0.5, random_state = 1) #
```

✓ 0.0s

```
[66] ✓ 0.0s
R2_train = regressor.score(X_train, Y_train)
R2_train
... 0.9659190444437519
```


▷ ▾

```
[67] ✓ 0.0s
R2_test = regressor.score(X_test, Y_test)
R2_test
... 0.9382449156444361
```

训练数据越多， R^2 越高

5 有兴趣的同学，可以采用“最小二乘法”实现该模型，可参考
<https://www.lizenghai.com/archives/20468.html>

答：网页无法访问...



数据挖掘与机器学习第七次作业

南京工业大学张新通 | 202321054027

课后作业要求

1. 观察 50_Startups 数据集特征，说明属性数量与分类变量。
2. 可视化分类变量（城市）和因变量 Profit-Y 之间的关系。
3. 总结分类变量转化为 one-hot 的过程，并写出示例代码。
4. 用 R^2 评估模型效果，获得系数和截距并写出数学公式。
5. 分析分类变量对多元线性回归的影响，判断 label 编码是否合理。

观察数据集的特征，有几个属性？


数值变量

分类变量

因变量

- 数据集共有 5 列：4 个自变量属性 + 1 个目标变量。
- 数值属性：R&D Spend-X1、Administration-X2、Marketing Spend-X3。
- 分类属性：State-X4，取值为 New York、California、Florida。
- 因变量：Profit-Y，用来表示公司利润/营收结果。




```
dataset = pd.read_csv('50_Startups.csv')
print(dataset.shape)
print(dataset.columns)
print(dataset['State-X4'].value_counts())
```



The screenshot shows a Jupyter Notebook interface. The top part displays the code used to load the dataset: `dataset = pd.read_csv('50_Startups.csv')` and `dataset.head()`. Below the code, the output shows the first five rows of the dataset. The columns are labeled: R&D Spend-X1, Administration-X2, Marketing Spend-X3, State-X4, and Profit-Y. The rows are indexed 0 through 4. The State-X4 column contains the values 'New York', 'California', 'Florida', 'New York', and 'Florida' respectively.

	R&D Spend-X1	Administration-X2	Marketing Spend-X3	State-X4	Profit-Y
0	165349.20	136897.80	471784.10	New York	192261.83
1	162597.70	151377.59	443898.53	California	191792.06
2	153441.51	101145.55	407934.54	Florida	191050.39
3	144372.41	118671.85	383199.62	New York	182901.99
4	142107.34	91391.77	366168.42	Florida	166187.94

如何可视化城市和 Profit-Y 的关系？



- 箱线图能观察每个城市利润分布、离散程度和异常值；柱状图能比较平均利润。
- 本数据中 Florida 平均 Profit-Y 最高，California 较低，但城市差异还需要结合投入变量一起解释。

如何把分类变量转化为 one-hot?

读取 State-X4



Label / OneHot



合并数值变量



进入回归模型

```
from sklearn.compose import ColumnTransformer
from sklearn.preprocessing import OneHotEncoder

ct = ColumnTransformer(
    transformers=[('encoder', OneHotEncoder(), [3])],
    remainder='passthrough')
X = np.array(ct.fit_transform(X))
```

- one-hot 会把 New York / California / Florida 转为多个 0/1 虚拟变量。
- 建模时通常删除其中一列作为基准组，避免虚拟变量陷阱。

如何完成模型训练与预测？


```
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression

X_train, X_test, Y_train, Y_test = train_test_split(
    X, Y, test_size=0.2, random_state=0)

regressor = LinearRegression()
regressor.fit(X_train, Y_train)
y_pred = regressor.predict(X_test)
```



项目	结果
测试集比例	20%
random_state	0
预测值示例	103901.90
模型类型	LinearRegression



```
y_pred = regressor.predict(X_test)
```

```
print(y_pred)
```

```
[103901.8969696  132763.05993126 133567.90370044  72911.78976736
 179627.92567224 115166.64864795  67113.5769057   98154.80686776
 114756.11555221 169064.01408795]
```

- 训练集用于估计参数，测试集用于观察泛化表现。
- 预测值 y_pred 与真实值 Y_test 对比，可以进一步计算误差或 R^2 。

如何用 R^2 评估结果?

$$R^2 = 1 - SSE / SST$$

评价指标	运行结果
全数据 R^2	0.949088
测试集 R^2	0.939396

- R^2 越接近 1, 说明模型对因变量变化的解释能力越强。
- 本次模型测试集 R^2 约为 0.939, 说明拟合效果较好。
- 评估时不能只看训练效果, 还要关注测试集表现和残差规律。

第4步 评估系数 R^2

```
R2 = regressor.score(X,Y)
R2
1) ✓ 0.0s Python
0.9490884301964866

bi = regressor.coef_ # 系数(权重)
bi
2) ✓ 0.0s Python
array([0.77884104, 0.0293919 , 0.03471025])
```


如何获得系数、截距和数学公式？

```
bi = regressor.coef_  
b0 = regressor.intercept_  
print(bi, b0)
```

参数	数值	含义
b0	42989.008	截距
b1	0.778841	R&D 权重
b2	0.029392	Administration 权重
b3	0.034710	Marketing 权重

$$\text{Profit} = 42989.008 + 0.778841X1 + 0.029392X2 + 0.034710X3$$

- R&D Spend-X1 的系数最大，说明研发投入对 Profit-Y 的预测贡献最明显。
- 系数解释应建立在“其他变量不变”的前提下。

分类变量对多元线性回归有什么影响？

特征	保留城市虚拟变量模型
R&D Spend-X1	0.773467
Administration-X2	0.032885
Marketing Spend-X3	0.036610
State-X4_Florida	-959.284160
State-X4_New York	699.369053

- 以 California 为基准组，Florida 和 New York 用虚拟变量表示。
- 计算不同城市 Profit 时，只需要把对应城市虚拟变量设为 1，其余设为 0。
- 当前 notebook 的 $X = X[:,3:6]$ 删除了城市 one-hot 列，原模型只用了三个数值变量。

$$\text{Profit} = 42554.168 + 0.773467X1 + 0.032885X2 + 0.036610X3 - 959.284F + 699.369N$$

能否把分类变量直接 label 化?

编码方式	含义	是否适合本案例
Label 编码	California=0, Florida=1, New York=2	不适合
One-hot 编码	每个城市用 0/1 单独表示	适合

- 城市名称没有大小顺序，直接变成 0、1、2 会让模型误以为城市之间有数值距离。
- one-hot 编码不会引入虚假的顺序关系，更符合分类变量的含义。
- 只有“低、中、高”这类天然有序分类变量，才适合考虑有序编码。

结论：本案例应使用 one-hot，而不是直接 label 化。

数据挖掘与机器学习第八次作业

南京工业大学张新通 | 202321054027

课后作业要求

1. Logistic 回归案例：加入分类变量 Gender，观察对结果的影响。
2. KNN 案例：加入性别因素并进行 one-hot 编码，比较准确率是否变化。
3. 比较 KNN 与 Logistic 在同一数据案例上的结果差异。
4. 观察训练集比例、超参数 K 对模型效果的影响，并说明过拟合。
5. 修改二维可视化图，在 Age / EstimatedSalary 图中体现 Gender。

本案例数据有什么特征？

样本数量 400

标签 Purchased

分类变量 Gender

项目	统计结果
Purchased=0	257 条
Purchased=1	143 条
Female	204 条
Male	196 条

- 这是一个二分类任务，目标是预测用户是否购买产品。
- 主要解释变量是 Age、EstimatedSalary，Gender 是本次加入的分类变量。

```
dataset = pd.read_csv('Social_Network_Ads.csv')
dataset['Purchased'].value_counts()
dataset['Gender'].value_counts()
```

加入分类变量 Gender，对 Logistic 结果有什么影响？

模型	混淆矩阵	Acc	<pre>X = dataset[['Gender', 'Age', 'EstimatedSalary']] ct = ColumnTransformer([('gender', OneHotEncoder(), ['Gender'])], remainder='passthrough') X = ct.fit_transform(X)</pre>
不加 Gender	[[57,1],[5,17]]	0.9250	
加入 Gender	[[56,2],[5,17]]	0.9125	

```
p = (cm[0,0]+cm[1,1])/(cm[0,0]+cm[1,1]+cm[0,1]+cm[1,0])
p
```

[16] ✓ 0.0s Python

np.float64(0.925)

```
p = (cm[0,0]+cm[1,1])/(cm[0,0]+cm[1,1]+cm[0,1]+cm[1,0])
p
```

[33] ✓ 0.0s Python

np.float64(0.9125)

- 加入 Gender 后准确率从 0.9250 降到 0.9125，说明它对本案例帮助不明显。
- Logistic 回归仍主要依赖 Age 和 EstimatedSalary 来划分购买与不购买。

加入性别因素后，KNN 的 Acc 有没有变化？

KNN 模型	混淆矩阵	Acc
不加 Gender	[[55,3],[1,21]]	0.9500
加入 Gender	[[55,3],[1,21]]	0.9500

```
classifier = KNeighborsClassifier(n_neighbors=5, metric='minkowski', p=2) classifier.fit(X_train, y_train) y_pred = classifier.predict(X_test)
```

```
# 1 加入性别因素
import pandas as pd
import numpy as np # 一个熟悉的库, num+py
dataset = pd.read_csv('Social_Network_Ads.csv')
dataset.head()
```

```
accuracy = (cm[0,0]+cm[1,1])/(cm[0,0]+cm[0,1]+cm[1,0]+cm[1,1])
accuracy
np.float64(0.95)
```

```
accuracy = (cm[0,0]+cm[1,1])/(cm[0,0]+cm[0,1]+cm[1,0]+cm[1,1])
accuracy
np.float64(0.95)
```

User ID	Gender	Age	EstimatedSalary	Purchased
0 15624510	Male	19	19000	0
1 15810944	Male	35	20000	0
2 15668575	Female	26	43000	0
3 15603246	Female	27	57000	0
4 15804002	Male	19	76000	0

- 加入 Gender 后 KNN 准确率没有变化，仍为 0.95。
- 说明性别变量不是关键分类因素，年龄和收入的局部分布更重要。

KNN 与 Logistic 哪个算法更有效?

算法	特征	Acc
Logistic	Age + Salary	0.9250
KNN	Age + Salary	0.9500

本案例：KNN 更有效

- KNN 根据邻近样本投票分类，更适合 Age / EstimatedSalary 上呈现局部边界的数据。
- Logistic 是线性分类器，若边界不是单纯直线，表现可能弱于 KNN。

训练集比例如何影响结果？

训练集比例	KNN Acc	Logistic Acc
0.60	0.8938	0.8562
0.70	0.9174	0.8678
0.75	0.9300	0.8900
0.80	0.9500	0.9250
0.90	0.9250	0.9500

- 训练集增大通常能提升模型学习效果。
- 测试集过小时，准确率容易受样本随机性影响而波动。
- 本案例中 80% 训练集时，KNN 测试效果最好。

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=0)
```

超参数 K 如何影响结果?

K	训练集 Acc	测试集 Acc
1	0.9969	0.8875
3	0.9156	0.9500
5	0.9187	0.9500
7	0.9094	0.9500
9	0.9125	0.9500

- K=1 训练集准确率极高，但测试集准确率较低，容易过拟合。
- K=3、5、7、9 的测试集 Acc 均为 0.95。
- K 值通常选奇数，可以减少投票平局。

```
for k in [1, 3, 5, 7, 9]:  
    classifier = KNeighborsClassifier(n_neighbors=k)
```

什么情况下会出现过拟合?

训练集表现好

测试集表现差

泛化能力弱

案例	训练集 Acc	测试集 Acc
KNN, K=1	0.9969	0.8875

- K 过小会让模型过度依赖单个邻居，容易记住训练样本细节。
- 判断过拟合时，要同时比较训练集和测试集表现。


结论：模型不是训练集越准越好，能在新样本上稳定预测才更重要。

二维图中如何把性别变量考虑进去？

```
# 1. 读取数据
dataset = pd.read_csv('Social_Network_Ads.csv')

# 2. 二维图仍然使用 Age 和 EstimatedSalary
# 用颜色表示是否购买 Purchased
# 用点的形状表示性别 Gender
sns.scatterplot(
    data=dataset,
    x='Age',
    y='EstimatedSalary',
    hue='Purchased',
    style='Gender',
    s=80
)

plt.title('Age and EstimatedSalary with Gender')
plt.xlabel('Age')
plt.ylabel('EstimatedSalary')
plt.show()
```




```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

dataset = pd.read_csv('Social_Network_Ads.csv')

sns.relplot(
    data=dataset,
    x='Age',
    y='EstimatedSalary',
    hue='Purchased',
    col='Gender',
    kind='scatter',
    height=4,
    aspect=1
)

plt.show()
```



- 二维坐标仍使用 Age 和 EstimatedSalary。
- Gender 可用点形状或分面子图表示，Purchased 用颜色表示。

数据挖掘与机器学习第九次作业

南京工业大学张新通 | 202321054027

决策树作业要求

1. 加入性别因素，看看 Acc 的变化。
2. 如何不进行特征缩放，预测的准确性有什么变化？
3. 比较 KNN、Logistic、决策树在该数据集上的表现。
4. 把决策树输出看看长什么样。

加入性别因素，Acc 有什么变化？

决策树模型	混淆矩阵	Acc
不加 Gender	[[53,5],[3,19]]	0.9000
加入 Gender	[[53,5],[3,19]]	0.9000

```
[16] ✓ 0.0s
... 混淆矩阵:
    [[53  5]
     [ 3 19]]
    准确率: 0.9
```

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import OneHotEncoder, StandardScaler
from sklearn.compose import ColumnTransformer
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import confusion_matrix, accuracy_score

# 1. 读取数据
dataset = pd.read_csv('Social_Network_Ads.csv')

# 2. 加入性别因素: Gender + Age + EstimatedSalary
X = dataset[['Gender', 'Age', 'EstimatedSalary']]
y = dataset['Purchased']

# 3. 对 Gender 做 one-hot 编码
ct = ColumnTransformer(
    transformers=[
        ('gender', OneHotEncoder(), ['Gender'])
    ],
    remainder='passthrough'
)

X = ct.fit_transform(X)

# 4. 划分训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.2,
    random_state=0
```

- 随机森林是 notebook 第15单元补充模型，会覆盖 clf；纯决策树结果仍为 0.9000。
- 加入 Gender 后测试集 Acc 没有变化，仍为 0.9000。
- 说明本案例中性别变量对决策树分类帮助不明显，Age 和 EstimatedSalary 更关键。

不进行特征缩放，预测准确性有什么变化？

设置	混淆矩阵	Acc
进行缩放	[[53,5],[3,19]]	0.9000
不缩放	[[53,5],[3,19]]	0.9000

- 决策树按照特征阈值切分样本，不依赖距离大小。
- 因此决策树通常不要求特征缩放。
- 本实验中缩放与否 Acc 完全相同。

```
print('混淆矩阵: ')
print(cm)
print('准确率: ', acc)
```

7] ✓ 0.0s

混淆矩阵:
[[53 5]
 [3 19]]
准确率: 0.9

```
# 1. 读取数据
dataset = pd.read_csv('Social_Network_Ads.csv')

# 2. 选择特征和标签
# 不加入性别，只使用 Age 和 EstimatedSalary
X = dataset[['Age', 'EstimatedSalary']]
y = dataset['Purchased']

# 3. 划分训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.2,
    random_state=0
)

# 4. 不进行特征缩放，直接训练决策树
clf = DecisionTreeClassifier(
    criterion='entropy',
    random_state=0
)

clf.fit(X_train, y_train)

# 5. 预测
y_pred = clf.predict(X_test)

# 6. 生成混淆矩阵和准确率
cm = confusion_matrix(y_test, y_pred)
acc = accuracy_score(y_test, y_pred)
```

KNN、Logistic、决策树表现如何？

算法	混淆矩阵	Acc
KNN K=5	[[55,3],[1,21]]	0.9500
Logistic	[[57,1],[5,17]]	0.9250
决策树	[[53,5],[3,19]]	0.9000
随机森林*	[[55,3],[2,20]]	0.9375

本案例：KNN 最优

- KNN 在测试集上 Acc 最高。
- 随机森林是 notebook 第15单元补充模型，会覆盖 clf；纯决策树结果仍为 0.9000。

决策树文本规则如何输出?

```
# 1. 读取数据
dataset = pd.read_csv('Social_Network_Ads.csv')

# 2. 选择特征和标签
X = dataset[['Age', 'EstimatedSalary']]
y = dataset['Purchased']

# 3. 划分训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.2,
    random_state=0
)

# 4. 特征缩放
sc = StandardScaler()
X_train = sc.fit_transform(X_train)
X_test = sc.transform(X_test)

# 5. 训练决策树
clf = DecisionTreeClassifier(
    criterion='entropy',
    random_state=0,
    max_depth=4
)

clf.fit(X_train, y_train)
```


```

... |--- Age <= 0.61
    |--- EstimatedSalary <= 0.60
    |   |--- Age <= -0.17
    |   |   |--- class: 0
    |   |--- Age > -0.17
    |   |   |--- EstimatedSalary <= -0.07
    |   |   |   |--- class: 0
    |   |   |--- EstimatedSalary > -0.07
    |   |   |   |--- class: 0
    |--- EstimatedSalary > 0.60
    |   |--- EstimatedSalary <= 1.84
    |   |   |--- EstimatedSalary <= 1.09
    |   |   |   |--- class: 1
    |   |   |--- EstimatedSalary > 1.09
    |   |   |   |--- class: 1
    |   |--- EstimatedSalary > 1.84
    |   |   |--- class: 1
    |--- Age > 0.61
    |   |--- EstimatedSalary <= -0.82
    |   |   |--- EstimatedSalary <= -1.37
    |   |   |   |--- Age <= 0.81
    |   |   |   |   |--- class: 0
    |   |   |   |--- Age > 0.81
    |   |   |   |   |--- class: 1
    |   |--- EstimatedSalary > -1.37
    ...
    |   |   |--- class: 1
    |   |--- Age > 1.97
    |   |   |--- class: 1

```

- 树图能直观看到分裂结构，文本规则能清楚看到每一步判断条件。
- Age、EstimatedSalary 前面的数值是标准化后的阈值。

把决策树输出看看长什么样？



本次决策树作业结论

- 加入 Gender 后，决策树 Acc 不变，说明性别变量贡献不明显。
- 是否进行特征缩放对决策树结果没有影响。
- 同一数据集上，KNN Acc=0.9500，Logistic Acc=0.9250，决策树 Acc=0.9000。
- 决策树可解释性强，可以输出树图和规则文本，但树太深时容易过拟合。

综合来看：本案例预测效果 KNN 更好，模型解释性决策树更直观。

数据挖掘与机器学习第十次作业


南京工业大学

张新通 | 202321054027

1 用花萼（第一0列和第二1列）的数据来聚类

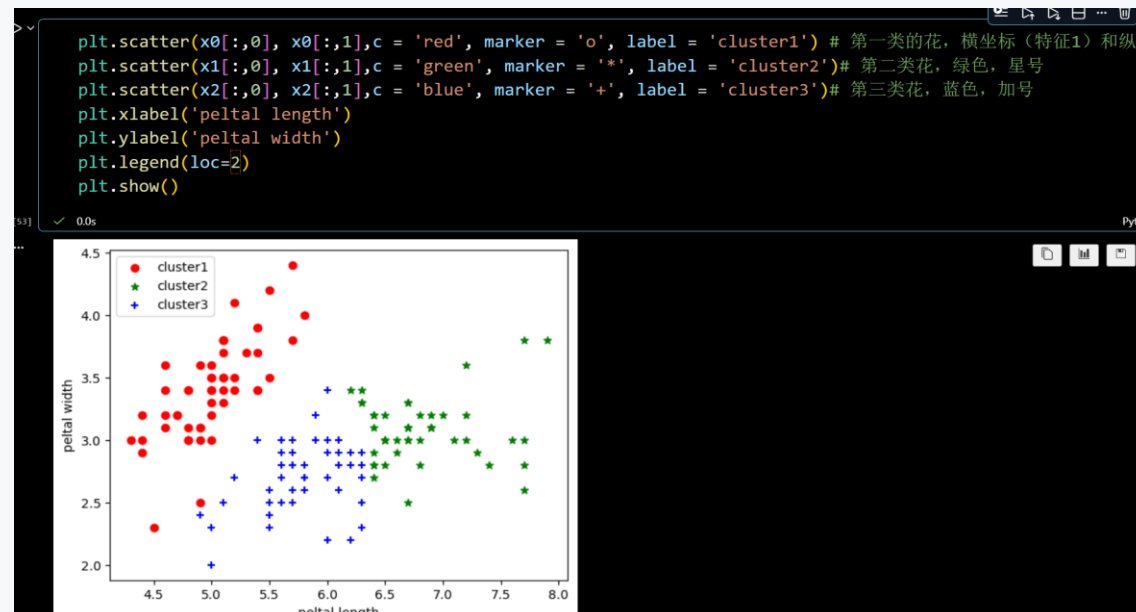
```
is.data[:,0:2]
X_2[0:10,:]
```

```
array([[5.1, 3.5],
       [4.9, 3. ],
       [4.7, 3.2],
       [4.6, 3.1],
       [5. , 3.6],
       [5.4, 3.9],
       [4.6, 3.4],
       [5. , 3.4],
       [4.4, 2.9],
       [4.9, 3.1]])
```



```
label_pred
```

```
array([0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
       0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
       0, 0, 0, 0, 0, 1, 1, 1, 2, 1, 2, 1, 2, 1, 2, 2, 2, 2, 2, 2, 1,
       2, 2, 2, 2, 2, 2, 2, 2, 1, 1, 1, 1, 2, 2, 2, 2, 2, 2, 2, 1, 2,
       2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 1, 2, 1, 1, 1, 1, 2, 1, 1, 1,
       1, 1, 1, 2, 2, 1, 1, 1, 1, 2, 1, 2, 1, 2, 1, 1, 2, 2, 1, 1, 1, 1,
       1, 2, 2, 1, 1, 1, 2, 1, 1, 1, 2, 1, 1, 1, 2, 1, 1, 2], dtype=int32)
```



2用所有数据来聚类（所有4列）

```
[157] ✓ 0.0s Python
X_2 = iris.data[:,0:4]

[158] ✓ 0.0s Python
X_2[0:10,:]
'''
array([[5.1, 3.5, 1.4, 0.2],
       [4.9, 3. , 1.4, 0.2],
       [4.7, 3.2, 1.3, 0.2],
       [4.6, 3.1, 1.5, 0.2],
       [5. , 3.6, 1.4, 0.2],
       [5.4, 3.9, 1.7, 0.4],
       [4.6, 3.4, 1.4, 0.3],
       [5. , 3.4, 1.5, 0.2],
       [4.4, 2.9, 1.4, 0.2],
       [4.9, 3.1, 1.5, 0.1]])

[171] ✓ 0.0s
label_pred
'''
array([0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
       0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
       0, 0, 0, 0, 0, 0, 1, 1, 2, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,
       1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 2, 1, 1, 1, 1, 1, 1, 1, 1, 1,
       1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 2, 1, 2, 2, 2, 2, 1, 2, 2, 2,
       2, 2, 2, 1, 1, 2, 2, 2, 2, 1, 2, 1, 2, 1, 2, 2, 1, 1, 2, 2, 2, 2,
       2, 1, 2, 2, 2, 2, 1, 2, 2, 2, 1, 2, 2, 2, 1, 2, 2, 1], dtype=int32)
```


3这里的K=3，把K改成2，试一试？

```
estimator = KMeans(n_clusters=2)
```

[176] ✓ 0.0s Python


```
label_pred
```

[182] ✓ 0.0s

```
... array([1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,
          1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,
          1, 1, 1, 1, 1, 1, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0,
          0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
          0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
          0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
          0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0], dtype=int32)
```

4查考资料，分析该案例，聚类的其他输出，比如：聚类中心（代码）。
可视化聚类中心。

聚类结果图



距离可视化图

