

数据挖掘与机器学习第一次作业

南京工业大学张新通 | 202321054027

课后作业要求

1. 阅读《参考教材1》第1-2章、4-5章。
2. 阅读《白话机器学习算法》第1章，整理读书笔记。
3. 整理本章上页 PPT “本章概念汇总”，形成笔记。

大数据的基本认知

大数据

规模巨大、类型复杂、增长快速的数据集合。

核心不只是“大”，而是能从数据中发现价值。

对管理决策而言，数据越多越需要方法筛选信息。

4V 特征

Volume: 数据量大

Variety: 类型多样

Velocity: 产生和处理速度快

Value: 价值密度低但潜在价值高

数据价值

通过分析规律支持预测、决策和优化。

价值往往隐藏在大量噪声和碎片信息中。

数据挖掘的任务就是把隐含规律转化为可用知识。

数据挖掘的概念

概念

任务

决策

数据挖掘是从大量、不完全、有噪声、模糊、随机的数据中，提取隐含的、事先未知的、潜在有用信息和知识的过程。

它不是简单查询，也不是只做统计描述，而是发现规律、建立模型并服务决策。

常见任务包括关联、回归、分类、聚类、预测和诊断。

本质上，数据挖掘连接了“原始数据”和“管理知识”：先处理数据，再建模解释，最后服务实际问题。

数据挖掘的基本过程



六阶段模型强调：先明确业务问题，再处理数据，最后让模型真正进入应用。
数据准备和探索往往占用最多时间，也是结果可靠性的基础。

教材截图标注：数据挖掘要点

标注重点

课后作业要求整理“数据挖掘的几个要点”（J p20-p21），本页对应教材中这一部分。

教材强调数据挖掘不是孤立算法，而是围绕目标、数据准备、模型建立和业务应用展开。

作业中应抓住三层逻辑：数据规模扩大、挖掘目标明确、结果服务业务决策。

这一页可作为“概念笔记”的依据：先写清数据来源，再写处理过程，最后说明输出知识如何产生价值。

J p20

管水平的目的。建设大数据中心，加强政务数据的获取、组织、分析、决策，通过云计算技术实现大数据对政务信息资源的统一管理，依据法律法规和各部门的需求进行政务资源的开发和利用，可以提高设备资源利用率、避免重复建设、降低维护成本。

大数据也将进一步提高决策的效率，提高政府决策的科学性和精准性，提高政府预测预警能力以及应急响应能力，节约决策的成本。以财政部门为例，基于云计算、大数据技术，财政部门可以按需掌握各个部门的数据，并对数据进行分析，作出的决策可以更准确、更高效。另外，也可以依据数据推动财政创新，使财政工作更有效率、更加开放、更加透明。2008年，法国总统萨科齐组建了一个专家组，成员包括以诺贝尔经济学奖获得者约瑟夫·斯蒂格利茨和阿玛蒂亚·森在内的20多名世界知名专家，进行了一项名为“幸福与测度经济进步”的研究。该研究将国民主观幸福感纳入了衡量经济表现的指标，以主观幸福度、生活质量及收入分配等指标来衡量经济发展。

1.5 大数据挖掘的要点

虽然大数据挖掘与一般的数据挖掘在挖掘过程、算法等方面差异不大，但由于大数据在广度和量度上的特殊性，对大数据的挖掘在实现上也会有些不同。要做好大数据的挖掘，除了掌握一般的数据挖掘方法，另外还要把握以下几个大数据挖掘的要点：

（1）大数据思维

大数据思维的核心是要具有利用数据的意识，无论量小还是量大。当我们处理的业务中涉及数据，尤其是有大量数据时，我们要想到是否可以利用这些数据处理碰到的新问题，这就是大数据思维。大数据思维也同时要求思维是开放的、包容的。在数据分享、信息公开的同时，也在释放善意，取得互信，在数据交换的基础上产生合作，这将打破传统封闭与垄断，形成开放、共享、合作思维。创造性思维是大数据思维方式的特性之一，通过对数据的重组、扩展和再利用，突破原有的框架，开拓新领域、确立新决策，发现隐藏在表面之下的数据价值，数据也创造性地成为可重复使用的“再生性”资源。

（2）大数据的收集与集成

大数据是客观存在的，但必须要对其进行控制和操作后才会进行更有意义的挖掘，而操作大数据的第一步就是大数据的收集和集成。

大数据挖掘在收集数据方面的要点就是理清和挖掘与目标可能有关联的数据，然后将这些关联数据收集起来。在当前，两个技术使得大数据的收集开始变得容易：一是各种传感器的廉价化和部署覆盖率的大大提高。比如，我们最熟悉的就是遍布身边的摄像头，不到10年的时间，城市里的任何一个角落放眼望去就全部是摄像头了。二是互联网，随着互联网技术的大发展，能够接入互联网的终端越来越便宜，在人群中的覆盖率不断提高，以致于我们拥有了一个可以覆盖大部分人口的传感器网络。比如，淘宝网每天有亿级别的用户访问、购物。在传统的工业时代，我们永远无法知道一个人在超市做了什么，也很难分析每个人在超

数据准备与预处理

为什么要预处理

原始数据常见问题：缺失、异常、重复、格式不一致。

不处理会导致模型偏差，甚至让算法无法运行。

数据准备是六阶段模型中最耗时的一环，也是后续分析可靠性的基础。

例如收入、年龄、购买次数等变量量纲不同，直接比较会影响距离或系数。

常见处理

数据清洗：修正错误、缺失和重复记录。

标准化/归一化：让不同量纲变量可比较。

衍生变量：根据业务含义构造新特征。

数据划分：保留测试集，避免只在训练数据上评价模型。

概念整理：大数据与数据挖掘

大数据 Big Data

指规模巨大、类型多样、产生速度快的数据集。

教材强调大数据的意义不只在“量大”，更在于通过分析发现隐藏价值。

典型特征可概括为 4V: Volume、Variety、Velocity、Value。

数据挖掘 Data Mining

从大量、不完全、有噪声的数据中，发现隐含、未知但有用的信息和知识。

它不是简单查询，而是经过数据准备、探索、建模、评估和应用的过程。常见任务包括关联、回归、分类、聚类、预测和诊断。

二者关系

大数据提供数据资源，数据挖掘提供发现规律的方法。

没有挖掘方法，大数据容易停留在存储层面。

没有高质量数据，模型也难以产生可靠知识。

概念整理：学习方式与数据形态

概念	含义	典型例子
有监督	训练数据带标签	分类、回归
无监督	训练数据无标签	聚类、降维
结构化	表格化、字段固定	数据库表
半结构化	有结构但不完全固定	XML、JSON
非结构化	缺少统一字段结构	文本、图片、视频

有监督学习关注“已知答案下学习映射关系”，无监督学习关注“没有标签时发现内部结构”。
数据形态决定了处理方法：结构化数据可直接建表分析，半结构化数据需解析字段，非结构化数据通常要先做特征提取。

概念整理：数据降维

数据降维

在尽量保留主要信息的前提下，减少变量数量或降低特征空间维度。

作用是降低计算复杂度、减少噪声、便于可视化和理解数据结构。

PCA 主成分分析

通过线性变换把原变量组合成少数主成分。

主成分按照解释方差大小排序，前几个主成分保留主要信息。

适合连续数值型变量的压缩和可视化。

t-SNE

用于高维数据的低维可视化，强调保持局部邻近关系。

常把复杂高维样本映射到二维平面观察群组结构。

更适合展示分布，不宜直接当作预测模型。

概念整理：数据处理与变量构造

概念	含义	作用
数据预处理	建模前的数据整理	提高数据可用性
数据清洗	处理缺失、异常、重复	减少错误和噪声
标准化	转成均值0、标准差1	消除量纲影响
归一化	缩放到固定区间	便于距离计算
衍生变量	由原始变量加工得到	增强业务解释力

数据预处理是总称，数据清洗是其中重要步骤。
标准化更强调按统计分布转换，归一化更强调把数值压缩到同一范围。
衍生变量来自业务理解，例如由购买时间生成“最近一次购买间隔”，由收入和负债生成“负债率”。

《白话机器学习》第1章读书笔记

教材3 p7

无监督学习	主成分分析 关联规则 社会网络分析
监督学习	回归分析 k 最近邻 支持向量机 决策树 随机森林 神经网络
强化学习	多臂老虎机

1.2.1 无监督学习

任务目标：指出数据中隐藏的模式。

当希望找出数据集中隐藏的模式时，可以使用 均值聚类、主成分分析、关联规则、社会网络分析等无监督学习算法。之所以称之为无监督学习算法，是因为我们不知道要找的模式是什么，而是要依靠算法从数据集中发现模式。

以表 1-1 中的数据为例，可以应用无监督学习模型找出哪些商品是顾客经常搭配购买的（其中会用到第 4 章讲解的关联规则算法），或者根据购买的商品对顾客进行分类（第 2 章将进行讲解）。

通过间接手段，可以对无监督学习模型输出的结果进行验证，比如检查得到的顾客分类是否与我们熟悉的分类（如食草动物和食肉动物）相符合。

1.2.2 监督学习

任务目标：使用数据中的模式做预测。

当需要做预测时，就会用到回归分析、k 最近邻、支持向量机、决策树、随机森林、神经网络等监督学习算法。之所以称之为监督学习算法，是因为它们的预测都基于已有的模式。

以表 1-1 中的数据为例，监督学习模型可以根据“顾客类别”以及“是否买鱼”（二者皆为预测变量）来预测“水果购买量”。

通过输入非表中顾客的预测变量值（“顾客类别”和“是否买鱼”），并且对比预测结果和实际的“水果购买量”，可以直接评估监督学习模型的准确度。

像“水果购买量”这样的整型数值或连续数值的预测过程，实际上是在解决回归问题。如图 1-1a 所示。二元值或分类值的预测过程，如预测是否会下雨，则是在解决分类问题，如图 1-1b 所示。尽管如此，大部分分类算法也可以生成连续的概率值，比如预测“降水概率是 75%”，这种预测精度更高。

教材图像说明

截图展示了机器学习基础章节中的数据、变量和算法选择内容。

读书时不能只记算法名称，还要先判断数据类型、变量含义和任务目标。

如果变量选择不合理，后面的模型再复杂也很难得到可信结果。

我的理解

第1章像是机器学习的“总入口”。

准备数据、选择算法、调参、评价模型是一条完整链路。

它和参考教材1的数据挖掘六阶段模型可以对应起来理解。

学习小结

第一讲建立了数据挖掘的整体框架：数据、任务、过程和应用。

理解“从数据到知识”的流程，比记住单个算法更重要。

本章概念可以串成一条主线：先认识数据形态，再清洗和转换数据，接着选择监督或无监督方法，最后评价结果能否服务决策。

后续回归、分类、聚类、关联规则都可以放入六阶段模型中理解：它们只是模型建立阶段的不同方法。

读书笔记的重点不是摘抄概念，而是把概念放入实际问题中解释，例如如何从企业数据中发现客户、风险或市场规律。