

数据挖掘与机器学习第二次作业

南京工业大学张新通 | 202321054027

课后作业要求

1. 整理数据回归方法的基本方法、步骤。
2. 整理一元线性回归和多元线性回归的基本数学模型。
3. 整理 Logistic 回归模型，说明它与普通回归的联系和区别。
4. 阅读《白话机器学习》第六章“回归”，完成读书笔记。

回归方法的基本思想

目标变量 y

解释变量 x

参数估计 b


回归用于研究变量之间的数量关系，并根据已知变量预测连续型结果。

核心任务是找到一个函数，使预测值尽量接近真实值。

建模时通常需要：确定目标变量、选择解释变量、估计参数、评价模型效果。

在数据挖掘流程中，回归既可以用于预测，也可以用于解释变量影响方向。

数据回归的基本步骤



收集数据后要先明确因变量 y 和解释变量 x ，避免把无关变量直接塞进模型。

训练集用于估计参数，测试集用于观察模型对新数据的表现。

检验效果时既看 R^2 、误差，也要看残差是否存在明显规律。

如果只看训练结果，容易高估模型能力；预测应用前应确认模型具有可解释性和稳定性。

一元线性回归模型

$$y = b_0 + b_1x + e$$

y 是因变量, x 是自变量。

b_0 表示截距, b_1 表示 x 每增加 1 个单位时 y 的平均变化量。

e 表示随机误差, 用来表示模型无法解释的部分。

教材截图标注：一元线性回归

标注重点

本页对应一元线性回归模型，是回归方法中最基础的形式。

整理时重点写清：一个自变量、一个因变量、截距 b_0 、斜率 b_1 和误差项 e 的含义。

b_1 的解释要结合变量单位： x 每增加 1 个单位， y 的平均变化量为 b_1 。

公式页后接截图页，既说明内容来自教材，也能把抽象模型和教材原文对应起来。

J p126

一元性：一元线性、一元非线性、多元线性、多元非线性。另外还有两种特殊的回归方式，一种在回归过程中可以调整变量数的回归方法，称为逐步回归，另一种是以指数结构函数作为回归模型的回归方法，称为 Logistic 回归。本章将逐一介绍这几个回归方法。

7.1 一元回归

7.1.1 一元线性回归

设 Y 是一个可观测的随机变量，它受到一个非随机变量因素 x 和随机误差 ε 影响。若 Y 与 x 有如下线性关系：

$$Y = \beta_0 + \beta_1 x + \varepsilon$$

且 ε 的均值 $E(\varepsilon) = 0$ ，方差 $\text{var}(\varepsilon) = \sigma^2 (\sigma > 0)$ ，其中 β_0 、 β_1 是固定的未知参数，称为回归系数， Y 称为因变量， x 称为自变量，则称此 Y 与 x 之间的函数关系表达式为一元线性回归模型。

对于实际问题，要建立回归方程，首先要确定能否建立线性回归模型，其次确定如何对模型中的未知参数 β_0 、 β_1 进行评估。

通常，我们首先对总体 (x, Y) 进行 n 次独立观测，获得 n 组数据（称为样本观测值）：

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$$

然后在直角坐标系 xOy 中画出数据点 $(x_i, y_i), (i = 1, 2, \dots, n)$ ，该图形称为数据的散点图。如果这些点大致地位于同一条直线的附近，或者说，散点图呈现线性形状，则认为 Y 与 x 之间的关系符合线性关系。此时，利用最小乘法可以得到回归模型参数 β_0 、 β_1 的最小二乘估计 $\hat{\beta}_0$ 、 $\hat{\beta}_1$ ，估计公式为：

$$\begin{cases} \hat{\beta}_0 = \bar{y} - \bar{x} \hat{\beta}_1 \\ \hat{\beta}_1 = \frac{L_{xy}}{L_{xx}} \end{cases}$$

$$\text{其中，} \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i, L_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2, L_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})。$$

于是就可以建立经验模型：

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

对于得到的回归方程形式，通常需要进行回归效果的评价，当有几种回归结果后，还通常要加以比较以选出较好的方程，常用的准则有：

1) 决定系数 R^2 ，其数学定义为：

$$R^2 = 1 - \frac{\text{SSE}}{\text{SST}}$$

R^2 称为决定系数。显然 $R^2 \leq 1$ ， R^2 大表示观测值 y_i 与拟合值 $\hat{y}_i$ 比较靠近，也就意味着

多元线性回归模型

$$y = b_0 + b_1x_1 + b_2x_2 + \dots + b_nx_n + e$$

多元线性回归同时考虑多个解释变量，更接近真实问题。

每个系数表示在其他变量不变时，该变量对 y 的边际影响。

变量间相关性过强时，可能影响系数解释，出现多重共线性问题。

建模时应关注变量含义、显著性、方向是否符合业务常识，而不是只追求拟合度。

Logistic 回归模型

$$P(y=1) = 1 / (1 + e^{-(b_0+b_1x_1+\dots+b_nx_n)})$$

Logistic 回归输出的是某一类别发生的概率。
通过 Sigmoid 函数把线性组合压缩到 0-1 之间。
常用于二分类问题，如是否违约、是否购买、是否流失。

教材截图标注： Logistic 回归

标注重点

本页对应 Logistic 回归数学模型。
它先形成线性组合，再通过 Sigmoid 函数转换为 0-1 之间的概率。
它看起来像回归，但输出可解释为“属于某类”的概率，因此常用于二分类问题。
它是“回归方法”和“分类任务”的连接点：参数估计类似回归，任务目标更接近分类。

J p144

31,22,44;2,54,18,22;21,47,4,26;1,40,23,34;11,66,9,12]; %自变量数据
Y=[78.5,74.3,104.3,87.6,95.9,109.2,102.7,72.5,93.1,115.9,83.8,113.3]; %因变量数据
Stepwise (X,Y,[1,2,3,4],0.05,0.10) % in=[1,2,3,4]表示 X1、X2、X3、X4 均保留在模型中
程序执行后得到下列逐步回归的窗口，如图 7-6 所示。




图 7-6 逐步回归操作界面

图 7-6 显示变量 X1、X2、X3、X4 均保留在模型中，窗口的右侧按钮上方提示：将变量 X3 剔除回归方程（Move X3 out），单击“Next Step”按钮，即进行下一步运算，将第 3 列数据对应的变量 X3 剔除回归方程。单击“Next Step”按钮后，剔除的变量 X3 所对应的行用红色表示，同时又得到提示：将变量 X4 剔除回归方程（Move X4 out），单击“Next Step”按钮，这样一直重复操作，直到“Next Step”按钮变灰，表明逐步回归结束，此时得到的模型即为逐步回归最终的结果。

7.4 Logistic 回归

7.4.1 Logistic 模型

在回归分析中，因变量 y 可能有两种情形：① y 是一个定量的变量，这时就用通常的 regress 函数对 y 进行回归；② y 是一个定性的变量，比如 $y = 0$ 或 1 ，这时就不能用通常的 regress 函数对 y 进行回归，而是使用所谓的 Logistic 回归。Logistic 方法主要应用在研究某些现象发生的概率 p ，比如股票涨还是跌，公司成功或失败的概率。除此之外，本章还讨论概率 p 与哪些因素有关。Logistic 回归模型的基本形式为：

$$p(Y=1|x_1,x_2,\dots,x_k)=\frac{\exp(\beta_0+\beta_1x_1+\dots+\beta_kx_k)}{1+\exp(\beta_0+\beta_1x_1+\dots+\beta_kx_k)}$$

其中， $\beta_0, \beta_1, \dots, \beta_k$ 为类似于多元线性回归模型中的回归系数。

Logistic 与线性回归的联系和区别

项目	线性回归	Logistic 回归
输出	连续数值	类别概率
任务	预测数量	预测类别
函数	线性函数	Sigmoid 函数
评价	误差 / R^2	准确率 / 混淆矩阵

二者都通过变量和系数建立模型，变量选择、参数解释和模型检验都很重要。
区别在于输出含义不同：线性回归直接预测数值，Logistic 回归预测概率并根据阈值转成类别。
因此 Logistic 回归虽然名字中有“回归”，但在数据挖掘任务中经常服务于分类。

模型评价：R² 和误差

R²

误差

泛化

解释性

R² 越接近 1，说明模型对数据波动的解释能力越强。

误差越小，说明预测值越接近真实值。

实际建模不能只看一个指标，还要看数据质量、变量含义和模型稳定性。

如果训练集效果很好、测试集效果变差，可能存在过拟合，需要重新检查变量和模型复杂度。

《白话机器学习》第六章读书笔记

教材3 p30




图 6-2 房价和低收入居民占比的关系

经过观察可以发现，相比于图 6-1，图 6-2b 中有更多数据点集中在趋势线附近，这说明周围居民的富裕程度对房价的影响要比房间数的影响大。

为了提高房价预测结果的准确度，可以把房间数和周围居民的富裕程度结合起来并将其作为一个预测变量使用。不过，由于后者对房价的影响要比前者大，因此把两者简单地加起来并不合理。合理的做法是给予周围居民富裕程度所做的预测赋予更高的权重，如图 6-3 所示。




图 6-3 房价和带权重的组合预测变量的关系，组合预测变量由房间数和周围居民的富裕程度组合而成

图 6-3 反映的是房价和带有最优权重的组合预测变量的关系。该组合预测变量由房间数和周围居民的富裕程度这两个预测变量组合而成。请注意，相比之前，图中的数据点离趋势线更近，因此通过这条趋势线所做的预测可能是最准确的。为了验证这一点，可以比较使用 3 条趋势线所得到的平均预测误差，如表 6-1 所示。

表 6-1 使用 3 条趋势线所得到的平均预测误差

教材图像说明

截图中的散点图和趋势线展示了回归的直观含义：用一条线刻画变量间的整体变化趋势。

点越围绕趋势线分布，线性关系越明显。

离趋势线较远的点会增加误差，也可能提示异常值或遗漏变量。

我的理解

回归不是把所有点都连起来，而是寻找整体规律。

模型好坏要看预测误差，也要看变量是否有现实含义。

在作业案例中， R^2 可以作为直观评价指标，但不能替代业务解释。

梯度下降与参数调整

教材3 p32




图 6-5 凹坑（绿色三角形）可能会被误认为是最优点，而真实的最优点在更下方（绿色水平线）

为了降低陷入这种凹坑的风险，可以使用另外一种方法——**随机梯度下降法**。在这种方法中，每次迭代并不是采用所有数据点，而是只从其中选取一个来调整参数。这样做就引入了多变性，有助于算法逃离凹坑。虽然从这个随机过程中得到的最终参数值可能不是最优的，但与最优值很接近，精度还是相当不错的。

梯度下降法的这个缺点通常只出现在更为复杂的模型中，做回归分析时根本无须担心这一点。

6.4 回归系数

在为回归预测变量求得最佳权重之后，需要对它们进行解释。

回归预测变量权重的正式名称是**回归系数**，它表示某个预测变量相比于其他预测变量的影响大小。换言之，它表示相关预测变量的增加值，而非绝对预测强度。

举例来说，如果使用房屋的建筑面积和房间数来预测房价，那么房间数的权重也许可以忽略不计。因为房间数在衡量房屋大小方面的作用与建筑面积有重叠，所以它对整个预测能力的贡献很小。

预测变量的度量单位不同也会影响对回归系数的解释。比如，对于同一个预测变量，以米为度量单位时的权重是以厘米为度量单位时的 100 倍。为了避免这个问题，应该在回归分析之前先对预测变量的度量单位进行标准化。标准化类似于统一使用百分位数来表示每个变量。经过标准化之后，预测变量的系数被称为**标准化回归系数**，可以用来做更准确的比较。

在预测房价的例子中，两个预测变量（房间数和周围低收入居民所占比例）都经过了标准化，权重比为 2.7 : 6.3。这意味着在预测房价时，周围低收入居民所占比例比房间数起更大的作用。回归方程如下所示。

$$\text{房价} = 2.7(\text{房间数}) - 6.3(\text{低收入居民所占比例})$$

请注意，在这个方程中，低收入居民所占比例的权重前面有一个负号，这表示权重为负。这是因为该预测变量和房价是负相关关系，这一点可以从图 6-2 中向下倾斜的趋势线看出来。

6.5 相关系数

当只存在一个预测变量时，该预测变量的**标准化回归系数**也被称为**相关系数**，记作 r ，如图 6-6 所示。相关系数的取值范围为 -1 到 1，它提供了两部分信息。

教材图像说明

教材图像展示了损失函数曲线和参数更新方向。

梯度下降的思想是沿着使误差减小最快的方向逐步调整参数。

学习率过大可能越过最优点，过小则收敛速度慢。

我的理解

b_0 、 b_1 不是凭空得到，而是通过优化过程估计出来。

理解梯度下降有助于明白“训练模型”具体在做什么。

这也解释了为什么数据规模、变量尺度会影响模型训练。

学习小结

线性回归解决连续值预测，Logistic 回归解决分类概率预测。

回归建模的重点是变量选择、参数估计和结果评价。

一元线性回归适理解单一变量关系，多元线性回归适合处理多因素影响，Logistic 回归适合把概率转换为类别判断。

模型不是越复杂越好，能解释、能泛化、能用于决策才有意义。

本次作业的关键是把数学模型、代码运行结果和评价指标联系起来，而不是只列公式。