

数据挖掘与机器学习第三次作业

南京工业大学

张新通 | 202321054027

分类定义

什么是分类 (Classification)?

对现有的数据进行学习，得到一个**目标函数或模型（分类器）**。

该模型能把**未知类别**的样本映射到给定的类别中。

注意：分类是一种**预测**，不是肯定。

不能期待准确率达到 100%，但总是致力于筛选出准确率最高的模型。

154 ❖ 第二篇 技术篇

类。尽管这些未来的测试数据的类标签是未知的，我们仍可以由此预测这些新数据所属的类。注意是预测，而不能肯定，因为分类的准确率不能达到百分之百。我们也可以由此对数据中的每一个类有更好的理解。也就是说：我们获得了对这个类的知识。

所以分类 (Classification) 也可以定义为：

对现有的数据进行学习，得到一个目标函数或规则，把每个属性集 x 映射到一个预先定义的类标号 y 。

目标函数或规则也称分类模型 (Classification Model)，分类模型有两个主要作用：一是描述性建模，即作为解释性的工具，用于区分不同类中的对象；二是预测性建模，即用于预测未知记录的类标号。

但是总能筛选出准确率最高的模型

图：作业笔记关于分类定义的原文截图

基本概念



分类器

能够解释原始数据，能够预测新数据的模型。



训练集

用来训练模型的原始数据（划分出的一部分）。



测试集

用来测试模型的原始数据（划分出的一部分）。




类标签

原始数据中已经给每个记录（对象）标记的类别。



开放集

使用训练好的模型（分类器）进行分类工作的新数据。



k-NN 方法



k-NN 算法步骤

- 1 初始化距离
设定最大值作为初始距离
- 2 计算与更新 (遍历)
计算距离 dist
比较并更新 K 个最近邻
- 5 遍历结束
完成所有训练样本的计算
- 6 统计频次
统计 K 近邻中各类别次数
- 7 输出预测
选择频率最高的类别


算法步骤

图 8-4 一个实例的 1-最近邻、2-最近邻和 3-最近邻

KNN 算法具体步骤如下：


- 步骤 1：初始化距离为最大值。
- 步骤 2：计算未知样本和每个训练样本的距离 dist。
- 步骤 3：得到目前 K 个最近邻样本中的最大距离 maxdist。
- 步骤 4：如果 dist 小于 maxdist，则将该训练样本作为 K-最近邻样本。
- 步骤 5：重复步骤 2~步骤 4，直到未知样本和所有训练样本的距离都算完。
- 步骤 6：统计 K 个最近邻样本中每个类别出现的次数。
- 步骤 7：选择出现频率最大的类别作为未知样本的类别

根据 KNN 算法的原理和步骤可以看出，KNN 算法对 K 值的依赖较高，所以 K 值的选择非常重要。如果 K 太小，预测目标容



KNN 算法步骤

Undo



评价指标

混淆矩阵 (Confusion Matrix)

	预测 Positive	预测 Negative
实际 Positive	TP	FN
实际 Negative	FP	TN

Accuracy (准确率)

$(TP + TN) / All$

Precision (精确率)

$TP / (TP + FP)$ 预测为正中正确的比例

Recall (召回率)

$TP / (TP + FN)$ 实际为正中被找出的比例

1

0

0

1

1

1

0

1

1

1

Accuracy = $\frac{1}{2}$

Precision = $\frac{1}{2}$

Recall = $\frac{1}{2}$

第8章 分类方法

❖

159

算法→评估

测试标签

预测标签

y

0

0

1

1

1

0

1

1

0

bulate(Ytest)

节程序执行结果如下:

数据集:

lue	Count	Percent
528	88.00%	
s	72	12.00%

试集:

lue	Count	Percent
360	90.00%	
s	40	10.00%

4) 训练 KNN 分类器

《白话机器学习》第七章读书笔记

k 最近邻 (k-NN) 算法，结合葡萄酒分类案例拆解核心知识点

核心原理上，k-NN 算法依据数据点周围 k 个邻居的类别进行分类，遵循少数服从多数原则；k 值选择是关键，过小易受噪声干扰，过大则忽略数据隐藏模式，需用交叉验证调优，二分类中取奇数避免平局。该算法不仅可用于分类，还能通过加权平均预测连续值，提升预测精度。

局限性与优化方向上，算法在类别不平衡时小类别易被掩盖，可采用加权投票法优化；多预测变量会增加计算量，需借助降维技巧筛选关键变量。整体而言，k-NN 算法简单易用，在低维、类别均衡的数据场景中表现优异。

最近邻算法


Pros

- 简单易懂
- 实用性强
- 异常检测

Cons

- 类别不平衡
- 预测变量过多
- 计算成本高

提高 k 最近邻算法的准确性



《白话机器学习》第七章读书笔记

应用场景方面，葡萄酒检测案例中，利用氯化物、二氧化硫等化学成分，k-NN 算法以超 98% 准确率区分红白葡萄酒，直观体现其效果；同时可用于异常检测，分类错误的异常点能帮助发现缺失变量、优化模型，移除异常数据还能减少噪声、提升模型准确度。




图 7-3 白葡萄酒（黑点）和红葡萄酒（红点）中氯化物和二氧化硫的含量

因为葡萄皮中的矿物质（比如氯化钠，与食盐成分一样）含量较高，所以红葡萄酒中这些成分的含量就相对较高，图中很好地反映出了这一点。葡萄皮还含有天然抗氧化剂，用来使葡萄保持新鲜。白葡萄酒不包含这种成分，所以需要使用更多的二氧化硫来充当防腐剂。正是这些原因使得红葡萄酒大都集中在图中的右下部分，白葡萄酒则主要集中在左上部分。





图 7-2 使用不同的 k 值进行拟合。黑色区域中的点被预测为白葡萄酒，红色区域中的点则被预测为红葡萄酒

如果 k 值太小，数据点只与最近的“邻居”匹配，并且随机噪声所产生的误差也会被放大，如图 7-2a 所示。如果 k 值太大，数据点会尝试与更远的“邻居”匹配，其中隐含的模式会被忽略，如图 7-2c 所示。

只有当 k 值恰到好处时，数据点才会参考合适数量的“邻居”，这使得误差相互抵消，有利于揭示数据中隐藏的趋势，如图 7-2b 所示。


《白话机器学习》第九章读书笔记

决策树的核心逻辑是通过一系列二元判定问题（仅含“是”“否”两个分支）实现预测，以根节点为起点，沿分支节点逐步迭代，最终抵达叶节点输出预测结果。该算法可适配分类任务（如性别区分）与连续值预测任务，其中连续值任务可通过离散化处理（如划分“高于平均值”“低于平均值”）转化为分类任务。在泰坦尼克号乘客生还预测案例中，决策树模型显示，男孩或女性乘客若不处于三等舱，其生还概率显著提升，直观验证了该算法的实践价值。



《白话机器学习》第九章读书笔记

决策树的挑战



决策树的生成核心是递归拆分过程：通过构建最优二元判定规则拆分数数据集，最大化各子数据集的同质性（即类内相似度），该过程可重复迭代，直至满足预设终止条件（包括叶节点内数据属于同一类别、叶节点样本量低于5个、进一步分支无法提升数据集同质性且超出预设阈值等）。决策树的核心优势的在于可解释性强、可视化程度高，对异常值具有较强的抗干扰能力，且不显著特征变量不会对预测结果产生影响。

决策树存在明显局限性，主要表现为模型稳定性差（数据集微小波动会导致决策树结构发生显著变化）、易出现过拟合现象、预测精度存在局限。针对上述问题，可通过决策树多样化策略进行改进，主流方法包括随机森林与梯度提升：随机森林通过随机选取判定规则生成多棵决策树，综合所有树的预测结果提升稳定性；梯度提升通过有策略地选取判定规则，逐步优化模型精度，最终以各预测结果的加权平均值作为最终输出。但此类改进方法结构复杂，难以实现可视化，属于“黑盒模型”。整体而言，决策树因具备较强的可解释性与可视化优势，仍是机器学习领域中应用广泛的基础分析工具。