

数据挖掘与机器学习第四次作业

南京工业大学张新通 | 202321054027

课后作业要求

1. 整理簇的概念。
2. 整理类度量的两种基本方法：欧式距离、余弦距离。
3. 整理 K-means 算法的原理和步骤。
4. 整理 HC 算法的过程。
5. 掌握 PPT 第26页 HC 聚类结果图。
6. 阅读《白话机器学习》K-means 章，整理读书笔记。

簇的概念

簇内相似

簇间差异

无监督

簇是由相似对象组成的集合。

同一簇内的数据对象应尽可能相似，不同簇之间应尽可能不同。

聚类属于无监督学习，事先没有给定类别标签。

因此聚类结果不是“标准答案”，而是根据相似性度量得到的一种结构解释。

类度量：欧式距离

$$d(x,y)=\text{sqrt}((x_1-y_1)^2 + \dots + (x_n-y_n)^2)$$

欧式距离衡量两个样本在空间中的直线距离，是聚类中最常用的距离之一。

距离越小，样本越相似；距离越大，样本差异越明显。

不同变量量纲不一致时，应先进行标准化或归一化，否则量纲大的变量会主导距离。

欧式距离适合数值型、连续型特征，例如花萼长度、收入、消费次数等。

类度量：余弦距离

$$\cos(\theta) = (x \cdot y) / (||x|| ||y||)$$

余弦相似度关注向量方向是否一致，而不是绝对大小。

适合文本、偏好、行为模式等高维稀疏数据。

相似度越接近 1，两个对象方向越接近；越接近 0，方向差异越大。

与欧式距离相比，余弦度量更强调结构比例，例如两个用户购买总量不同但偏好结构相似。

K-means 算法思想

K-means 先指定 K 个簇，然后不断调整簇中心。

每个样本被分配给距离最近的中心点。

更新中心点后再次分配，直到结果基本稳定。

算法目标是让簇内距离尽量小、簇间差异尽量明显。

它适合较规则、近似球形的簇；如果数据形状复杂或异常值很多，结果可能不稳定。

教材截图标注：K-means 原理

标注重点

教材本页对应 K-means 的原理和步骤。

作业中应突出：先定 K、再分配样本、再更新中心、循环直到稳定。

K 值和初始中心都会影响聚类结果，因此实际使用中常需要多次运行或比较不同 K 值。

从作业角度看，不能只写“运行算法”，还要解释每一步为什么会改变簇中心和样本归属。

J p192

9.2 K-means 方法

K-均值聚类算法是著名的划分聚类分割方法。划分方法的基本思想是：给定一个有 N 个元组或者记录的数据集，分裂法将构造 K 个分组，每一个分组就代表一个聚类， $K < N$ 。而且这 K 个分组满足下列条件：①每一个分组至少包含一个数据记录；②每一个数据记录属于且仅属于一个分组；对于给定的 K ，算法首先给出一个初始的分组方法，以后通过反复迭代的方法改变分组，使得每一次改进之后的分组方案都较前一次好，而所谓好的标准就是：同一分组中的记录越近越好（已经收敛，反复迭代至组内数据几乎无差异），而不同分组中的记录越远越好。

9.2.1 K-means 原理和步骤

K-means 算法的工作原理：首先随机从数据集中选取 K 个点，每个点初始地代表每个簇的聚类中心，然后计算剩余各个样本到聚类中心的距离，将它赋给最近的簇，接着重新计算每一簇的平均值，整个过程不断重复，如果相邻两次调整没有明显变化，说明数据聚类形成的簇已经收敛。本算法的一个特点是在每次迭代中都要考察每个样本的分类是否正确。若不正确，就要调整，在全部样本调整完后，再修改聚类中心，进入下一次迭代。这个过程将不断重复直到满足某个终止条件，终止条件可以是以下任何一个：

- 1) 没有对象被重新分配给不同的聚类。
- 2) 聚类中心不再发生变化。
- 3) 误差平方和局部最小。

算法步骤：

- 1) 从 n 个数据对象中任意选择 k 个对象作为初始聚类中心；
- 2) 循环 3) 到 4) 直到每个聚类不再发生变化为止；
- 3) 根据每个聚类对象的均值（中心对象），计算每个对象与这些中心对象的距离；并根据最小距离重新对相应对象进行划分；
- 4) 重新计算每个聚类的均值（中心对象），直到聚类中心不再变化。这种划分使得下式最小：

$$E = \sum_{j=1}^k \sum_{x_i \in m_j} \|x_i - m_j\|^2$$

K-means 算法是很典型的基于距离的聚类算法，采用距离作为相似性的评价指标，即认为两个对象的距离越近，其相似性就越大。该算法认为簇是由距离靠近的对象组成，因此把得到紧凑且独立的簇作为最终目标。

K-means 算法：

输入：聚类个数 k ，以及包含 n 个数据对象的数据库。

输出：满足方差最小标准的 k 个聚类。


K-means 算法步骤



K 值不同会得到不同聚类结果。

初始中心可能影响最终结果，因此实际应用中常多次运行比较。

HC 层次聚类过程



HC 不一定需要预先指定类别数，可以通过树状图选择切分层级。
数据量较大时，层次聚类计算成本较高。

教材截图标注：HC 算法

标注重点

本页对应 HC 层次聚类过程。
重点是理解“逐步合并”和“树状图”的关系：从单个样本开始，把距离最近的类逐层合并。
树状图不是装饰图，而是确定聚类层级的重要依据。
与 K-means 相比，HC 更适合展示层次结构，但计算复杂度较高，通常更适合较小数据集。

J p198

9.2.4 K-means 特点

1) 在 K-means 算法中 K 是事先给定的，这个 K 值的选定是非常难以估计的。

2) 在 K-means 算法中，首先需要根据初始聚类中心来确定一个初始划分，然后对初始划分进行优化。

3) K-means 算法需要不断地进行样本分类调整，不断地计算调整后的新的聚类中心，因此当数据量非常大时，算法的时间开销是非常大的。

4) K-means 算法对一些离散点和初始 K 值敏感，不同的距离初始值对同样的数据样本可能得到不同的结果。

9.3 层次聚类

9.3.1 层次聚类原理和步骤

层次聚类算法，是通过将数据组织为若干组并形成一棵树来进行聚类的。根据层次是自底向上还是自顶向下形成，层次聚类算法可以进一步分为凝聚的聚类算法和分裂的聚类算法，如图 9-7 所示。一个完全层次聚类的质量由于无法对已经做的合并或分解进行调整而受到影响。但是层次聚类算法没有使用准则函数，它所含的对数据结构的假设更少，所以它的通用性更强。

在实际应用中一般有两种层次聚类方法：

1) 凝聚的层次聚类：这种自底向上的策略首先将每个对象作为一个簇，然后合并这些原子簇为越来越大的簇，直到所有的对象都在一个簇中，或者某个终结条件被达到要求。大部分的层次聚类方法都属于一类，它们在簇间的相似度的定义有点不一样。

2) 分裂的层次聚类：像这样的自顶向下的策略与凝聚的层次聚类有些不一样，它首先将所有对象放在一个簇中，然后慢慢地细分为越来越小的簇，直到每个对象自行形成一簇，或者直到满足其他的一个终结条件，例如满足了某个期望的簇数目，又或者两个最近的簇之间的距离达到了某一个阈值。

图 9-7 描述了一个凝聚的层次聚类方法 AGENES 和一个分裂的层次聚类方法 DIANA 在一个包括五个对象的数据的集合 {a,b,c,d,e} 上的处理过程。初始时，AGENES 将每个样本点自为一簇，之后这样的簇依照某一种准则逐渐合并，例如，例如簇 C1 中的某个样本点和簇 C2 中的一个样本点相隔的距离是所有不同类簇的样本点间欧几里得距离最近的，则认为簇 C1

图 9-7 凝聚的层次聚类和分裂的层次聚类处理过程


南京工业大学 | 张新通 | 202321054027

参考教材1: J p198

HC 聚类结果图怎么看

PPT 第26页

第四张图 (图9-10) (重点, 这个是需要掌握的)



图怎么看? (重点)

图9-10, 就是左图, 一定要会看了, 这个是HC聚类经常会用到的图。这个图怎么看, 关键就是怎么通过这个图确定类别, 就是我在左图中添加的红色线, 当这个线从上往下平移, 它与多少垂直线相交, 就分成了几个类。左边的就是本例的3类。

另外, 我跑出来的结果与教材有差别, 这不是错误, 没有关系。

还有一点很重要, 这个图是函数dendrogram (Ip200) 画出来的, 这个函数默认是最底下画30个节点, 这样出来的图就比较清晰了, 不会太拥挤。

图像说明

这张图是 HC 层次聚类常用的树状图, 由 dendrogram 函数画出。

纵轴表示样本或类合并时的距离, 高度越高, 说明被合并对象差异越大。

图中的红色虚线是一条水平切分线, 它与多少条垂直分支相交, 就可以理解为分成多少类。

截图中红线与 3 条垂直线相交, 所以左图解释为聚成 3 类。

作业回答

如果要聚成 5 类, 应把水平线继续向下平移, 直到它与 5 条垂直分支相交。

线画得越高, 类别越少; 线画得越低, 类别越多。

程序结果与教材略有差异不算错误, 关键是掌握树状图的读法。

《白话机器学习》K-means 读书笔记

教材3 p18



图 3-6 使用两个主成分绘图

对于图中以蓝色表示的肉来说，主成分 1 的值较小，所以它们集中分布在左侧，而以橙色表示的蔬菜则集中分布在右侧。还可以看到，海产品（深蓝色）的脂肪含量较低，即主成分 2 的值较小，因而主要分布在图的左下角。同理，几种非叶类蔬菜（深橙色）的维生素 C 含量较低，所以大部分分布在图的右下角。

确定主成分数量

本例有 4 个主成分，这与数据集的原始变量个数一致。由于主成分来源于原始变量，因此用来区分数据点的可用信息会受到原始变量个数的制约。

然而，为了让结果更简单、更通用，应该只选择前几个主成分来进行可视化和后续分析。主成分按照其对数据点的区分效果进行排列，第 1 个主成分的区分效果最好。可以利用第 2 章讲过的陡坡图来确定合适的主成分数量。

从图 3-7 可以看出，随着个数增多，主成分区分数据点的效果会变差。根据经验，陡坡图曲线的拐弯处往往体现了最佳主成分数量。

教材图像说明

教材中的散点图展示了样本被分成不同群组的直观效果。

K-means 的结果依赖距离度量：离哪个中心更近，就被划到哪个簇。

图中颜色不是原始标签，而是算法根据相似性计算出的分组。

我的理解

聚类的重点不是“命名类别”，而是发现数据内部结构。

分好类以后，还要结合业务背景解释每一簇代表什么。

例如顾客分群时，需要把簇转化为高价值、价格敏感等可理解标签。

K 值选择与肘部法




图 3-7 陡坡图曲线在主成分 2 处拐弯，这表示最佳主成分数量为 2
在图中，曲线在主成分 2 处拐弯。这意味着，尽管用更多的主成分可以更好地分散数据点，但是复杂度会升高，因此并不值得这样做。从陡坡图中可以看到，前两个主成分已经可以让数据的散度达到约 70%。在对当前的数据样本进行解释时，使用的主成分越少，泛化能力就越强。

3.4 局限性

在分析包含许多变量的数据集时，主成分分析很有用。但是，它本身存在一些缺点。

- **散度最大化**：主成分分析有个重要假设，即数据点最分散的维度是最有用的。然而，这个假设并不一定正确。一个常见的反例是计算薄饼的个数，如图 3-8 所示。在计算时，需要沿着垂直方向（即堆叠高度）把一张薄饼与另一张区分开。然而，如果堆叠高度比较低，主成分分析就会错误地认为水平方向（即薄饼直径）是完成这项任务的最好主成分，这是因为水平方向上的散度是最大的。




图 3-8 与数薄饼进行类比

- **解释成分**：主成分分析算法面临的一个重大难题是，必须对其产生的成分进行解释。但有时，可能很难解释变量按某种方式进行组合的原因。尽管如此，掌握相关领域的知识仍然很有用。在前面的例子中，了解有关食物种类的知识有助于理解主成分为何由那些营养成分变量组成。
- **正交成分**：主成分分析算法总是生成正交主成分，即成分之间存在正交关系。然而，这个假设可能不正确，因为信息维度之间可能不存在正交关系。为了解决这个问题，可以使用另一项技术，即**独立成分分析**。独立成分分析不需要其成分之间存在正交关系，但是禁止它们所包含的信息发生重叠（如图 3-9 所示）。这使得每个独立成分所揭示的与数据集有关的信息都是唯一的。除了不需要假设正交关系，独立成分分析在确定成分时还无须考虑数据的散度，因而不易出现薄饼例子中的错误。

教材图像说明

教材图像用曲线展示聚类数量增加后误差下降的趋势。
当 K 增大时，簇内距离通常会变小，但类别过多会降低解释性。
曲线出现明显转折的位置，可以作为选择 K 的参考。

我的理解

K 不是越大越好。
好的 K 值要兼顾数学指标和实际解释。
这和作业中改变 K 后观察聚类结果的要求是一致的。

学习小结

聚类的关键是“相似性度量”和“分组解释”。

欧式距离强调空间距离，余弦距离强调方向结构，应根据数据类型选择。

K-means 适合快速划分，HC 适合观察层次结构。

聚类没有标准答案，结果好不好要结合数据特征和应用目标判断。

本次作业中，K 值变化、树状图切分和聚类中心解释都属于“结果解释”，不能只停留在程序输出层面。