

数据挖掘与机器学习第五次作业

南京工业大学张新通 | 202321054027

课后作业要求

1. 整理有关关联选股的背景知识。
2. 分析数据，清楚说明矩阵行与列的含义。
4. 分析结果，思考教材分析过程的含义，并指出教材中的错误。

关联规则的基本思想

$X \Rightarrow Y$

共现

筛选规则

业务解释

关联规则用于发现项目之间经常同时出现的关系。

典型形式为 $X \Rightarrow Y$ ，表示出现 X 时也倾向于出现 Y 。

在商业中常用于购物篮分析，在金融中可用于发现行业或股票之间的联动关系。

对行业关联选股而言，规则不是直接给出买卖结论，而是提供“哪些行业经常一起变化”的分析线索。

教材截图标注：Apriori 算法

标注重点

作业要求是“行业关联选股法”，核心算法是 Apriori。先把行业或股票表现转成事务矩阵，再寻找频繁共现组合。

Apriori 的关键不是暴力枚举所有组合，而是利用“频繁项集的子集也频繁”的思想进行剪枝。

截图页用于标注教材依据，正文页负责解释算法如何服务于行业联动分析。

Apriori

2) 基于规则中数据的抽象层次，可以分为单层关联规则和多层关联规则。

在单层的关联规则中，所有的变量都没有考虑到现实的数据是具有多个不同的层次的；而在多层的关联规则中，对数据的多层性已经进行了充分的考虑。例如：IBM 台式机 $\Rightarrow$ Sony 打印机，是一个细节数据上的单层关联规则；台式机 $\Rightarrow$ Sony 打印机，是一个较高层次和细节层次之间的多层关联规则。

3) 基于规则中涉及的数据的维数，关联规则可以分为单维的和多维的。

在单维的关联规则中，我们只涉及数据的一个维，如用户购买的物品；而在多维的关联规则中，要处理的数据将会涉及多个维。换句话说，单维关联规则是处理单个属性中的一些关系；多维关联规则是处理各个属性之间的某些关系。例如：啤酒 $\Rightarrow$ 尿布，这条规则只涉及用户购买的物品；性别=“女” $\Rightarrow$ 职业=“秘书”，这条规则就涉及两个字段的的信息，是两个维上的一条关联规则。

6.1.4 关联规则挖掘常用算法

关联规则挖掘算法是关联规则挖掘研究的主要内容，迄今为止已提出了许多高效的关联规则挖掘算法。最著名的关联规则发现方法是 R. Agrawal 提出的 Apriori 算法。Apriori 算法主要包含两个步骤：第一步是找出事务数据库中所有大于等于用户指定的最小支持度的数据项集；第二步是利用频繁项集生成所需要的关联规则，根据用户设定的最小置信度进行取舍，最后得到强关联规则。识别或发现所有频繁项目集是关联规则发现算法的核心。

关联规则挖掘另一个比较著名的算法是 J. Han 等提出的 FP-tree。该方法采用分而治之的策略，在经过第一遍扫描之后，把数据库中的频集压缩进一棵频繁模式树（FP-tree），同时依然保留其中的关联信息，随后再将 FP-tree 分化成一些条件库，每个库和一个长度为 1 的频集相关，然后再对这些条件库分别进行挖掘。当原始数据量很大时，也可以结合划分的方法，使得一个 FP-tree 可以放入主存中。实验表明，FP-Growth 对不同长度的规则都有很好的适应性，同时在效率上较之 Apriori 算法有巨大的提高。

在下面的章节中将重点介绍这两个算法。

6.2 Apriori 算法

6.2.1 Apriori 算法基本思想

关联规则的挖掘分为两步：①找出所有频繁项集；②由频繁项集产生强关联规则。而其总体性能由第一步决定。在搜索频繁项集时，最简单、基本的算法就是 Apriori 算法。算法的名字基于这样一个事实：算法使用频繁项集性质的先验知识。Apriori 使用一种被称作逐层搜索的迭代方法， k 项集用于探索 $(k+1)$ 项集。首先，通过扫描数据库，累积每个项的计数，并收集满足最小支持度的项，找出频繁 1 项集的集合。该集合记作 L_1 。然后， L_1 用于找频

支持度、置信度和提升度

支持度

规则涉及项目在全部分事务中共同出现的比例。

回答：这个组合常不常见？

在选股中可理解为某些行业共同满足条件的频率。

置信度

在 X 出现时 Y 也出现的条件概率。

回答：X 对 Y 的预测强不强？

置信度高不代表因果，只代表条件共现更明显。

提升度

规则相对随机共现的提升程度。

大于 1 通常说明存在正向关联。

它能帮助排除单纯由高频项目造成的假强规则。

Apriori 算法流程



Apriori 原理：如果一个项集是频繁的，它的所有非空子集也应是频繁的。
利用这一点可以减少候选组合数量，提高计算效率。

行业关联选股法背景

股市中不同行业并非完全独立，政策、周期、产业链和资金偏好会造成板块联动。关联选股不是直接预测涨跌，而是寻找行业或股票之间的共同变化模式。当某些行业频繁共同上涨或共同表现异常时，可作为组合观察和投资分析线索。

参考网站与背景归纳

筛选标准

行业逻辑

公司分析

数据补充

知乎问题 28778713：从大量股票中筛选目标，需要先建立选择标准，而不是随机挑选。
雪球文章 82720628：行业深度分析强调基本面逻辑，说明行业选择具有现实意义。
搜狐文章 198291969_611347：选股先看行业，再看公司，体现行业层面分析的重要性。
因此，行业关联选股法可以作为“行业之间联动关系”的数据化补充。

矩阵行、列和元素的含义

对象	含义	示例
行	交易日或观察样本	某一天
列	行业或股票	银行、证券、地产
元素	是否满足条件	上涨=1，否则=0
规则	行业间关联	证券 => 银行

矩阵把连续市场表现转化为 0/1 事务数据，便于 Apriori 算法处理。
行表示一次观察，列表示一个可参与关联分析的项目，元素表示该项目是否在该观察中出现。
如果阈值设置不同，矩阵也会变化，因此结果分析必须说明数据转化规则。

《白话机器学习》关联规则读书笔记

教材3 p21

	   
交易 2	  
交易 3	 
交易 4	 
交易 5	   
交易 6	  
交易 7	 
交易 8	 

置信度 表示当 X 项出现时 Y 项同时出现的频率，记作 $(X \rightarrow Y)$ 。换言之，置信度指同时包含 X 项和 Y 项的交易数与包含 X 项的交易数之比（如图 4-2 所示）。在表 4-1 中，{ 苹果 $\rightarrow$ 啤酒 } 的置信度为 3/4，即 75%。

$$\text{置信度} \{ \text{苹果} \rightarrow \text{啤酒} \} = \frac{\text{支持度} \{ \text{苹果}, \text{啤酒} \}}{\text{支持度} \{ \text{苹果} \}}$$

图 4-2 置信度指标

这个指标有一个缺点，那就是它可能会错估某个关联规则的重要性。图 4-2 中的例子只考虑了苹果的购买频率，而并未考虑啤酒的购买频率。如果啤酒也很受欢迎（正如表 4-1 所示），那么包含苹果的交易显然很有可能也包含啤酒，这会抬高置信度指标。然而，借助第 3 个指标，我们可以同时把苹果和啤酒出现的基础频率考虑在内。

提升度 指 X 项和 Y 项一同出现的频率，但同时要考虑这两项各自出现的频率（如图 4-3 所示）。

因此，{ 苹果 $\rightarrow$ 啤酒 } 的提升度等于 { 苹果 $\rightarrow$ 啤酒 } 的置信度除以 { 啤酒 } 的支持度。

$$\text{提升度} \{ \text{苹果} \rightarrow \text{啤酒} \} = \frac{\text{支持度} \{ \text{苹果}, \text{啤酒} \}}{\text{支持度} \{ \text{苹果} \} \times \text{支持度} \{ \text{啤酒} \}}$$

图 4-3 提升度指标

根据表 4-1，{ 苹果 $\rightarrow$ 啤酒 } 的提升度等于 1，这表示苹果和啤酒无关联。 $(X \rightarrow Y)$ 的提升度大于 1，这表示如果顾客购买了商品 X，那么可能会购买商品 Y；而提升度小于 1 则表示如果顾客购买了商品 X，那么不太可能再购买商品 Y。

4.3 示例：分析杂货店的销售数据

为了演示上述指标的用法，下面将对某个杂货店一个月（30 天）的销售数据进行分析。图 4-4 展示了多对杂货之间的关联关系，它们的置信度和提升度分别大于 0.9% 和 2.3。圆越大，支持度越高；颜色越红，则提升度越高。

教材图像说明

教材用购物篮案例说明：一张交易记录可以看成是一个事务，商品就是事务中的项目。

图中不同顾客购买的水果组合，对应关联规则中的“项集”。

关联规则从大量事务中寻找经常一起出现的项目组合。

这个思路迁移到行业选股时，交易日可看作事务，行业上涨或满足条件可看作项目。

我的理解

关联规则强调“共现”，不是因果。

支持度保证规则有足够样本基础。

置信度和提升度用于判断规则是否有分析价值。

结果分析要点

频率

条件概率

相对提升

行业解释

高支持度说明组合出现频繁，但不一定代表有投资价值。

高置信度说明前件出现时后件更可能出现，但要警惕样本偏差。

提升度大于 1 说明存在强于随机的正向关联。

最终解释必须结合行业基本面、产业链关系和市场环境。

如果规则只在少数极端行情中出现，实际参考价值会下降。

教材分析中的可能问题

如果只根据关联强度选股，容易忽略时间先后关系和因果关系。
关联规则发现的是共现模式，不等于“某行业上涨必然导致另一行业上涨”。
若没有说明阈值、样本区间和数据处理方式，结果可重复性不足。
如果教材把高置信度直接解释为投资确定性，就容易夸大关联规则的作用。
投资分析中还需要结合风险、流动性、估值和基本面因素。
因此，教材案例的合理用法应是辅助发现行业联动线索，而不是直接替代选股决策。