

数据挖掘与机器学习第七次作业

南京工业大学张新通 | 202321054027

课后作业要求

1. 观察 50_Startups 数据集特征，说明属性数量与分类变量。
2. 可视化分类变量（城市）和因变量 Profit-Y 之间的关系。
3. 总结分类变量转化为 one-hot 的过程，并写出示例代码。
4. 用 R^2 评估模型效果，获得系数和截距并写出数学公式。
5. 分析分类变量对多元线性回归的影响，判断 label 编码是否合理。

观察数据集的特征，有几个属性？


数值变量

分类变量

因变量

- 数据集共有 5 列：4 个自变量属性 + 1 个目标变量。
- 数值属性：R&D Spend-X1、Administration-X2、Marketing Spend-X3。
- 分类属性：State-X4，取值为 New York、California、Florida。
- 因变量：Profit-Y，用来表示公司利润/营收结果。




```
dataset = pd.read_csv('50_Startups.csv')
print(dataset.shape)
print(dataset.columns)
print(dataset['State-X4'].value_counts())
```



The screenshot shows a Jupyter Notebook interface. The top part displays the code used to load the dataset: `dataset = pd.read_csv('50_Startups.csv')` and `dataset.head()`. Below the code, the output shows the first five rows of the dataset. The columns are labeled: R&D Spend-X1, Administration-X2, Marketing Spend-X3, State-X4, and Profit-Y. The rows are indexed from 0 to 4. The State-X4 column contains the values 'New York', 'California', 'Florida', 'New York', and 'Florida' respectively.

	R&D Spend-X1	Administration-X2	Marketing Spend-X3	State-X4	Profit-Y
0	165349.20	136897.80	471784.10	New York	192261.83
1	162597.70	151377.59	443898.53	California	191792.06
2	153441.51	101145.55	407934.54	Florida	191050.39
3	144372.41	118671.85	383199.62	New York	182901.99
4	142107.34	91391.77	366168.42	Florida	166187.94

如何可视化城市和 Profit-Y 的关系？



- 箱线图能观察每个城市利润分布、离散程度和异常值；柱状图能比较平均利润。
- 本数据中 Florida 平均 Profit-Y 最高，California 较低，但城市差异还需要结合投入变量一起解释。

如何把分类变量转化为 one-hot?

读取 State-X4



Label / OneHot



合并数值变量



进入回归模型

```
from sklearn.compose import ColumnTransformer
from sklearn.preprocessing import OneHotEncoder

ct = ColumnTransformer(
    transformers=[('encoder', OneHotEncoder(), [3])],
    remainder='passthrough')
X = np.array(ct.fit_transform(X))
```

- one-hot 会把 New York / California / Florida 转为多个 0/1 虚拟变量。
- 建模时通常删除其中一列作为基准组，避免虚拟变量陷阱。

如何完成模型训练与预测？


```
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression

X_train, X_test, Y_train, Y_test = train_test_split(
    X, Y, test_size=0.2, random_state=0)

regressor = LinearRegression()
regressor.fit(X_train, Y_train)
y_pred = regressor.predict(X_test)
```



项目	结果
测试集比例	20%
random_state	0
预测值示例	103901.90
模型类型	LinearRegression



```
y_pred = regressor.predict(X_test)

print(y_pred)
```

```
[103901.8969696  132763.05993126 133567.90370044  72911.78976736
 179627.92567224 115166.64864795  67113.5769057   98154.80686776
 114756.11555221 169064.01408795]
```

- 训练集用于估计参数，测试集用于观察泛化表现。
- 预测值 `y_pred` 与真实值 `Y_test` 对比，可以进一步计算误差或 R^2 。

如何用 R^2 评估结果?

$$R^2 = 1 - SSE / SST$$

评价指标	运行结果
全数据 R^2	0.949088
测试集 R^2	0.939396

- R^2 越接近 1, 说明模型对因变量变化的解释能力越强。
- 本次模型测试集 R^2 约为 0.939, 说明拟合效果较好。
- 评估时不能只看训练效果, 还要关注测试集表现和残差规律。

第4步 评估系数 R^2

```
R2 = regressor.score(X,Y)
R2
1) ✓ 0.0s Python
0.9490884301964866

bi = regressor.coef_ # 系数(权重)
bi
2) ✓ 0.0s Python
array([0.77884104, 0.0293919 , 0.03471025])
```

如何获得系数、截距和数学公式？

```
bi = regressor.coef_  
b0 = regressor.intercept_  
print(bi, b0)
```

参数	数值	含义
b0	42989.008	截距
b1	0.778841	R&D 权重
b2	0.029392	Administration 权重
b3	0.034710	Marketing 权重

$$\text{Profit} = 42989.008 + 0.778841X1 + 0.029392X2 + 0.034710X3$$

- R&D Spend-X1 的系数最大，说明研发投入对 Profit-Y 的预测贡献最明显。
- 系数解释应建立在“其他变量不变”的前提下。

分类变量对多元线性回归有什么影响？

特征	保留城市虚拟变量模型
R&D Spend-X1	0.773467
Administration-X2	0.032885
Marketing Spend-X3	0.036610
State-X4_Florida	-959.284160
State-X4_New York	699.369053

- 以 California 为基准组，Florida 和 New York 用虚拟变量表示。
- 计算不同城市 Profit 时，只需要把对应城市虚拟变量设为 1，其余设为 0。
- 当前 notebook 的 $X = X[:,3:6]$ 删除了城市 one-hot 列，原模型只用了三个数值变量。

$$\text{Profit} = 42554.168 + 0.773467X1 + 0.032885X2 + 0.036610X3 - 959.284F + 699.369N$$

能否把分类变量直接 label 化?

编码方式	含义	是否适合本案例
Label 编码	California=0, Florida=1, New York=2	不适合
One-hot 编码	每个城市用 0/1 单独表示	适合

- 城市名称没有大小顺序，直接变成 0、1、2 会让模型误以为城市之间有数值距离。
- one-hot 编码不会引入虚假的顺序关系，更符合分类变量的含义。
- 只有“低、中、高”这类天然有序分类变量，才适合考虑有序编码。

结论：本案例应使用 one-hot，而不是直接 label 化。