

# 数据挖掘与机器学习第八次作业

南京工业大学张新通 | 202321054027

# 课后作业要求

1. Logistic 回归案例：加入分类变量 Gender，观察对结果的影响。
2. KNN 案例：加入性别因素并进行 one-hot 编码，比较准确率是否变化。
3. 比较 KNN 与 Logistic 在同一数据案例上的结果差异。
4. 观察训练集比例、超参数 K 对模型效果的影响，并说明过拟合。
5. 修改二维可视化图，在 Age / EstimatedSalary 图中体现 Gender。

# 本案例数据有什么特征？

样本数量 400

标签 Purchased

分类变量 Gender

| 项目          | 统计结果  |
|-------------|-------|
| Purchased=0 | 257 条 |
| Purchased=1 | 143 条 |
| Female      | 204 条 |
| Male        | 196 条 |

- 这是一个二分类任务，目标是预测用户是否购买产品。
- 主要解释变量是 Age、EstimatedSalary，Gender 是本次加入的分类变量。

```
dataset = pd.read_csv('Social_Network_Ads.csv')
dataset['Purchased'].value_counts()
dataset['Gender'].value_counts()
```

# 加入分类变量 Gender，对 Logistic 结果有什么影响？

| 模型        | 混淆矩阵            | Acc    | <pre>X = dataset[['Gender', 'Age', 'EstimatedSalary']] ct = ColumnTransformer(     [('gender', OneHotEncoder(), ['Gender'])],     remainder='passthrough') X = ct.fit_transform(X)</pre> |
|-----------|-----------------|--------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 不加 Gender | [[57,1],[5,17]] | 0.9250 |                                                                                                                                                                                          |
| 加入 Gender | [[56,2],[5,17]] | 0.9125 |                                                                                                                                                                                          |

```
p = (cm[0,0]+cm[1,1])/(cm[0,0]+cm[1,1]+cm[0,1]+cm[1,0])
p
```

[16] ✓ 0.0s Python

np.float64(0.925)

```
p = (cm[0,0]+cm[1,1])/(cm[0,0]+cm[1,1]+cm[0,1]+cm[1,0])
p
```

[33] ✓ 0.0s Python

np.float64(0.9125)

- 加入 Gender 后准确率从 0.9250 降到 0.9125，说明它对本案例帮助不明显。
- Logistic 回归仍主要依赖 Age 和 EstimatedSalary 来划分购买与不购买。

# 加入性别因素后，KNN 的 Acc 有没有变化？

| KNN 模型    | 混淆矩阵            | Acc    |
|-----------|-----------------|--------|
| 不加 Gender | [[55,3],[1,21]] | 0.9500 |
| 加入 Gender | [[55,3],[1,21]] | 0.9500 |

```
classifier = KNeighborsClassifier(n_neighbors=5, metric='minkowski', p=2) classifier.fit(X_train, y_train) y_pred = classifier.predict(X_test)
```

```
# 1 加入性别因素
import pandas as pd
import numpy as np # 一个熟悉的库, num+py
dataset = pd.read_csv('Social_Network_Ads.csv')
dataset.head()
```

```
accuracy = (cm[0,0]+cm[1,1])/(cm[0,0]+cm[0,1]+cm[1,0]+cm[1,1])
accuracy
np.float64(0.95)
```

```
accuracy = (cm[0,0]+cm[1,1])/(cm[0,0]+cm[0,1]+cm[1,0]+cm[1,1])
accuracy
np.float64(0.95)
```

| User ID    | Gender | Age | EstimatedSalary | Purchased |
|------------|--------|-----|-----------------|-----------|
| 0 15624510 | Male   | 19  | 19000           | 0         |
| 1 15810944 | Male   | 35  | 20000           | 0         |
| 2 15668575 | Female | 26  | 43000           | 0         |
| 3 15603246 | Female | 27  | 57000           | 0         |
| 4 15804002 | Male   | 19  | 76000           | 0         |

- 加入 Gender 后 KNN 准确率没有变化，仍为 0.95。
- 说明性别变量不是关键分类因素，年龄和收入的局部分布更重要。

# KNN 与 Logistic 哪个算法更有效?

| 算法       | 特征           | Acc    |
|----------|--------------|--------|
| Logistic | Age + Salary | 0.9250 |
| KNN      | Age + Salary | 0.9500 |

**本案例：KNN 更有效**

- KNN 根据邻近样本投票分类，更适合 Age / EstimatedSalary 上呈现局部边界的数据。
- Logistic 是线性分类器，若边界不是单纯直线，表现可能弱于 KNN。

# 训练集比例如何影响结果？

| 训练集比例 | KNN Acc | Logistic Acc |
|-------|---------|--------------|
| 0.60  | 0.8938  | 0.8562       |
| 0.70  | 0.9174  | 0.8678       |
| 0.75  | 0.9300  | 0.8900       |
| 0.80  | 0.9500  | 0.9250       |
| 0.90  | 0.9250  | 0.9500       |

- 训练集增大通常能提升模型学习效果。
- 测试集过小时，准确率容易受样本随机性影响而波动。
- 本案例中 80% 训练集时，KNN 测试效果最好。

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=0)
```

# 超参数 K 如何影响结果?

| K | 训练集 Acc | 测试集 Acc |
|---|---------|---------|
| 1 | 0.9969  | 0.8875  |
| 3 | 0.9156  | 0.9500  |
| 5 | 0.9187  | 0.9500  |
| 7 | 0.9094  | 0.9500  |
| 9 | 0.9125  | 0.9500  |

- K=1 训练集准确率极高，但测试集准确率较低，容易过拟合。
- K=3、5、7、9 的测试集 Acc 均为 0.95。
- K 值通常选奇数，可以减少投票平局。

```
for k in [1, 3, 5, 7, 9]:  
    classifier = KNeighborsClassifier(n_neighbors=k)
```



# 什么情况下会出现过拟合?

训练集表现好

测试集表现差

泛化能力弱

| 案例       | 训练集 Acc | 测试集 Acc |
|----------|---------|---------|
| KNN, K=1 | 0.9969  | 0.8875  |

- K 过小会让模型过度依赖单个邻居，容易记住训练样本细节。
- 判断过拟合时，要同时比较训练集和测试集表现。


**结论：模型不是训练集越准越好，能在新样本上稳定预测才更重要。**

# 二维图中如何把性别变量考虑进去？

```
# 1. 读取数据
dataset = pd.read_csv('Social_Network_Ads.csv')

# 2. 二维图仍然使用 Age 和 EstimatedSalary
# 用颜色表示是否购买 Purchased
# 用点的形状表示性别 Gender
sns.scatterplot(
    data=dataset,
    x='Age',
    y='EstimatedSalary',
    hue='Purchased',
    style='Gender',
    s=80
)

plt.title('Age and EstimatedSalary with Gender')
plt.xlabel('Age')
plt.ylabel('EstimatedSalary')
plt.show()
```




```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

dataset = pd.read_csv('Social_Network_Ads.csv')

sns.relplot(
    data=dataset,
    x='Age',
    y='EstimatedSalary',
    hue='Purchased',
    col='Gender',
    kind='scatter',
    height=4,
    aspect=1
)

plt.show()
```



- 二维坐标仍使用 Age 和 EstimatedSalary。
- Gender 可用点形状或分面子图表示，Purchased 用颜色表示。