

数据挖掘与机器学习第九次作业

南京工业大学张新通 | 202321054027

决策树作业要求

1. 加入性别因素，看看 Acc 的变化。
2. 如何不进行特征缩放，预测的准确性有什么变化？
3. 比较 KNN、Logistic、决策树在该数据集上的表现。
4. 把决策树输出看看长什么样。

加入性别因素，Acc 有什么变化？

决策树模型	混淆矩阵	Acc
不加 Gender	[[53,5],[3,19]]	0.9000
加入 Gender	[[53,5],[3,19]]	0.9000

```
[16] ✓ 0.0s
... 混淆矩阵:
    [[53  5]
     [ 3 19]]
    准确率: 0.9
```

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import OneHotEncoder, StandardScaler
from sklearn.compose import ColumnTransformer
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import confusion_matrix, accuracy_score

# 1. 读取数据
dataset = pd.read_csv('Social_Network_Ads.csv')

# 2. 加入性别因素: Gender + Age + EstimatedSalary
X = dataset[['Gender', 'Age', 'EstimatedSalary']]
y = dataset['Purchased']

# 3. 对 Gender 做 one-hot 编码
ct = ColumnTransformer(
    transformers=[
        ('gender', OneHotEncoder(), ['Gender'])
    ],
    remainder='passthrough'
)

X = ct.fit_transform(X)

# 4. 划分训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.2,
    random_state=0
```

- 随机森林是 notebook 第15单元补充模型，会覆盖 clf；纯决策树结果仍为 0.9000。
- 加入 Gender 后测试集 Acc 没有变化，仍为 0.9000。
- 说明本案例中性别变量对决策树分类帮助不明显，Age 和 EstimatedSalary 更关键。

不进行特征缩放，预测准确性有什么变化？

设置	混淆矩阵	Acc
进行缩放	[[53,5],[3,19]]	0.9000
不缩放	[[53,5],[3,19]]	0.9000

- 决策树按照特征阈值切分样本，不依赖距离大小。
- 因此决策树通常不要求特征缩放。
- 本实验中缩放与否 Acc 完全相同。

```
print('混淆矩阵: ')
print(cm)
print('准确率: ', acc)
```

7] ✓ 0.0s

混淆矩阵:
[[53 5]
 [3 19]]
准确率: 0.9

```
# 1. 读取数据
dataset = pd.read_csv('Social_Network_Ads.csv')

# 2. 选择特征和标签
# 不加入性别，只使用 Age 和 EstimatedSalary
X = dataset[['Age', 'EstimatedSalary']]
y = dataset['Purchased']

# 3. 划分训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.2,
    random_state=0
)

# 4. 不进行特征缩放，直接训练决策树
clf = DecisionTreeClassifier(
    criterion='entropy',
    random_state=0
)

clf.fit(X_train, y_train)

# 5. 预测
y_pred = clf.predict(X_test)

# 6. 生成混淆矩阵和准确率
cm = confusion_matrix(y_test, y_pred)
acc = accuracy_score(y_test, y_pred)
```

KNN、Logistic、决策树表现如何？

算法	混淆矩阵	Acc
KNN K=5	[[55,3],[1,21]]	0.9500
Logistic	[[57,1],[5,17]]	0.9250
决策树	[[53,5],[3,19]]	0.9000
随机森林*	[[55,3],[2,20]]	0.9375

本案例：KNN 最优

- KNN 在测试集上 Acc 最高。
- 随机森林是 notebook 第15单元补充模型，会覆盖 clf；纯决策树结果仍为 0.9000。

决策树文本规则如何输出?

```
# 1. 读取数据
dataset = pd.read_csv('Social_Network_Ads.csv')

# 2. 选择特征和标签
X = dataset[['Age', 'EstimatedSalary']]
y = dataset['Purchased']

# 3. 划分训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.2,
    random_state=0
)

# 4. 特征缩放
sc = StandardScaler()
X_train = sc.fit_transform(X_train)
X_test = sc.transform(X_test)


# 5. 训练决策树
clf = DecisionTreeClassifier(
    criterion='entropy',
    random_state=0,
    max_depth=4
)

clf.fit(X_train, y_train)
```

```
... | --- Age <= 0.61
    | --- EstimatedSalary <= 0.60
    | | --- Age <= -0.17
    | | | --- class: 0
    | | | --- Age > -0.17
    | | | | --- EstimatedSalary <= -0.07
    | | | | | --- class: 0
    | | | | | --- EstimatedSalary > -0.07
    | | | | | --- class: 0
    | | | --- EstimatedSalary > 0.60
    | | | | --- EstimatedSalary <= 1.84
    | | | | | --- EstimatedSalary <= 1.09
    | | | | | | --- class: 1
    | | | | | --- EstimatedSalary > 1.09
    | | | | | | --- class: 1
    | | | | --- EstimatedSalary > 1.84
    | | | | | --- class: 1
    | --- Age > 0.61
    | | --- EstimatedSalary <= -0.82
    | | | --- EstimatedSalary <= -1.37
    | | | | --- Age <= 0.81
    | | | | | --- class: 0
    | | | | | --- Age > 0.81
    | | | | | | --- class: 1
    | | | | --- EstimatedSalary > -1.37
    | | | | | --- class: 1
    | | | | | --- Age > 1.97
    | | | | | | --- class: 1
```

- 树图能直观看到分裂结构，文本规则能清楚看到每一步判断条件。
- Age、EstimatedSalary 前面的数值是标准化后的阈值。

把决策树输出看看长什么样？



本次决策树作业结论

- 加入 Gender 后，决策树 Acc 不变，说明性别变量贡献不明显。
- 是否进行特征缩放对决策树结果没有影响。
- 同一数据集上，KNN Acc=0.9500，Logistic Acc=0.9250，决策树 Acc=0.9000。
- 决策树可解释性强，可以输出树图和规则文本，但树太深时容易过拟合。

综合来看：本案例预测效果 KNN 更好，模型解释性决策树更直观。