

张新通个人工作报告

在本次机器学习课程案例报告中，我主要负责数据来源、数据生命周期和数据治理相关部分，同时也参与了机器学习建模前的数据准备和部分结果整理工作。我们小组的研究主题是“中小企业 AI 流程自动化采纳机制研究”，整体内容包括数据采集、数据清洗、变量构建、模型训练、结果分析和部署策略总结。我的主要任务是把数据这一部分整理清楚，保证后续机器学习分析有比较可靠的基础。

最开始我配合组长确定研究所需的数据方向，重点围绕企业 AI 采纳、数字化基础、云服务、ICT 能力和治理准备度等内容整理数据来源。由于本案例需要体现机器学习项目的规范性和真实性，我主要负责整理 Eurostat 官方数据的相关信息，核对数据文件来源，并说明选择官方数据的原因。相比普通问卷数据或网络二手数据，官方数据在来源、口径和复核性方面更加可靠，因此我在报告中整理了数据下载记录、文件说明、数据真实性校验和数据生命周期等内容。

在数据清洗部分，我参与梳理了从原始数据到建模数据的处理过程。原始数据不能直接用于模型训练，需要经过筛选、清洗、转换和审计。我协助整理了长表转面板、目标变量非空筛选、缺失值审计、重复键检查以及目标泄漏控制等流程，并参与了 Stage 1 和 Stage 2 两个数据层级的边界说明。Stage 1 主要用于解释中小企业层面的 AI 采纳机制，Stage 2 则用于行业和区域层面的外部验证。在整理这部分内容时，我比较注意样本口径的准确表达，避免把不同层级的数据混淆。除了数据相关工作，我也参与了机器学习建模前的数据准备，包括变量整理、特征含义核对和部分结果表格检查。在小组讨论模型结果时，我结合自己负责的数据流程，协助理解数字基础、云服务能力、ICT 人才和治理成熟度等变量对企业 AI 采纳的影响。通过参与模型结果整理，我也进一步了解了 R2、MAE 和 GroupKFold 交叉验证等评价方法，认识到机器学习项目不仅要关注模型效果，还要关注数据处理过程和验证方式是否合理。

在报告撰写过程中，我主要完成了数据来源与真实性、数据生命周期与清洗结果、数据边界说明等内容，并根据小组整体安排对相关文字进行了修改和补充。PPT 制作阶段，我也协助整理了数据升级、数据生命周期和样本边界相关页面。通过这次项目，我对完整机器学习案例的流程有了更清楚的认识，也体会到数据整理虽然是基础工作，但会直接影响后续模型分析和结论表达。