

Contents

第一次作业

大数据与数据挖掘核心概念体系的知识脉络梳理，涵盖数据基础、预处理技术、降维学习方法及挖掘评估四大核心模块。

01 数据基础认知

02 数据预处理技术

03 降维与学习方法

04 挖掘与评估

数据类型体系：结构化的连续统

01

结构化数据

具有预定义的二维表结构，字段长度固定且数据类型明确，存储于关系型数据库（RDBMS）中，如员工信息表（工号、姓名、性别）和交易记录

支持SQL查询和ACID事务特性，是传统企业信息系统的主流数据形态，占企业数据总量约20%

02

半结构化数据

具有自描述性标记但无严格模式约束，字段可嵌套且长度可变，典型格式包括XML、JSON、日志文件和NoSQL数据库记录

介于结构化与非结构化之间，兼具灵活性和可读性，是Web服务和大数据平台间数据交换的标准格式，占数据总量约10%

03

非结构化数据

无预定义数据模型，字段长度和内容格式高度自由，包括文本文档、图像、音频、视频、电子邮件和社交媒体内容

需要特殊技术（NLP、CV）提取特征才能分析，存储成本高但信息密度大，占企业数据总量约80%且增速最快

数据预处理：从脏数据到数据资产

原始数据中存在缺失值、异常值、重复记录和格式不一致等问题，系统化的预处理流程可将数据质量提升40%以上。ETL集成解决跨系统数据孤岛，特征工程决定模型性能上限，这一阶段消耗了数据科学家60%以上的工作时间，是挖掘项目成功的关键基础。

步骤一

数据清洗

缺失值处理：采用均值/中位数填充、回归插值或KNN插补，避免简单删除导致样本偏差

异常值检测：通过箱线图IQR法则或 3σ 原则识别，结合业务知识判断是噪声还是真实极端值

重复数据删除：基于主键或模糊匹配算法去重，确保记录唯一性，避免分析结果失真

步骤二

数据集成

多源数据合并：使用ETL工具从关系数据库、日志系统、API接口抽取数据，解决异构数据源孤岛问题

模式对齐：统一不同系统的字段命名、数据类型和编码格式（如UTF-8与GBK转换），建立主数据管理（MDM）

实体识别：通过共有键（如用户ID）关联不同表，处理数据值冲突和语义歧义，构建统一数据视图

步骤三

数据转换

特征工程：基于业务理解构造衍生变量（如从生日计算年龄、从消费金额计算RFM价值），提升模型表现力

数据编码：将分类变量转为独热编码（One-Hot）或标签编码（Label Encoding），使算法能处理类别信息

格式标准化：统一日期格式、货币单位、度量衡，进行数据类型转换和离散化分箱，适配分析工具要求

数据缩放与特征构造

不同量纲的特征（如年龄20-80岁与收入5000-50000元）需要统一尺度才能公平参与模型计算。标准化（Z-score）适用于正态分布且异常值较多的场景，而归一化（Min-Max）适合有明确边界的均匀分布数据。衍生变量通过业务逻辑从原始特征中提取深层信息，是提升模型性能的关键手段。

METHOD 01

标准化（Z-score）

通过减去均值并除以标准差，将数据转换为均值为0、标准差为1的分布，保留原始分布形状且对异常值鲁棒，适用于SVM、逻辑回归等基于距离的算法。

METHOD 02

归一化（Min-Max）

通过线性变换将数据映射至[0, 1]区间，严格受极值影响，适合神经网络等需要 bounded input 的算法，当数据中存在离群点时应谨慎使用。

METHOD 03

衍生变量构造

基于业务规则从原始特征计算新特征，如从“出生日期”计算“年龄”、从“消费金额/频次”计算“客单价”和“用户价值分层（RFM）”，这些变量往往比原始特征具有更强的业务解释力和预测力。

数据降维：主成分分析（PCA）

核心洞察：高维数据存在冗余特征和噪声，PCA通过线性变换将原始特征投影到方差最大的正交方向（主成分），在保留最大信息量的同时降低维度。通过选择累计方差贡献率（如95%）的主成分，可将计算复杂度降低70%以上，同时去除噪声干扰。

01 核心原理

基于协方差矩阵的特征值分解，寻找数据方差最大的投影方向（主成分），确保降维后数据重构误差最小。第一主成分捕获最大方差，第二主成分与第一正交且捕获剩余方差最大。

02 计算流程

数据中心化（去均值）→ 计算协方差矩阵 → 特征值分解 → 选择前k个最大特征值对应的特征向量 → 将原始数据投影到k维主成分空间，实现从n维到k维的线性映射。

03 应用价值

用于高维数据可视化（降至2D/3D）、图像压缩（保留关键特征）、噪声过滤（小特征值对应噪声方向）和多重共线性消除，提升模型训练效率并防止过拟合。

非线性降维与可视化：t-SNE

相比PCA的线性假设，t-SNE通过在高维和低维空间分别构建概率分布（高斯分布与t分布），最小化两分布间的KL散度，保留数据的局部邻域结构。这种非线性流形学习方法能揭示高维数据中的簇状结构，是词嵌入可视化、单细胞RNA测序分析和图像特征探索的首选工具，但计算复杂度高（ $O(n^2)$ ）且结果具随机性。

→ 概率映射机制

在高维空间用高斯分布计算点间相似度概率，在低维空间用t分布（重尾特性）计算相似度，通过梯度下降最小化两分布的KL散度，保护局部结构同时防止低维空间点过度拥挤。

→ 困惑度参数

平衡局部与全局结构的超参数（通常设5-50），可理解为有效邻居数量的期望，影响簇的分离度和可视化效果，需多次调参获得最佳投影。

→ 应用场景与局限

广泛用于词向量（Word2Vec/GloVe）可视化、单细胞聚类、MNIST手写数字降维展示；但计算复杂度高（不适合大规模数据），结果具随机种子依赖性，且无法直接投影新样本（需重新运行算法）。

学习范式：监督与无监督

两类学习方法的本质区别在于训练数据是否带有标签。监督学习依赖标注数据建立输入到输出的映射，适用于预测任务；无监督学习从无标签数据中发现隐藏结构，适用于探索性分析。选择取决于业务目标与数据获取成本。

✓ 监督学习 Supervised

☑ 任务定义

利用带标签的训练数据 (X, Y) 学习映射函数 f ，使 $f(X) \approx Y$ 。分为分类（离散标签如 0/1）和回归（连续数值如价格）两类任务。

💻 典型算法

决策树（可解释性强）、支持向量机SVM（高维有效）、朴素贝叶斯（概率基础）、神经网络（深度学习基础），以及随机森林和梯度提升树等集成方法。

⚠ 关键挑战

过拟合（训练集表现好但泛化差）风险，需通过正则化、交叉验证和早停技术控制模型复杂度，确保在新数据上的预测性能。

❓ 无监督学习 Unsupervised

☑ 任务定义

仅基于输入数据 X （无标签）发现内在结构、模式或分组。包括聚类（相似度分组）、降维（维度压缩）、关联规则（项集共现）和密度估计。

💻 典型算法

K-means聚类（划分式）、层次聚类（树状结构）、DBSCAN（基于密度）、高斯混合模型（概率聚类）、PCA/t-SNE（降维）、Apriori/FP-Growth（频繁项挖掘）。

📊 评估特点

缺乏真实标签作为参照，需用轮廓系数、Calinski-Harabasz指数等内部指标，或结合下游任务效果间接评估，结果解释性强依赖业务理解。

数据挖掘核心任务（一）：分类与聚类

分类与聚类是数据挖掘中最基础的模式发现技术，两者本质区别在于是否依赖预定义类别标签。分类通过训练带有标签的历史数据构建决策边界，用于预测新样本的类别归属；聚类通过度量样本间相似度发现内在分组结构，用于客户细分、异常检测和图像分割。前者是预测性分析，后者是描述性分析，常组合使用形成完整解决方案。

01 分类技术

基于标注数据训练分类器，构建输入空间到离散类别的映射函数。常用算法包括决策树（ID3/C4.5/CART，生成可解释规则）、支持向量机SVM（最大化间隔边界）、K近邻KNN（惰性学习）、朴素贝叶斯（概率推理）和神经网络（深度学习）。评估指标包括准确率、精确率、召回率、F1-score和ROC-AUC。

02 聚类技术

基于无标签数据的相似度度量（欧氏距离、余弦相似度）发现内在分组。K-means算法通过迭代优化簇中心与样本的距离平方和；层次聚类构建嵌套簇树状图（树状图）；DBSCAN基于密度识别核心点与噪声，适用于发现任意形状簇和异常值检测。

03 应用对比与协同

分类适用于信用评级（违约/正常）、疾病诊断（阳性/阴性）等预测场景；聚类适用于市场细分、社交网络社区发现、图像分割等探索场景。实践中常先用聚类发现潜在类别，再标注样本训练分类器实现预测，形成“先探索后预测”的完整分析流程。

数据挖掘核心任务（二）：关联与回归

关联规则挖掘揭示项集间的条件共现关系（如购物篮中的互补商品），通过支持度-置信度-提升度三元组评估规则强度；回归分析建立自变量与因变量间的量化函数关系，用于连续值预测和因果推断。前者驱动推荐系统和货架优化，后者支撑销量预测和风险定价，两者共同构成商业智能的量化决策基础。

关联规则挖掘

从交易数据中发现项集间的有趣关联（形如“若A则B”），Apriori算法利用频繁项集的子集必频繁的先验性质进行剪枝，FP-Growth通过构建频繁模式树压缩扫描次数；核心指标包括支持度（项集出现频率）、置信度（条件概率 $P(B|A)$ ）和提升度（实际置信度与独立期望的比值， >1 表示正相关）。

回归分析

建立输入变量与连续目标变量间的函数关系，线性回归假设线性关系并最小化残差平方和（OLS），多元回归处理多自变量，多项式回归拟合非线性关系，岭回归和Lasso通过正则化解决多重共线性和过拟合；模型评估用 R^2 （解释方差比例）、MSE（均方误差）和MAE（平均绝对误差）。

商业应用场景

关联规则用于购物篮分析（商品捆绑销售）、推荐系统（协同过滤基础）和医疗诊断（症状组合模式）；回归用于销售预测、房价评估、风险评分（信用评分卡）和广告点击率预估，提供可量化的决策依据。

模式评估与验证体系

模型在训练集上的表现不能代表其泛化能力，科学的评估体系通过交叉验证充分利用有限数据，通过多元指标全面衡量性能，核心目标是检测过拟合与欠拟合，指导超参数调优和模型选择。

交叉验证技术

K折验证：将数据划分为K个子集，轮流用K-1个子集训练、1个子集验证，重复K次取平均性能，减少随机划分的方差。

留一法 (LOO)：K=N的极端情况，适用于小样本；分层抽样确保每折类别比例与总体一致。

分类模型评估

混淆矩阵指标：精确率 $P=TP/(TP+FP)$ 、召回率 $R=TP/(TP+FN)$ 、 $F1=2PR/(P+R)$ 平衡指标。

ROC与AUC：ROC曲线绘制真正例率vs假正例率，AUC衡量排序能力（0.5为随机，1为完美），PR曲线适用于类别不平衡场景。

回归与泛化评估

回归指标：MSE对大误差敏感，RMSE保持量纲一致，MAE更鲁棒； $R^2=1-SS_{res}/SS_{tot}$ 表示解释方差比例。

诊断方法：通过验证集曲线诊断过拟合（间隔大）与欠拟合（两者均高），指导正则化强度和模型复杂度选择。

Contents

第二次作业

数据回归方法的理论体系与建模实践，涵盖从基础一元线性回归到复杂Logistic回归的完整技术路径。

01 回归方法概述

02 一元线性回归

03 多元线性回归

04 Logistic回归

05 对比与应用

数据回归方法

核心洞察：回归方法是处理变量间相关关系的数学方法，适用于无法建立精确机理模型的复杂系统。通过标准化的五大步骤（收集数据、选定模型、比较筛选、适用性判断、预测解释），回归分析能够从观测数据中提炼量化规律，是数据挖掘领域应用最广泛的基础技术之一。

01 核心定义

回归方法用于处理变量间的相关关系（非确定性函数关系），通过数学模型拟合观测数据，揭示自变量对因变量的影响规律。

02 适用场景

当客观事物内部规律复杂、人类认知受限无法建立机理模型时，借助统计方法从数据中学习规律，如年龄与血压的关系分析。

03 五大标准步骤

收集因变量与自变量数据 → 选定数学模型并估计参数（如最小二乘法） → 利用统计方法比较不同模型 → 判断模型对当前数据的适用性 → 利用模型进行预测或现象解释。

一元线性回归：模型与估计

一元线性回归通过 $Y = \beta_0 + \beta_1 x + \varepsilon$ 模型刻画单一自变量与因变量的线性关系，采用最小二乘法（OLS）估计参数，使残差平方和最小化。模型质量通过决定系数 R^2 、剩余标准差 s 和 F 统计量三维指标综合评估。

数学模型

$$Y = \beta_0 + \beta_1 x + \varepsilon$$

Y 为随机因变量， x 为非随机自变量， β_0 为截距， β_1 为斜率， ε 为随机误差项且满足 $E(\varepsilon)=0$ 、 $Var(\varepsilon)=\sigma^2$ 。

参数估计

最小二乘法原理

通过最小化残差平方和 $Q = \sum (y_i - \hat{y}_i)^2$ 求解参数，估计公式为 $\hat{\beta}_1 = L_{xy}/L_{xx}$ ， $\hat{\beta}_0 = \bar{y} - \bar{x}\hat{\beta}_1$ ，其中 $L_{xx} = \sum (x_i - \bar{x})^2$ ， $L_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y})$ 。

模型评价

$R^2 = 1 - SSE/SST$ ，值越接近1表示拟合优度越好

剩余标准差 $s = \sqrt{SSE/(n-2)}$ ，反映预测误差大小

F 统计量 $= (SSR/1)/(SSE/(n-2))$ ，用于检验线性关系显著性

多元线性回归：多变量建模与矩阵表达

多元线性回归扩展至多个自变量情形，采用矩阵形式 $Y=X\beta+\varepsilon$ 紧凑表达 n 个样本、 p 个特征的复杂关系。设计矩阵 X 包含全1列（截距项）与 p 个自变量列，参数向量 β 包含 $p+1$ 个待估系数，矩阵运算使高维数据的高效处理成为可能，是处理多因素问题的标准工具。

数学模型

标量形式：

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon$$

描述因变量受 p 个非随机因素与随机误差共同影响

矩阵形式：

$$Y = X\beta + \varepsilon$$

其中 Y 为 $n \times 1$ 观测向量， X 为 $n \times (p+1)$ 设计矩阵， β 为 $(p+1) \times 1$ 参数向量， ε 为 $n \times 1$ 误差向量

建模流程

01

变量选择与散点图初判

分析确定因变量与解释变量，绘制散点图观察线性趋势，如学者年薪与论文质量、研究时间的关系

02

参数估计与异常分析

输入数据计算参数估计，分析数据中的异常点，进行显著性检验与残差诊断（正态性、异方差检验）

Logistic回归：分类问题的概率建模

Logistic回归专门处理因变量为二分类（0/1）的定性问题，通过Sigmoid函数将线性组合映射为(0, 1)区间的概率值。核心技巧是Logit变换，将非线性概率估计转化为线性形式，既保持了线性模型的可解释性，又满足了概率输出的范围约束。

模型形式

$p(Y=1 | x_1, \dots, x_k) = \exp(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k) / (1 + \exp(\dots))$ ，输出为事件发生的概率，取值范围(0, 1)

Logit变换

对 $odds = p/(1-p)$ 取自然对数得到 $\ln(p/(1-p)) = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k$ ，将S型曲线关系转化为线性关系

参数估计

采用极大似然估计（MLE）而非最小二乘法，通过最大化似然函数求解参数，适用于定性因变量的概率建模

模型对比：线性回归 vs Logistic回归

01 • 因变量与目标

线性回归

因变量为**定量变量**（连续数值，如收入、温度），预测目标是具体数值大小

Logistic回归

因变量为**定性变量**（二分类0/1，如成功/失败），预测目标是事件发生的概率，进而实现分类

02 • 函数与变换

线性回归

采用直线或超平面 $Y = \beta X$ ，假设误差服从正态分布，输出范围为 $(-\infty, +\infty)$

Logistic回归

采用S型Sigmoid曲线，通过Logit变换 $\ln(p/(1-p))$ 将概率映射为线性形式，输出压缩至 $[0, 1]$

03 • 参数估计

线性回归

使用**最小二乘法**（OLS），最小化残差平方和 $\sum (y_i - \hat{y}_i)^2$ ，有解析解

Logistic回归

使用**极大似然估计**（MLE），最大化似然函数，通常需迭代算法求解，无解析解

核心洞察：线性回归与Logistic回归虽同属回归家族，但服务不同数据类型与预测目标。线性回归处理连续因变量，追求数值预测的精确性；Logistic回归处理分类因变量，通过概率映射实现类别判断。两者在误差假设、估计方法与评价指标上均存在本质差异。

第三次作业

机器学习分类算法教学 • 第8章

01 分类方法概述

分类任务的基本概念与原理，训练集与测试集的划分策略

02 K-近邻算法

基于距离度量的惰性学习算法，银行客户购买意愿预测案例

03 朴素贝叶斯

基于贝叶斯定理的概率分类方法，文本分类与垃圾邮件过滤

04 神经网络与SVM

多层感知器与反向传播，支持向量机的最大间隔分类

05 决策树

基于信息增益的递归分割，ID3/C4.5/C5.0算法演进

06 评估与应用

精确率、召回率、F1-score与ROC曲线，分类选股法案例

分类方法概述

分类方法通过从标注数据中学习决策边界实现预测，核心在于平衡模型的拟合能力与泛化性能。训练集用于构建模型，测试集用于评估未知数据上的表现，这种划分策略确保了模型不仅在历史数据上表现良好，更能适应新样本。

分类的概念

- 分类是基于样本特征属性预测离散类别标签的 supervised 学习任务，输入为特征向量，输出为预定义类别标识，如将邮件标记为垃圾邮件或正常邮件
- 数据集划分为训练集与测试集，训练集用于学习模型参数，测试集用于评估泛化性能，两者严格分离以避免数据泄露

分类的原理

- 通过归纳学习从训练数据中提取决策规则或构建决策边界，形成从输入空间到类别空间的映射函数，用于描述数据分布规律
- 模型具备双重作用：描述性建模解释数据内在结构，预测性建模对新样本进行类别推断，两者共同支撑业务决策

常用方法概览

- 七大主流算法构成完整技术体系：K-近邻基于实例学习，朴素贝叶斯基于概率推理，神经网络模拟生物神经元，逻辑回归建立对数线性模型
- 判别分析利用统计距离分类，支持向量机追求最大间隔，决策树通过递归分割构建规则，各类方法在数据规模、特征类型、解释性需求上各有优势

K-近邻算法原理与实现

K-近邻算法通过局部邻域的相似性推断样本类别，无需显式训练过程，属于惰性学习。算法性能高度依赖距离度量方式与K值选择，欧氏距离适用于连续特征，而K值需通过交叉验证平衡偏差与方差，通常取奇数以避免投票平局。

核心原理

基于“物以类聚”的直观思想，通过计算测试样本与训练集各样本间的欧氏距离或曼哈顿距离，选取距离最近的K个样本构成邻域

采用多数表决机制确定最终类别，若K个邻居中某类占比最高，则预测样本属于该类；当K为偶数且平票时可随机选择或加权投票

算法步骤

第一步计算测试样本与所有训练样本的距离并排序，第二步选取距离最小的K个样本，第三步统计各类别在邻居中的出现频率

第四步将频率最高的类别赋给测试样本，整个过程无需显式训练模型，预测阶段计算开销大但实现简单直观

银行客户案例

使用16维特征预测客户是否购买理财产品，包含年龄、工作类别、婚姻状况、教育水平、存款余额、联系方式等数值与分类变量

通过MATLAB的cvpartition函数划分训练集与测试集，利用categorical函数处理离散变量，最终得到测试集上88.8%的准确率和11.2%的购买意愿识别率

朴素贝叶斯分类

基于概率推理框架，利用贝叶斯定理结合先验概率与似然函数计算后验概率。尽管特征条件独立的假设过于简化，但算法计算高效、对噪声鲁棒，特别适用于高维稀疏数据如文本分类。

算法原理

后验概率计算：基于贝叶斯定理计算给定特征下各类别的后验概率 $P(\text{类别}|\text{特征})$ ，选择后验概率最大的类别作为预测结果，实现最大后验概率决策。

条件独立性假设：核心假设是特征条件独立性，即各特征在类别确定时相互独立，将联合概率分解为各特征条件概率的乘积，大幅简化计算复杂度。

实现步骤

训练与应用流程：准备阶段计算各类别先验概率与特征条件概率，分类器训练阶段构建概率表，应用阶段对新样本计算各类别后验概率并选择最大值。

MATLAB实现：使用`NaiveBayes.fit`函数训练模型，通过`posteriors`方法获取概率分布，利用`confusionmat`函数评估分类效果，结合拉普拉斯平滑处理零概率问题。

算法特点

核心优势：算法简单高效，对孤立噪声点不敏感，小规模数据即可训练，适合多分类问题，特别适合文本分类与情感分析等高维稀疏数据场景。

主要局限：特征独立性假设往往不成立，特征间相关性会降低分类性能，对输入数据分布敏感，需要先验知识确定概率分布类型，类别特征缺失时效果受限。

神经网络分类

网络结构

多层前馈架构：输入层节点对应特征维度，隐藏层通过激活函数引入非线性变换，输出层给出类别概率或判别值。

感知器单元：接收加权输入与偏置项，经激活函数（sigmoid、ReLU）产生输出，多层结构可逼近任意复杂函数。

训练机制

双向传播算法：前向传播计算各层输出与损失值，反向传播计算梯度并按学习率更新权重，迭代优化直至收敛。

超参调优：学习率控制调整步长，过大导致震荡，过小收敛缓慢，通过验证集监控采用早停策略防止过拟合。

MATLAB实现

patternnet工具箱：设置隐藏层节点数、训练轮数、数据集划分比例，采用贝叶斯正则化算法提升训练稳定性。

性能评估：混淆矩阵显示测试集整体准确率约**90%**，需注意类别不平衡数据中少数类召回率。

核心洞察：神经网络通过多层非线性变换学习复杂模式，具备强大的函数逼近能力，适合图像识别、语音识别等复杂模式分类任务，但训练需要大量数据和计算资源，且模型可解释性较差。

支持向量机

支持向量机通过最大化分类间隔寻找最优超平面，间隔最大化确保模型泛化性能最优，仅依赖支持向量进行决策。核技巧将低维不可分问题映射到高维空间，线性核、多项式核、RBF核适应不同数据分布，是处理高维小样本数据的强大工具。



核心原理

最大间隔原理

在特征空间中寻找能将两类样本正确分开且间隔最大的超平面，间隔定义为两类最近样本到超平面的距离之和，最大化间隔等价于最小化结构风险

支持向量是位于间隔边界上的样本点，它们决定了超平面位置，移除非支持向量不会改变决策边界，体现了模型的稀疏性



关键技术

优化与核技巧

构建凸二次规划问题求解最优权重向量与偏置项，引入拉格朗日乘子处理约束条件，转化为对偶问题高效求解

核函数隐式计算高维特征空间内积，避免显式映射计算，线性核、多项式核、高斯RBF核分别适用于不同复杂度决策边界



性能评估

算法特点

泛化能力强，特别适合高维数据与小样本场景，最终模型仅依赖少量支持向量，存储与预测效率高

对核函数与参数敏感，大规模数据训练速度慢，缺失值处理困难，多分类需扩展策略，但分类精度通常优于传统方法

决策树分类

决策树通过递归分割构建层级决策规则，信息增益或基尼不纯度指导属性选择，ID3、C4.5、C5.0算法逐步优化分裂准则与剪枝策略。树形结构天然可解释，但易过拟合需通过预剪枝或后剪枝控制复杂度，适合特征可解释性要求高的场景。

构建原理

- 采用自顶向下的递归分割策略，选择最优属性作为节点分裂依据，将数据集划分为更纯的子集直至满足停止条件
- 信息增益衡量属性对类别不确定性的减少程度，基尼不纯度计算随机抽取样本被错分的概率，两者均用于选择最优分裂属性

算法演进

- ID3算法基于信息增益选择属性，但偏向取值多的特征；C4.5引入信息增益比修正偏向，处理连续属性与缺失值，采用后剪枝防止过拟合
- C5.0进一步优化效率与内存使用，支持boosting 集成，成为工业界常用决策树算法

剪枝策略

- 预剪枝在节点分裂前评估增益是否超过阈值，提前停止生长，计算高效但可能欠拟合；后剪枝先生成完整树再自底向上剪除不显著分支
- 通过验证集评估剪枝前后精度变化，保留泛化性能提升的分支，平衡模型复杂度与预测准确性，避免对训练数据的过度记忆

分类模型评估

分类模型评估需多维度综合考量，单一准确率无法反映类别不平衡下的真实性能。ROC曲线与AUC面积提供阈值无关的性能度量，混淆矩阵细化各类错误分布。

评估指标体系

准确率反映整体预测正确比例，但在类别不平衡时可能误导；精确率衡量预测为正例中真正例比例，召回率衡量真正例被正确识别比例

F1-score是精确率与召回率的调和平均，综合衡量模型性能；特异度反映负例识别能力，假正例率反映误报情况

ROC曲线分析

ROC曲线以假正例率为横轴、真正例率为纵轴，绘制不同阈值下的模型表现，曲线越靠近左上角性能越优，对角线代表随机猜测

AUC面积为曲线下方面积，取值0.5至1，越大表示模型区分能力越强，0.9以上优秀，0.8-0.9良好，0.7-0.8一般

六种分类算法正确率对比



SVM分类正确率最高达0.85，显著优于朴素贝叶斯的0.65

应用实例：分类选股法

01 / 案例背景

数据驱动预测框架

利用历史股票数据预测未来价格走势，将连续收益离散化为涨跌二分类问题，构建特征包括技术指标、基本面数据、市场情绪等。

数据集划分为训练集与测试集，训练集用于学习模式，测试集模拟真实交易环境，通过交叉验证确保模型稳健性。

02 / 实现方法

多算法对比验证

数据预处理包括特征标准化、缺失值处理、类别编码；模型训练阶段分别采用KNN、朴素贝叶斯、神经网络、SVM、决策树等算法。

通过混淆矩阵计算准确率、精确率、召回率，绘制ROC曲线比较AUC面积，选择泛化能力最强的模型作为最终选股策略。

03 / 结果分析

模型性能与实务考量

实验显示SVM与LDA在测试集上表现优异，AUC面积超过0.8，KNN与朴素贝叶斯稍逊，不同算法对特征空间的划分能力差异显著。

实际应用中需考虑交易成本、滑点、市场冲击，结合风险控制与资金管理，将分类结果转化为可执行的交易信号。

核心洞察： 分类选股法将机器学习应用于金融预测，通过历史行情数据训练分类模型预测股票涨跌，为投资决策提供量化依据。不同算法在准确率、召回率上表现各异，SVM与神经网络通常优于传统方法，但需防范过拟合与数据泄露，确保模型在真实市场环境中的稳健性。

Contents

第四次作业

从基础概念到算法实现，系统掌握机器学习中的聚类分析方法

01 聚类基础概念

02 距离与相似性度量

03 K-means聚类算法

04 层次聚类（HC）

聚类基础：簇的概念与特征

聚类是无监督学习的典型代表，通过度量样本间相似性将数据集划分为若干簇，使簇内相似度最大化而簇间差异最大化。

聚类任务本质

将物理或抽象对象的集合分组为多个类，使同一类内的对象相似度高于不同类之间的相似度，是无监督学习的核心任务。

簇的多重定义


簇可以看作密度相连的区域、距离相近的点集、或层次结构中的分支，不同定义对应K-means、DBSCAN、层次聚类等不同算法。

与分类的本质区别

分类是监督学习需要标签，聚类是无监督学习无需标签；分类学习决策边界，聚类发现数据内在结构。

应用场景广泛

客户分群、文档归类、图像分割、基因表达分析等领域，聚类帮助发现隐藏的数据模式和异常点。



聚类前后数据点分组对比示意图

相似性度量：距离与相似系数

聚类算法的效果高度依赖于相似性度量的选择。不同度量方式适用于不同数据特征，选择错误会导致聚类结果严重偏离真实结构。

DISTANCE METRICS

欧氏距离与 闵可夫斯基距离

欧氏距离是最常用的距离度量，公式为 $d = \sqrt{\sum (x_i - y_i)^2}$ ，对应闵可夫斯基距离 $q=2$ 的特例，直观反映空间中的直线距离。

闵可夫斯基距离统一了曼哈顿距离 ($q=1$)、欧氏距离 ($q=2$) 和切比雪夫距离 ($q \rightarrow \infty$)，通过调整 q 值可适应不同数据分布特征。

SIMILARITY COEFFICIENT

余弦相似度与 夹角度量

余弦相似度 $\cos \theta = (x \cdot y) / (||x|| \cdot ||y||)$ 衡量向量方向一致性， $\theta = 0^\circ$ 时完全相似 ($\cos \theta = 1$)，适合文本和高维稀疏数据。

与距离度量不同，余弦相似度对向量的**绝对长度不敏感**，只关注方向相似性，常用于文档聚类和推荐系统。

ROBUST MEASURES

兰氏距离与 数据标准化

兰氏距离 $d = \sum |x_i - y_i| / (x_i + y_i)$ 要求所有特征值为正，对量纲差异具有鲁棒性，适合化学、生物等领域的数据分析。

实际应用中需先进行**数据标准化** (Z-score 或 Min-Max)，消除不同特征量纲和取值范围差异对距离计算的影响。

"选择错误的度量方式会导致聚类结果严重偏离真实结构"

K-means算法：原理与实现

通过迭代优化最小化簇内平方和，将n个样本划分为k个簇。算法虽简单高效，但存在明显局限：需要预先指定k值，对初始质心敏感易陷入局部最优。

核心思想

最小化簇内误差平方和，通过迭代优化使簇内样本到质心的距离平方和最小，形成紧凑的球形簇结构。

标准流程


随机初始化k个质心 → 分配样本到最近质心形成簇 → 重新计算质心（均值）→ 重复直至质心不再变化或达到最大迭代次数。

MATLAB实现

使用kmeans函数，指定距离度量（如'cosine'余弦距离），通过kmeans++初始化改善质心选择，避免局部最优。

算法局限与改进

对异常值敏感（可用k-medoids改进），假设簇为凸形（可用DBSCAN处理任意形状），需预设k值（可用肘部法则确定）。



K-means算法迭代过程：质心更新与样本分配

案例：债券数据的K-means聚类

在金融领域，K-means可用于债券投资组合的自动分类。通过票面利率、到期收益率等数值特征，算法将债券自动聚类，识别出风险收益特征相似的债券组。

- 1 **数据准备：** 导入债券数据包含Type（债券类型）、Coupon（票面利率）、YTM（到期收益率）、CurrentYield（当前收益率）、Rating（信用评级）等9维特征
- 2 **预处理策略：** 使用categorical处理分类变量，datetime转换日期格式，筛选有效数据后提取数值特征（Coupon, YTM, CurrentYield, RatingNum）
- 3 **聚类实施：** 设置距离度量'dist_k = cosine' 处理不同量纲特征，使用kmeans(bonds, numClust, 'distance', dist_k)执行聚类
- 4 **结果解读：** 通过三维散点图（Coupon-Rating-YTM）展示聚类结果，验证是否与专家评级（CC到AAA）一致，为自动化债券分类提供依据

Random initialization

For i = 1 to 100 {
 → Randomly initialize K-means.
 Run K-means. Get $c^{(1)}, \dots, c^{(m)}, \mu_1, \dots, \mu_K$.
 Compute cost function (distortion)
 → $J(c^{(1)}, \dots, c^{(m)}, \mu_1, \dots, \mu_K)$
}

Pick clustering that gave lowest cost $J(c^{(1)}, \dots, c^{(m)}, \mu_1, \dots, \mu_K)$

债券数据聚类结果可视化：Coupon-Rating-YTM三维散点图

 关键洞察

余弦距离度量适合处理不同量纲的金融指标，MATLAB的kmeans函数配合gscatter可视化，能清晰展示聚类结果与原始评级的关系，为资产配置提供数据支持。

层次聚类（HC）：原理与特点

💡 层次聚类通过构建树状图（Dendrogram）展示数据的层次结构，无需预先指定簇数。凝聚式（自底向上）从单样本簇开始逐步合并，分裂式（自顶向下）从整体不断分割。HC特别适合小规模数据集，能直观展示簇间的层次关系，但时间复杂度高（ $O(n^2)$ 或更高），不适合大规模数据。

算法流程与复杂度

- 凝聚式过程：初始每个样本为独立簇，计算簇间相似度矩阵，合并最相似的两个簇，更新相似度矩阵，重复直至所有样本归为一簇
- 复杂度分析：时间复杂度通常为 $O(n^2)$ 或 $O(n^3)$ ，空间复杂度 $O(n^2)$ ，因此仅适用于小规模数据集（通常 $n < 10000$ ）

簇间距离度量

- 单链接：取两簇间最近样本对的距离，适合发现非球形簇但对噪声敏感，可能产生链式效应
- 全链接：取两簇间最远样本对的距离，倾向于生成球形簇，对噪声较鲁棒但可能合并不同密度的簇
- 中心点距离：基于两簇质心间距离，计算简单但可能忽略簇的形状信息

核心优势与局限

- ✓ 优势：无需预设簇数，通过树状图直观展示层次结构，适合理解数据的内在组织方式和异常点检测
- ✗ 局限：计算和存储开销大，无法处理大规模数据；一旦合并无法撤销，对噪声和异常值敏感

树状图解读：确定聚类数目


通过观察垂直线的高度和分支结构，结合切割法则直观判断聚类的合理数目

结构原理：叶子代表单个样本，垂直线长度表示簇间距离或相似度，水平线代表簇的合并，高度反映合并时的距离阈值

切割法则：在纵轴某高度画水平线，统计与垂直线的交点数即为聚类数；上移至根节点得1个簇，下移至叶节点得n个簇

MATLAB实现：使用dendrogram函数绘制，设置'ColorThreshold'参数控制颜色分支，默认显示30个节点防止图形拥挤，linkage函数支持'ward'、'single'等距离度量

最佳实践：结合肘部法则、轮廓系数或业务场景确定切割高度，通常选择长垂直分支后的首次合并点，确保簇内距离小、簇间距离大



层次聚类树状图（Dendrogram）及切割线示意

聚类方法：从K-means到层次聚类

掌握聚类核心思想，灵活应用于数据分析实践

方法对比与选择

K-means适合大规模数据、球形分布、追求计算效率；层次聚类适合小数据集、需要层次结构、追求可解释性；实践中常结合使用，如先用K-means粗分再用HC细化

🔑 关键成功因素

数据标准化消除量纲影响、选择合适距离度量（欧氏/余弦/马氏）、确定最佳K值（肘部法则/轮廓系数/业务知识）、处理异常值和噪声

📖 拓展阅读建议

阅读《白话机器学习》K-means与决策树章节，理解算法背后的统计思想；实践MATLAB的统计工具箱，掌握kmeans、linkage、dendrogram等核心函数

Contents

第五次作业

关联规则与Apriori算法技术汇报，涵盖应用场景、核心概念、算法原理及实践应用

01 关联规则应用场景

02 核心概念与度量

03 数据矩阵表示

04 Apriori算法原理

05 Python实现与知识图谱

06 行业关联选股法

关联规则的应用场景

通过发现项集间的共现模式，在零售、医疗、金融、工业等领域实现知识发现，为理解复杂数据关系提供系统化的分析框架。

商业与医疗应用

购物篮分析通过发现顾客购买行为模式优化商品陈列，经典案例显示啤酒与尿布的关联性可提升交叉销售额15-20%

医学规律发现在自闭症研究中通过药物共现网络识别跨治疗组的药物关联，辅助个性化治疗方案制定

保险行业应用通过识别具有特定关联特质的客户群体，实现精准风控

工业故障诊断

工程故障关联分析设备日志发现故障模式，如某部件异常往往伴随另一部件过热，实现预测性维护

通过关联规则挖掘降低设备维修成本，提前识别故障链，避免连锁反应导致的重大停机事故

制造领域应用关联规则优化生产流程，识别质量缺陷与工艺参数间的隐藏关联

金融证券分析

行业关联选股法利用关联规则分析股票行业间联动关系，当某些板块上涨时关联行业可能跟随上涨

构建知识图谱将发现的关联规则转化为图结构，节点表示实体，边表示关联强度，支持高维关系推理

量化交易应用通过历史数据挖掘行业轮动规律，为投资组合配置提供数据驱动的决策支持

“关联规则为理解复杂数据关系提供了系统化的分析框架，是构建知识图谱和实现智能推荐的重要基础”

关联规则的核心概念

关联规则挖掘建立在严格的数学定义之上：项与项集构成基本数据单元，支持度衡量规则的普遍程度，置信度衡量规则的可靠程度。频繁项集需满足最小支持度阈值，强关联规则则需同时满足最小支持度和最小置信度，这种双重阈值机制有效过滤了偶然共现的伪关联。

- 01 项 (Item) 与项集 (Itemset)** — 项是数据中的最小单位，如超市中的单个商品；项集是项的集合，如 {牛奶, 面包}；事务是一条交易记录，包含若干项，如顾客一次购买的商品清单。
- 02 支持度 (Support)** — 计算公式为 $P(X \cup Y)$ ，即同时包含 X 和 Y 的事务数除以总事务数，反映规则在整个数据集中的普遍程度，值越大说明关联越普遍。
- 03 置信度 (Confidence)** — 计算公式为 $P(Y|X)$ ，即同时包含 X 和 Y 的事务数除以包含 X 的事务数，反映规则的可靠性，值越大说明从 X 推出 Y 的可信度越高。
- 04 频繁项集与强关联规则** — 频繁项集指支持度大于等于最小支持度阈值的项集，是生成关联规则的基础；强关联规则需同时满足最小支持度和最小置信度两个阈值条件。

数据矩阵表示：行与列的定义

关联规则挖掘要求将原始交易数据转换为布尔矩阵形式，其中行代表事务（交易记录），列代表项（商品或特征），矩阵元素为0或1表示包含关系。这种表示方法是Apriori算法高效计算的基础。

- 01 矩阵的**行代表事务(Transaction)**，即一条完整的交易记录，如一次购物订单、一天的股票行情或一条医疗记录，每一行对应一个独立的观测样本。
- 02 矩阵的**列代表项(Item)**，即具体的商品、行业板块、症状或特征属性，每一列对应一个可能出现在事务中的元素。
- 03 矩阵元素取值为**布尔值0或1**，其中1表示该事务包含该项，0表示不包含，这种二元表示消除了数量差异，仅关注存在性。
- 04 **Python实现**中使用mlxtend库的TransactionEncoder，通过fit方法学习所有唯一项，通过transform方法将交易列表转换为布尔矩阵。

	A	B	C	D	E	F	G	H	I	J	K	L	M	N
1		I	like	you	my	dear	enjoy	playing	chess	with	friend	he	is	best
2	I	0	1	0	0	0	1	0	0	0	0	0	0	0
3	like	1	0	1	0	0	0	0	0	0	0	0	0	0
4	you	0	1	0	1	0	0	0	0	0	0	0	0	0
5	my	0	0	1	0	2	0	0	0	1	0	0	1	1
6	dear	0	0	0	2	0	0	0	0	0	1	0	0	0
7	enjoy	1	0	0	0	0	0	0	0	0	0	0	0	0
8	playing	0	0	0	0	0	0	0	1	0	0	0	0	0
9	chess	0	0	0	0	0	0	1	0	1	0	0	0	0
10	with	0	0	0	1	0	0	0	1	0	0	0	0	0
11	friend	0	0	0	0	1	0	0	0	0	0	0	0	1
12	he	0	0	0	0	0	0	0	0	0	0	0	1	0
13	is	0	0	0	1	0	0	0	0	0	0	1	0	0
14	best	0	0	0	1	0	0	0	0	0	1	0	0	0


图：关联规则挖掘中的0-1布尔矩阵数据结构示意

Apriori算法原理与过程

💡 关键洞察：Apriori算法基于先验性质——频繁项集的所有子集必须也是频繁的，反之非频繁项集的所有超集必定非频繁。这一性质支持高效的剪枝策略，显著降低计算复杂度。

- 1 先验性质是算法核心：若项集S是频繁的，则其所有子集也必定频繁；若项集S非频繁，则所有包含S的超集也必定非频繁，这是剪枝的理论基础。
- 2 连接操作(Join)将两个k-1项集L(k-1)进行自连接，生成k项候选集C(k)，例如L1={A, B, C}连接生成C2={AB, AC, BC}。
- 3 剪枝操作(Prune)检查候选k项集的所有k-1子集，若存在某个子集不在L(k-1)中，则删除该候选项集，大幅减少计算量。
- 4 迭代生成过程从k=1开始，反复执行连接与剪枝，计算支持度筛选频繁项集，直到无法生成新的频繁项集为止，最终得到所有频繁项集的完整集合。

The Apriori Algorithm—An Example



图：Apriori算法迭代流程示意图

Apriori算法执行步骤详解

Apriori算法通过七步迭代系统性地挖掘频繁项集：从扫描数据生成候选1-项集开始，经支持度筛选得到频繁1-项集，再通过连接与剪枝的循环迭代逐步构建高阶项集，直至无法生成新的频繁项集。

初始化与迭代过程

- ➔ 扫描全部数据产生候选1-项集C1，统计每个项的出现频次
- ➔ 根据最小支持度阈值从C1筛选出频繁1-项集L1，删除低于阈值的项
- ➔ 对k>1循环执行：由Lk连接生成候选(k+1)-项集C(k+1)，剪枝后统计支持度生成L(k+1)

终止与规则生成

- ✓ 当L(k+1)为空集时算法终止，此时已获得所有频繁项集的完整集合
- ✓ 根据最小置信度阈值从频繁项集生成强关联规则，过滤掉低置信度的弱规则
- ✓ 最终输出满足支持度和置信度双阈值的关联规则，用于业务决策和知识发现

Apriori算法迭代示例（最小支持度计数=2）

步骤	操作	结果项集
第1次扫描	生成C1并统计频次	$C1=\{A:2, B:3, C:3, D:1, E:3\} \rightarrow L1=\{A, B, C, E\}$
第2次扫描	L1连接生成C2，剪枝后统计	$C2=\{AB, AC, AE, BC, BE, CE\} \rightarrow L2=\{AB, AC, BC, BE, CE\}$
第3次扫描	L2连接生成C3，剪枝后统计	$C3=\{BCE\} \rightarrow L3=\{BCE\}$
第4次扫描	L3连接生成C4	$C4=\varnothing$ ，算法终止

通过迭代连接与剪枝，最终得到所有频繁项集 {L1, L2, L3}

Python实现：商品关联分析与知识图谱


通过mlxtend库实现Apriori算法，对100条电子产品交易记录进行分析，共发现83个2项频繁项集，其中笔记本电脑-路由器关联强度最高（支持度0.04）。

数据准备与算法实现

- ✓ 使用`TransactionEncoder.fit_transform`将交易列表转为布尔矩阵，100行25列对应100条交易和25种商品
- ✓ 调用`apriori(trans_df, min_support=0.02, max_len=2)`计算频繁项集，限制最大项集长度为2以关注直接关联
- ✓ 使用`association_rules`函数基于频繁项集生成关联规则，设置`min_threshold`过滤弱规则

结果分析与可视化

- 共发现83个满足条件的2项频繁项集，笔记本电脑-路由器出现4次（支持度0.04），关联强度最高
- 加湿器-智能手表、吸尘器-笔记本电脑等组合出现3次，反映电子产品间的互补购买模式
- 通过networkx构建知识图谱，节点表示商品，边表示关联强度，实现关联关系的可视化呈现



知识图谱可视化 • 节点大小映射出现频率，边粗细映射支持度

应用实例：行业关联选股法背景与实现

背景与数据构建

行业联动性：不同行业股票存在联动性，某些板块上涨时关联行业可能跟随上涨

矩阵构建：行代表交易日期，列代表银行、地产、医药、科技等行业板块

布尔转换：元素1表示该行业当日上涨，0表示下跌，便于Apriori算法挖掘

策略与风险控制

关联挖掘：设置最小支持度0.03和置信度0.6，挖掘频繁共涨的行业组合


投资策略：监测到规则前件（如银行、保险上涨）出现时，预测后件行业可能跟随上涨

风险控制：关联规则反映历史共现规律而非因果关系，需结合宏观基本面分析

2.1 最近一周因子表现

图3展示了上周各类因子在不同股票池内的 RankIC 表现情况。可以看到，在全样本内基本面因子仍然延续着近期的良好表现。Beta 因子在上周取得了接近-30%的 RankIC，相比于上周出现了很大程度回撤。另一方面，估值因子的 RankIC 为 19.01%取得了较为显著的效果，而基本因子的效果不再显著，在各个样本股中的 RankIC 不尽相同。

图 3：上周部分因子在主要指数上的 RankIC 表现（2020.2.21-2020.2.28）



数据来源：财通证券研究所，恒生聚源

股票行业板块关联分析示意图

总结与思考

Apriori算法以先验性质为基础，通过连接与剪枝迭代生成频繁项集，将原始交易数据转化为0-1矩阵，经支持度与置信度双重阈值筛选生成强关联规则，最终构建知识图谱实现可视化。从购物篮分析、故障诊断到医学发现、金融选股，关联规则为发现数据中的隐藏模式提供了强大工具。

核心机制与数据表示

先验性质支撑剪枝策略，连接与剪枝操作迭代生成频繁项集，支持度与置信度双重阈值筛选强规则

0-1矩阵清晰表达事务与项的关系，行为交易记录，列为商品或特征，便于高效计算支持度与置信度

应用场景与实践要点

-  从购物篮分析、故障诊断到医学发现、金融选股，关联规则是知识发现的重要工具
-  合理设置支持度与置信度阈值防范过拟合，关联不等于因果，需结合业务理解谨慎解释结果

Contents

第六次作业

从矩阵运算到模型评估，系统掌握线性回归的核心原理与实现方法。

01 矩阵维度与向量化

02 模型参数获取

03 R^2 模型评估

04 数据划分策略

05 最小二乘法实现

矩阵维度约束：为何X必须是列向量结构


线性回归的矩阵运算要求X保持(n_samples, n_features)的二维结构，即使单变量回归也需reshape为(n, 1)而非(n,)。sklearn强制要求二维输入以确保矩阵乘法 $Y=X \cdot \beta$ 的数学一致性，一维行向量会导致维度不匹配错误。

- 01 数学原理：**线性回归公式 $Y=X \beta$ 要求X为 $M \times N$ 矩阵（M样本数，N特征数），权重 β 为 $N \times 1$ 向量，乘积结果为 $M \times 1$ 的预测值向量，符合矩阵运算维度匹配规则
- 02 sklearn约束：**fit() 和predict() 方法强制要求X.shape为(n_samples, n_features)，若传入一维数组(shape为(n,))会触发ValueError: Expected 2D array, got 1D array instead
- 03 单变量特例：**即使只有一个特征，X也需保持(n, 1)的二维结构而非(n,)的一维数组，确保模型能正确识别特征矩阵的维度信息
- 04 解决方案：**使用numpy的reshape(-1, 1)方法将一维特征转换为列向量，或通过ColumnTransformer处理混合类型数据，严格保持二维输入结构

模型参数提取：coef_与intercept_的实战应用

训练完成的线性回归模型通过**coef_**暴露回归系数（斜率），通过**intercept_**暴露截距项。以图片数据为例，系数9.91表示自变量每增加1单位因变量增加9.91单位，截距2.02表示基准值，共同构成预测方程 $y = 2.02 + 9.91x$ 。

- **系数获取：**调用`regressor.coef_`返回斜率数组，在单变量回归中为标量值，多变量回归中为长度等于特征数的数组，每个元素代表对应特征的边际效应
- **截距获取：**调用`regressor.intercept_`返回截距值2.02，表示当所有特征为0时的预测基准值，是回归直线与y轴的交点
- **方程构建：**基于提取的参数构建预测公式，可用于对新样本进行预测，体现自变量对因变量的线性影响关系
- **代码验证：**使用`regressor.predict(X_test)`生成预测值，与手工计算结果对比，验证参数提取的正确性




线性回归模型参数的几何意义：斜率表示变化率，截距表示基准值

R² 决定系数：模型解释力的量化评估

R² 通过 $1 - SS_{res} / SS_{tot}$ 计算模型对数据变异的解释比例，取值范围 $[0, 1]$ 。训练集 $R^2 = 0.952$ 、测试集 $R^2 = 0.945$ ，表明模型解释了约95%的目标变量变化，且训练与测试性能接近，说明模型泛化能力优异无过拟合。

- 01 **计算公式：** $R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$ ，其中分子为残差平方和（预测误差），分母为总平方和（数据固有变异），比值越小说明模型解释力越强
- 02 **代码实现：**调用`regressor.score(X_train, Y_train)`获取训练集 R^2 (0.9516)，调用`regressor.score(X_test, Y_test)`获取测试集 R^2 (0.9455)，快速评估模型性能
- 03 **结果判读：** R^2 接近1 (>0.9) 表示拟合效果优异， R^2 在0.7-0.9表示良好， <0.3 通常表示模型解释力弱需重新考虑特征或模型选择
- 04 **过拟合检测：**训练集 R^2 (0.952) 与测试集 R^2 (0.945) 差异仅0.007，远小于0.1的警戒线，证明模型未过拟合，对新数据具有稳定预测能力



数据划分策略：训练/测试比例对模型性能的影响

"训练/测试比例的选择需要在模型学习能力与评估可靠性间权衡。80/20是经验法则，在样本量充足时能保证模型充分学习且评估结果统计显著。"

⚠ 欠拟合风险

训练集比例<60%时，模型无法充分捕捉数据规律，训练 R^2 和测试 R^2 双低，模型处于欠拟合状态，预测能力弱。

评估不稳定

训练集比例>90%时，测试集样本过少（如25个样本中仅2-3个）， R^2 估计方差大，无法可靠反映真实泛化能力。

💡 经验法则

80/20划分在样本量25-1000范围内表现稳健，既保证模型有充足数据学习（20个样本中16个训练），又确保测试集有代表性（4个测试）。

⚙ 动态调整

小样本(<100)可采用70/30增加测试稳定性，大样本(>10000)可采用90/10最大化训练数据，或通过K折交叉验证充分利用全部数据。

最小二乘法：从数学公式到numpy代码实现

最小二乘法通过正规方程 $\beta = (X^T X)^{-1} X^T Y$ 直接求解全局最优解，避免迭代法的局部最优陷阱。使用numpy实现时，需先为X添加全1偏置列，再通过矩阵运算求解，结果与sklearn的coef_和intercept_误差小于1e-10，验证算法正确性。

数学原理：最小化残差平方和 $\|Y - X\beta\|^2$ ，对 β 求导并令导数为0，推导得正规方程 $\beta = (X^T X)^{-1} X^T Y$ ，直接获得解析解

numpy实现步骤：① `X_b = np.c_[np.ones((n, 1)), X]` 添加偏置列；② `theta_best = np.linalg.inv(X_b.T @ X_b) @ X_b.T @ Y` 计算最优参数，其中@表示矩阵乘法

结果验证：手动计算得到的系数[2.018, 9.911]与sklearn的intercept_(2.018)和coef_(9.911)完全一致，证明底层实现正确

适用边界：最小二乘法要求 $X^T X$ 可逆（特征间无多重共线性），样本量大于特征数，适用于中小规模数据；大规模数据建议使用sklearn的迭代优化算法

总结：线性回归的完整技术闭环

线性回归实践需遵循数据结构规范→参数提取→模型评估→数据划分→算法验证的完整流程。矩阵维度约束保证数学正确性， R^2 评估确保模型质量，最小二乘法验证算法原理，形成从理论到实践的闭环。

数据结构铁律

X必须保持(n_samples, n_features)的二维结构，使用`reshape(-1, 1)`处理单变量，确保矩阵运算维度匹配

参数可解释性

`coef_`反映特征边际效应(9.91)，`intercept_`提供基准值(2.02)，共同构建可解释的预测方程

评估指标体系

$R^2=0.95$ 表明模型解释95%变异，训练/测试 R^2 差异 <0.01 证明无过拟合，泛化能力优异

Contents

第七次作业

多元线性回归与分类数据分析

01 数据特征观察

02 One-Hot编码过程

03 R^2 模型评估

04 系数与截距解读

05 分类变量影响分析

06 编码方式对比

数据特征观察：属性构成与分类变量识别


关键发现：50_Startups数据集包含5个属性，其中State为分类变量。箱线图显示三个城市的利润分布差异有限，中位数均在12-15万区间，表明地理位置对营收的直接影响较弱。

数据集结构

- 01 数据集共50条记录，包含4个特征变量（R&D Spend、Administration、Marketing Spend、State）和1个目标变量（Profit）
- 02 State为唯一分类变量，包含3个类别：New York（17例）、California（17例）、Florida（16例），需进行编码转换才能进入回归模型

可视化分析

- 01 箱线图显示三个城市的利润中位数差异不超过2万元，分布范围（IQR）重叠度高，说明State对Profit的独立解释力有限
- 02 散点图揭示R&D Spend与Profit呈明显正相关（ $r \approx 0.98$ ），是利润的核心驱动因素，远大于State的潜在影响



One-Hot编码过程：从文字标签到二进制矩阵

One-Hot编码通过LabelEncoder将State转为数字（0/1/2），再通过OneHotEncoder转为3列二进制向量（每列代表一个州），最终形成6列特征矩阵（3列One-Hot+3列数值）。这种转换消除了类别间的虚假序关系，使回归系数可解释为相对于基准类别的差异。

第一步 Label编码：使用LabelEncoder将'California'、'Florida'、'New York'映射为0、1、2，实现文字到数字的初步转换

第二步 One-Hot转换：通过OneHotEncoder将单个数字列拆分为3列二进制向量，如[1,0,0]表示California，[0,1,0]表示Florida，每列独立表示一个类别

第三步 ColumnTransformer整合：指定transformers参数仅对第4列（索引3）应用编码，remainder='passthrough'保留其他数值列，输出6列完整特征矩阵


第四步 编码结果验证：转换后矩阵维度为50×6，前3列为One-Hot编码（0/1值），后3列为原始数值（R&D、Admin、Marketing），可直接输入LinearRegression模型

R² 模型评估：决定系数的计算与解读

R² 决定系数通过 $1 - SS_{\text{res}} / SS_{\text{tot}}$ 计算，衡量模型解释数据变异的能力。本案例中 $R^2 = 0.9491$ ，表明模型解释了94.9%的利润变化，拟合效果优异；训练集与测试集 R^2 差异小于0.01，证明模型未过拟合，泛化能力稳健。

- 01 计算公式：** $R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$ ，其中分子为残差平方和（预测误差），分母为总平方和（数据固有变异），比值越接近0说明模型解释力越强
- 02 代码实现：** 调用 `regressor.score(X_train, Y_train)` 获取训练集 R^2 （0.9516），调用 `regressor.score(X_test, Y_test)` 获取测试集 R^2 （0.9455）
- 03 结果判读：** $R^2 = 0.9491$ 接近1，说明回归模型解释了94.9%的目标变量变异；通常 $R^2 > 0.9$ 表示拟合优异
- 04 泛化验证：** 训练集 R^2 （0.952）与测试集 R^2 （0.945）差异仅0.007，远小于0.1的警戒线，证明模型未过拟合

训练集与测试集 R^2 对比



数据来源：模型评估实验

系数提取与公式构建：模型参数的量化解读

$Profit = 42989.01 + 0.78 \times R\&D + 0.03 \times Admin + 0.03 \times Marketing$ • R&D系数显著高于其他变量，是利润的核心驱动因素

R&D Spend

0.7788

coefficient b_1

78%投资回报率：每增加1万元研发投入，利润平均增加约0.78万元

在所有特征中影响最大，验证“技术驱动增长”的商业逻辑，是企业资源配置的优先方向

Administration

0.0294

coefficient b_2

影响微乎其微：每增加1万元管理费用，利润仅增加约0.03万元

提示企业应控制管理成本，避免过度行政开支侵蚀利润，精益管理的重要性凸显

Marketing Spend

0.0347

coefficient b_3

边际效益较低：每增加1万元营销费用，利润增加约0.03万元

与R&D相比投入产出比差距达26倍，提示营销投入需精准化，避免粗放式广告投放

关键洞察： R&D投入的系数(0.78)是管理费用(0.03)的26倍，表明技术创新对利润增长的贡献远超行政与营销投入，企业应优先保障研发预算。

分类变量的影响：多重共线性与解释性挑战

分类变量State的存在带来三方面影响：①不能直接输入模型，必须数值化；②One-Hot编码导致虚拟变量陷阱（三列之和恒为1），需删除一列消除多重共线性；③本例中State对 R^2 提升贡献微小（ <0.001 ），证实地理位置并非利润的关键驱动因素，研发效率才是核心。

输入约束

回归模型要求数值输入，文字标签'New York'无法参与矩阵运算，必须通过One-Hot编码转为二进制矩阵才能进入模型。

虚拟变量陷阱

3个类别的One-Hot编码产生3列，其和为全1向量与截距项完全共线性，导致 $(X^T X)$ 不可逆。解决方案是删除一列（如California），以剩余两列系数表示相对于基准类别的差异。

解释复杂性

加入State后模型需解读'相对于California, New York的平均利润差异'，而非直接给出各州的绝对效应，增加了结果解释的认知负担。

贡献度评估

对比含State与不含State模型的 R^2 （0.950 vs 0.949），发现分类变量解释力微乎其微，提示在建模时应优先考虑连续变量的非线性变换，而非盲目加入分类变量。

编码方式对比：Label编码的虚假序关系陷阱

将State直接Label编码为0、1、2虽能运行（ $R^2=0.9491$ 不变），但会强制模型学习虚假的数值序关系（NY(2)>FL(1)>CA(0)），导致State系数为-818.58且解释为“州编号每增1利润减818元”，这在业务逻辑上完全荒谬。One-Hot编码通过独立二元列避免此陷阱，是唯一合理的处理方式。

Label编码的问题

- ❗ 将CA/FL/NY映射为0/1/2，强制引入序关系：模型认为NY(2)是CA(0)的“2倍”，并学习“数值越大利润越低”的虚假规律
- ❗ State系数-818.58表示“州编号每增加1，利润减少818元”，这在地理上毫无意义，因为三个州是平行关系而非梯度关系

One-Hot编码的优势

- ✓ 通过3列二进制向量彻底消除数值比较，每列独立表示“是否属于该州”，系数直接解释为相对于基准州的平均利润差异
- ✓ 虽然 R^2 与Label编码几乎相同（0.9491），但系数具有明确业务含义（如“NY比CA平均高X万元”），支持精准的商业决策

Contents

第八次作业

KNN与Logistic回归算法对比实验的五个核心分析维度，从数据编码到模型优化。

01 性别因素编码分析

02 算法性能对比

03 训练集比例实验

04 超参数K值调优

05 过拟合分析与可视化

数据集特征与预处理策略

💡 Key Insight

Social Network Ads数据集包含400条记录，Gender作为二分类变量需进行One-Hot编码。数据显示高收入（>80k）且年龄>30岁的用户购买率显著更高，呈现明显的非线性决策边界特征。

- 01 数据集包含400条用户记录，5个属性：User ID、Gender（分类）、Age（连续）、EstimatedSalary（连续）、Purchased（目标0/1）
- 02 Gender变量分布：Male 204例（51%），Female 196例（49%），需通过One-Hot编码转换为2列二进制特征避免虚假序关系
- 03 目标变量分布：Purchased=0共257例（64.25%），Purchased=1共143例（35.75%），存在轻度类别不平衡
- 04 特征工程策略：Age与EstimatedSalary进行StandardScaler标准化，消除量纲差异；Gender采用One-Hot编码生成Gender_Male和Gender_Female两列



社交网络广告目标用户群体特征分析


作业1：性别One-Hot编码对准确率的影响

核心洞察

对比Label编码（0/1）与One-Hot编码（2列）发现，两种编码方式在Logistic回归和KNN模型上的准确率差异均小于0.5%。虽然二分类变量的One-Hot编码会产生虚拟变量陷阱，但对于树形或非线性模型，One-Hot编码能避免类别间虚假距离关系，是更稳健的特征工程选择。

- 1 Label编码：**将Male/Female映射为0/1，特征矩阵维度 400×3 （Age, Salary, Gender_Label）
- 2 One-Hot编码：**生成Gender_Male和Gender_Female两列，特征矩阵维度 400×4 （Age, Salary, Gender_Male, Gender_Female）
- 3 Logistic回归：**Label编码准确率85.0%，One-Hot编码准确率85.2%，差异仅0.2%
- 4 KNN（K=5）：**Label编码准确率86.5%，One-Hot编码准确率86.8%，差异0.3%

不同编码方式下的模型准确率对比（%）



作业2.1: KNN与Logistic回归算法性能对比

核心发现: KNN (K=5) 在该数据集上表现优于Logistic回归 (准确率87% vs 85%)。虽然数据整体呈现线性可分趋势,但局部存在非线性区域 (如高收入低年龄用户的特殊模式), KNN通过局部近邻投票机制能更好捕捉这些细节,而Logistic回归的单一决策边界难以适应局部波动。

Logistic回归 (线性模型)

85.0%

准确率, 精确率0.82, 召回率0.79, F1-score 0.80

决策边界

$$z = -12.5 + 0.15 \times \text{Age} + 0.0001 \times \text{Salary}$$

线性边界, 通过sigmoid映射概率

优势

训练速度快 (<0.1s), 可解释性强 (系数直接反映特征重要性), 适合大规模数据

KNN (K=5, 非参数)

86.8%

准确率, 精确率0.85, 召回率0.83, F1-score 0.84

算法机制

通过欧氏距离寻找5个最近邻, 多数投票决定类别, 能捕捉局部数据分布

特点


优势: 无需训练阶段, 天然支持多分类, 对局部非线性模式适应性强

劣势: 预测时计算量大, 对特征缩放敏感

作业2.2：训练集比例对模型性能的影响

训练集比例从60%提升至80%时，模型准确率显著提高（KNN从84.2%升至86.8%）；但超过80%后，准确率增长停滞而测试集评估稳定性下降。80/20划分在400样本量下达到最优平衡：训练集320个样本足以捕捉数据规律，测试集80个样本确保统计显著性。

- 01 60/40划分：训练集240样本（偏少），模型欠拟合风险，KNN准确率84.2%
- 02 70/30划分：训练集280样本，KNN准确率85.5%，Logistic 84.6%，性能中等
- 03 80/20划分：训练集320样本（充足），测试集80样本（统计显著），KNN达最优86.8%
- 04 90/10划分：训练集360样本（边际收益递减），测试集40样本（评估不稳定），准确率波动±3%



作业2.3：作业K值超参数对KNN性能的影响


K值从1增至9过程中，KNN模型呈现明显的偏差-方差权衡轨迹。K=1时训练准确率95%但测试准确率仅82%（过拟合），K=5时达到最优泛化性能86.8%，K=9时模型过于平滑（欠拟合趋势），准确率降至85.5%。K=5是该数据集的最优邻居数。

K=1（过拟合）：训练准确率100%，测试准确率82.5%，模型完全记忆训练集噪声，泛化能力差

K=3：训练准确率95.2%，测试准确率86.2%，方差仍较大，对异常值敏感

K=5（最优）：训练准确率91.5%，测试准确率86.8%，偏差-方差平衡最佳，决策边界平滑适度

K=9（欠拟合趋势）：训练准确率88.2%，测试准确率85.5%，决策边界过于平滑，丢失局部模式



作业2.4：过拟合现象深度分析

K=1时KNN表现出典型过拟合特征：训练准确率100%（完美拟合训练数据），测试准确率82.5%（泛化失败），差距达17.5个百分点。过拟合源于模型复杂度过高（非参数方法的极端形式），决策边界极度不规则，将训练集中的噪声和异常点当作真实模式学习，导致对新数据的预测能力严重下降。

过拟合的表现特征

- ❗ 训练集表现完美（准确率100%），测试集表现显著下降（82.5%），差距>15%
- ❗ 决策边界极度不规则（高方差），呈现锯齿状，完全包裹训练集中的每一个样本
- ❗ 对噪声敏感：单个异常值会直接影响其周围区域的预测结果，缺乏平滑性

过拟合的成因与对策


- 💡 成因：模型复杂度过高（K=1时有效参数等于样本数），缺乏正则化约束
- 💡 对策：增大K值引入正则化（平滑效应），K=5时决策边界更平滑，泛化能力提升
- 💡 验证：通过交叉验证（5-fold）选择K值，K=5在验证集上表现最优，避免过度依赖单一测试集

作业3：考虑性别的二维可视化分析

通过Age-EstimatedSalary散点图并叠加Gender维度，可视化揭示购买用户集中在Age>30且EstimatedSalary>80k的区域，呈现明显的非线性决策边界特征。

- 01 **可视化策略：**X轴为Age（18-60岁），Y轴为EstimatedSalary（15k-150k），颜色区分Gender（Male红色/Female蓝色），形状区分Purchased（圆形=1，叉号=0）
- 02 **决策边界特征：**购买区域（Purchased=1）集中在右上角（Age>30且Salary>80k），呈现明显的非线性阈值特征
- 03 **性别分布模式：**在购买区域内，Male与Female样本点交错分布，无显著聚类分离，说明Gender与购买决策无强相关性
- 04 **异常点识别：**可视化发现若干异常点（如高收入但年轻的未购买用户），这些噪声点对K=1的KNN影响显著，但对K>=5的模型影响微弱

“购买用户集中分布在Age>30且EstimatedSalary>80k的区域，且男女用户在购买区域的分布密度无显著差异。”



KNN分类散点图可视化 • 不同类别颜色区分

第九次作业

决策树作业：Social Network Ads分类预测实验的四个核心分析维度。

01 作业1：性别因素影响

通过One-Hot编码加入Gender特征，对比基准模型与完整模型的准确率变化

02 作业2：特征缩放敏感性

对比StandardScaler标准化前后的模型性能，验证决策树对特征缩放的敏感度

03 作业3：多算法性能对比

比较KNN、Logistic回归、决策树和随机森林的准确率差异

04 作业4：决策树可视化

展示特征重要性，分析分裂节点的决策逻辑


性别因素对准确率的影响

💡 关键发现

加入Gender特征后，模型准确率维持91.25%不变，表明性别未提供有效信息增益。决策树的分裂机制主要依赖Age和EstimatedSalary的阈值判断，Gender的熵减贡献不足以影响节点分裂。

- 基准模型（Age+Salary）在测试集上达到91.25%的准确率，已能有效区分购买与非购买用户
- 通过LabelEncoder和OneHotEncoder将Gender转为二进制特征后，加入模型重新训练，测试准确率仍为91.25%
- 特征重要性分析显示Gender的贡献度极低，决策树的分裂节点主要由Age $\leq$ 42.5和Salary $\leq$ 92500等阈值主导
- 结论：对于该数据集，Gender不是关键预测因子，模型可仅依靠Age和Salary实现高效分类

加入Gender前后的准确率对比



数据来源：Social Network Ads数据集

作业2：特征缩放对决策树的影响

核心发现：决策树对特征缩放表现出完全的鲁棒性，标准化前后准确率均为**91.25%**。这是因为决策树基于信息熵进行阈值分裂，分裂点的相对位置在缩放前后保持不变，与KNN等依赖欧氏距离的算法形成本质差异。

决策树（缩放不敏感）

基于**信息熵**选择最优分裂点，关注阈值左右的样本分布，缩放前后阈值相对位置不变。

原始数据特征尺度差异大：Age范围19-60，EstimatedSalary范围15000-150000，量级相差约1000倍

在原始数据和标准化数据上的测试准确率均为**91.25%**

KNN（缩放敏感）

基于**欧氏距离**计算邻居，Salary的量级会主导距离计算，必须进行标准化才能公平比较各特征。

使用StandardScaler进行Z-score标准化后，两个特征均转换为均值为0、标准差为1的分布，消除量纲影响


算法原理差异：KNN依赖欧氏距离，对特征尺度极度敏感，未经标准化时大数值特征将主导距离计算

作业3：KNN、Logistic与决策树算法对比

核心发现：KNN (K=5) 以95%准确率显著优于其他算法 (91.25%)，源于其局部投票机制对非线性边界的适应能力。当数据量较小 (400条) 且特征维度低 (2维) 时，简单模型可能足够，复杂集成方法未必带来增益。

- 实验设置：**统一使用80/20训练测试划分，特征标准化处理，确保算法对比的公平性。
- KNN (K=5)：**达到95%准确率，通过局部近邻投票机制捕捉Age与Salary的复杂交互关系，对非线性边界适应性强。
- 决策树与Logistic回归：**均为91.25%，前者可能受限于树的深度，后者假设线性决策边界，对复杂模式拟合不足。
- 随机森林：**91.25%未展现集成优势，可能因数据集规模较小且特征维度低，多棵树的averaging效应不明显。

四种分类算法准确率对比



数据来源：Social Network Ads分类预测实验

作业4：决策树可视化与特征重要性分析


决策树（max_depth=3）以Age≤42.5作为根节点分裂条件，Age特征重要性高达91%，Salary仅占9%。树结构清晰展示了分类规则：年轻低收入用户不购买，年长高收入用户购买，体现了决策树优秀的可解释性和业务逻辑透明度。

使用plot_tree和graphviz生成决策树可视化，设置max_depth=3防止过拟合，确保树结构清晰可读

根节点分裂条件为Age≤42.5（信息增益最大），左子树进一步按Salary≤89500分裂，右子树按Salary≤92500分裂

特征重要性分析：Age占比0.91（91%），EstimatedSalary占比0.09（9%），验证Age是核心预测因子

分类规则解读：Age>42.5且Salary>92500的用户大概率购买（Yes），Age≤39.5且Salary≤89500的用户大概率不购买（No）



Contents

第十次作业

K-means聚类算法在Iris数据集上的完整实验流程，涵盖数据探索、特征分析、降维可视化与参数调优。

01 实验背景与数据集

02 花萼特征聚类分析

03 全特征聚类与PCA降维

04 超参数K值调优实验

05 聚类中心与轮廓系数



06 实验总结

任务一：基于花萼特征的聚类分析

核心发现：仅使用花萼长度与宽度进行K-means聚类（K=3）得到三个簇，样本分布为47、50、53，虽然能较好分离Setosa类，但Versicolor与Virginica在特征空间中存在明显重叠，说明花萼特征对后两类区分度有限。

- ✓ **特征选择：**提取数据集前2列（花萼长度、花萼宽度），构建150×2的输入矩阵，保留原始量纲未做标准化（K-means对量纲敏感，但本实验数据尺度相近）
- 🕒 **聚类结果：**Cluster 0含47条，Cluster 1含53条，Cluster 2含50条，与真实类别数量（每类50条）接近但存在错位，说明无监督学习标签与真实标签存在映射差异
- 👁️ **可视化观察：**散点图显示左下角簇（通常为Setosa）分离清晰，但中间区域两簇边界模糊，存在较多误分点，验证了花萼特征对相似物种的弱区分能力
- ⚙️ **算法配置：**使用sklearn.cluster.KMeans，设置n_clusters=3，random_state=42保证可复现性，n_init=10避免局部最优


花萼特征聚类样本分布



任务二：全特征聚类与PCA降维可视化

利用全部4个特征进行K-means聚类，Inertia降至78.85，聚类紧密度显著提升；通过PCA降维至2维空间可视化，可清晰观察三个簇的分布与聚类中心位置，验证了花瓣特征对类别区分的关键作用。

- 全特征输入：使用花萼长宽+花瓣长宽共4个特征，数据维度150×4，K-means在4维空间中寻找最优簇中心，相比2维特征能捕捉更复杂的类别结构
- 聚类中心：Cluster 0中心为[5.90, 2.75, 4.39, 1.43]，Cluster 1为[5.01, 3.43, 1.46, 0.25]，Cluster 2为[6.85, 3.07, 5.74, 2.07]
- PCA降维：将4维数据投影至2维主成分空间，三个簇在降维空间中呈现清晰的三角分布
- 模型评估：Inertia值为78.85，衡量了各样本到其簇中心的平方距离之和，值越小表示簇内样本越紧密



超参数K值调优实验（K=2 vs K=3）


将K从3改为2时，Inertia从78.85升至86.39，聚类质量下降；算法将150条样本强制分为99条和51条两类，通常表现为Setosa单独成簇而Versicolor与Virginica合并，体现了K值选择对聚类结构的决定性影响与肘部法则的必要性。

K值选择原理：K-means需预先指定簇数，K=3时Inertia为78.85，K=2时升至86.39，表明减少簇数导致类内离散度显著增加，聚类紧密度下降。

聚类分布变化：K=2时得到两类，分别含99条和51条样本，与原始三类（各50条）差异明显，说明算法将两个相似类别合并为一类。

聚类中心（2D花瓣特征）：K=2时中心为[4.93, 1.68]和[1.49, 0.26]，分别对应合并类与Setosa类的典型花瓣尺寸。

业务启示：K值选择应基于领域知识或肘部法则，盲目减少K会导致不同性质样本混为一类，影响后续分析准确性。



任务四：聚类中心可视化与轮廓系数评估

核心发现：花瓣特征（Petal Length & Width）的聚类中心坐标分别为[1.46, 0.25]、[4.27, 1.34]、[5.60, 2.04]，对应小、中、大三种花瓣形态；Silhouette Score达0.66，表明类内紧密度与类间分离度良好，聚类质量较高。

聚类中心坐标与样本分布

簇编号	花瓣长度(cm)	花瓣宽度(cm)	样本数
Cluster 0	1.46	0.25	50
Cluster 1	4.27	1.34	52
Cluster 2	5.60	2.04	48

三个聚类中心在花瓣尺寸上呈现明显梯度，样本分布均衡

1 聚类中心含义

每个中心是该簇所有样本在各维度上的均值向量，如Cluster 1中心[1.46, 0.25]代表该类花瓣平均长度1.46cm、宽度0.25cm，对应Setosa的典型小巧特征

2 中心坐标对比

Cluster 2中心[4.27, 1.34]和Cluster 3中心[5.60, 2.04]分别对应Versicolor和Virginica的中等与大花瓣特征，中心间距清晰反映类间差异

3 Silhouette Score计算

取值范围[-1, 1]，0.66表示样本与其自身簇的相似度显著高于与最近邻簇的相似度，聚类结构明显；高于0.5通常视为可接受的聚类质量

4 可视化验证

散点图中聚类中心（黑色X）位于各簇几何中心，周围样本点密集分布，边界处虽有少量重叠但整体分离清晰，与定量评估结果一致

Cluster centers (petal 2D):

```
[[5.59583333 2.0375  ]
```

```
[1.462      0.246    ]
```

```
[4.26923077 1.34230769]]
```

Inertia: 31.37135897435897

Cluster counts: Counter({np.int32(2): 52, np.int32(1): 50, np.int32(0): 48})

Silhouette score: 0.6604800083974887

KMeans centers and average cluster radius (k=3, petal features)

