

Contents

第一次作业

大数据与数据挖掘核心概念体系的知识脉络梳理，涵盖数据基础、预处理技术、降维学习方法及挖掘评估四大核心模块。

01 数据基础认知

02 数据预处理技术

03 降维与学习方法

04 挖掘与评估

数据类型体系：结构化的连续统

01

结构化数据

具有预定义的二维表结构，字段长度固定且数据类型明确，存储于关系型数据库（RDBMS）中，如员工信息表（工号、姓名、性别）和交易记录

支持SQL查询和ACID事务特性，是传统企业信息系统的主流数据形态，占企业数据总量约20%

02

半结构化数据

具有自描述性标记但无严格模式约束，字段可嵌套且长度可变，典型格式包括XML、JSON、日志文件和NoSQL数据库记录

介于结构化与非结构化之间，兼具灵活性和可读性，是Web服务和大数据平台间数据交换的标准格式，占数据总量约10%

03

非结构化数据

无预定义数据模型，字段长度和内容格式高度自由，包括文本文档、图像、音频、视频、电子邮件和社交媒体内容

需要特殊技术（NLP、CV）提取特征才能分析，存储成本高但信息密度大，占企业数据总量约80%且增速最快

数据预处理：从脏数据到数据资产

原始数据中存在缺失值、异常值、重复记录和格式不一致等问题，系统化的预处理流程可将数据质量提升40%以上。ETL集成解决跨系统数据孤岛，特征工程决定模型性能上限，这一阶段消耗了数据科学家60%以上的工作时间，是挖掘项目成功的关键基础。

步骤一

数据清洗

缺失值处理：采用均值/中位数填充、回归插值或KNN插补，避免简单删除导致样本偏差

异常值检测：通过箱线图IQR法则或 3σ 原则识别，结合业务知识判断是噪声还是真实极端值

重复数据删除：基于主键或模糊匹配算法去重，确保记录唯一性，避免分析结果失真

步骤二

数据集成

多源数据合并：使用ETL工具从关系数据库、日志系统、API接口抽取数据，解决异构数据源孤岛问题

模式对齐：统一不同系统的字段命名、数据类型和编码格式（如UTF-8与GBK转换），建立主数据管理（MDM）

实体识别：通过共有键（如用户ID）关联不同表，处理数据值冲突和语义歧义，构建统一数据视图

步骤三

数据转换

特征工程：基于业务理解构造衍生变量（如从生日计算年龄、从消费金额计算RFM价值），提升模型表现力

数据编码：将分类变量转为独热编码（One-Hot）或标签编码（Label Encoding），使算法能处理类别信息

格式标准化：统一日期格式、货币单位、度量衡，进行数据类型转换和离散化分箱，适配分析工具要求

数据缩放与特征构造

不同量纲的特征（如年龄20-80岁与收入5000-50000元）需要统一尺度才能公平参与模型计算。标准化（Z-score）适用于正态分布且异常值较多的场景，而归一化（Min-Max）适合有明确边界的均匀分布数据。衍生变量通过业务逻辑从原始特征中提取深层信息，是提升模型性能的关键手段。

METHOD 01

标准化（Z-score）

通过减去均值并除以标准差，将数据转换为均值为0、标准差为1的分布，保留原始分布形状且对异常值鲁棒，适用于SVM、逻辑回归等基于距离的算法。

METHOD 02

归一化（Min-Max）

通过线性变换将数据映射至[0, 1]区间，严格受极值影响，适合神经网络等需要 bounded input 的算法，当数据中存在离群点时应谨慎使用。

METHOD 03

衍生变量构造

基于业务规则从原始特征计算新特征，如从“出生日期”计算“年龄”、从“消费金额/频次”计算“客单价”和“用户价值分层（RFM）”，这些变量往往比原始特征具有更强的业务解释力和预测力。

数据降维：主成分分析（PCA）

核心洞察：高维数据存在冗余特征和噪声，PCA通过线性变换将原始特征投影到方差最大的正交方向（主成分），在保留最大信息量的同时降低维度。通过选择累计方差贡献率（如95%）的主成分，可将计算复杂度降低70%以上，同时去除噪声干扰。

01 核心原理

基于协方差矩阵的特征值分解，寻找数据方差最大的投影方向（主成分），确保降维后数据重构误差最小。第一主成分捕获最大方差，第二主成分与第一正交且捕获剩余方差最大。

02 计算流程

数据中心化（去均值）→ 计算协方差矩阵 → 特征值分解 → 选择前k个最大特征值对应的特征向量 → 将原始数据投影到k维主成分空间，实现从n维到k维的线性映射。

03 应用价值

用于高维数据可视化（降至2D/3D）、图像压缩（保留关键特征）、噪声过滤（小特征值对应噪声方向）和多重共线性消除，提升模型训练效率并防止过拟合。

非线性降维与可视化：t-SNE

相比PCA的线性假设，t-SNE通过在高维和低维空间分别构建概率分布（高斯分布与t分布），最小化两分布间的KL散度，保留数据的局部邻域结构。这种非线性流形学习方法能揭示高维数据中的簇状结构，是词嵌入可视化、单细胞RNA测序分析和图像特征探索的首选工具，但计算复杂度高（ $O(n^2)$ ）且结果具随机性。

→ 概率映射机制

在高维空间用高斯分布计算点间相似度概率，在低维空间用t分布（重尾特性）计算相似度，通过梯度下降最小化两分布的KL散度，保护局部结构同时防止低维空间点过度拥挤。

→ 困惑度参数

平衡局部与全局结构的超参数（通常设5-50），可理解为有效邻居数量的期望，影响簇的分离度和可视化效果，需多次调参获得最佳投影。

→ 应用场景与局限

广泛用于词向量（Word2Vec/GloVe）可视化、单细胞聚类、MNIST手写数字降维展示；但计算复杂度高（不适合大规模数据），结果具随机种子依赖性，且无法直接投影新样本（需重新运行算法）。

学习范式：监督与无监督

两类学习方法的本质区别在于训练数据是否带有标签。监督学习依赖标注数据建立输入到输出的映射，适用于预测任务；无监督学习从无标签数据中发现隐藏结构，适用于探索性分析。选择取决于业务目标与数据获取成本。

✓ 监督学习 Supervised

☑ 任务定义

利用带标签的训练数据 (X, Y) 学习映射函数 f ，使 $f(X) \approx Y$ 。分为分类（离散标签如 0/1）和回归（连续数值如价格）两类任务。

💻 典型算法

决策树（可解释性强）、支持向量机SVM（高维有效）、朴素贝叶斯（概率基础）、神经网络（深度学习基础），以及随机森林和梯度提升树等集成方法。

⚠ 关键挑战

过拟合（训练集表现好但泛化差）风险，需通过正则化、交叉验证和早停技术控制模型复杂度，确保在新数据上的预测性能。

❓ 无监督学习 Unsupervised

☑ 任务定义

仅基于输入数据 X （无标签）发现内在结构、模式或分组。包括聚类（相似度分组）、降维（维度压缩）、关联规则（项集共现）和密度估计。

💻 典型算法

K-means聚类（划分式）、层次聚类（树状结构）、DBSCAN（基于密度）、高斯混合模型（概率聚类）、PCA/t-SNE（降维）、Apriori/FP-Growth（频繁项挖掘）。

📊 评估特点

缺乏真实标签作为参照，需用轮廓系数、Calinski-Harabasz指数等内部指标，或结合下游任务效果间接评估，结果解释性强依赖业务理解。

数据挖掘核心任务（一）：分类与聚类

分类与聚类是数据挖掘中最基础的模式发现技术，两者本质区别在于是否依赖预定义类别标签。分类通过训练带有标签的历史数据构建决策边界，用于预测新样本的类别归属；聚类通过度量样本间相似度发现内在分组结构，用于客户细分、异常检测和图像分割。前者是预测性分析，后者是描述性分析，常组合使用形成完整解决方案。

01 分类技术

基于标注数据训练分类器，构建输入空间到离散类别的映射函数。常用算法包括决策树（ID3/C4.5/CART，生成可解释规则）、支持向量机SVM（最大化间隔边界）、K近邻KNN（惰性学习）、朴素贝叶斯（概率推理）和神经网络（深度学习）。评估指标包括准确率、精确率、召回率、F1-score和ROC-AUC。

02 聚类技术

基于无标签数据的相似度度量（欧氏距离、余弦相似度）发现内在分组。K-means算法通过迭代优化簇中心与样本的距离平方和；层次聚类构建嵌套簇树状图（树状图）；DBSCAN基于密度识别核心点与噪声，适用于发现任意形状簇和异常值检测。

03 应用对比与协同

分类适用于信用评级（违约/正常）、疾病诊断（阳性/阴性）等预测场景；聚类适用于市场细分、社交网络社区发现、图像分割等探索场景。实践中常先用聚类发现潜在类别，再标注样本训练分类器实现预测，形成“先探索后预测”的完整分析流程。

数据挖掘核心任务（二）：关联与回归

关联规则挖掘揭示项集间的条件共现关系（如购物篮中的互补商品），通过支持度-置信度-提升度三元组评估规则强度；回归分析建立自变量与因变量间的量化函数关系，用于连续值预测和因果推断。前者驱动推荐系统和货架优化，后者支撑销量预测和风险定价，两者共同构成商业智能的量化决策基础。

关联规则挖掘

从交易数据中发现项集间的有趣关联（形如“若A则B”），Apriori算法利用频繁项集的子集必频繁的先验性质进行剪枝，FP-Growth通过构建频繁模式树压缩扫描次数；核心指标包括支持度（项集出现频率）、置信度（条件概率 $P(B|A)$ ）和提升度（实际置信度与独立期望的比值， >1 表示正相关）。

回归分析

建立输入变量与连续目标变量间的函数关系，线性回归假设线性关系并最小化残差平方和（OLS），多元回归处理多自变量，多项式回归拟合非线性关系，岭回归和Lasso通过正则化解决多重共线性和过拟合；模型评估用 R^2 （解释方差比例）、MSE（均方误差）和MAE（平均绝对误差）。

商业应用场景

关联规则用于购物篮分析（商品捆绑销售）、推荐系统（协同过滤基础）和医疗诊断（症状组合模式）；回归用于销售预测、房价评估、风险评分（信用评分卡）和广告点击率预估，提供可量化的决策依据。

模式评估与验证体系

模型在训练集上的表现不能代表其泛化能力，科学的评估体系通过交叉验证充分利用有限数据，通过多元指标全面衡量性能，核心目标是检测过拟合与欠拟合，指导超参数调优和模型选择。

交叉验证技术

K折验证：将数据划分为K个子集，轮流用K-1个子集训练、1个子集验证，重复K次取平均性能，减少随机划分的方差。

留一法 (LOO)：K=N的极端情况，适用于小样本；分层抽样确保每折类别比例与总体一致。

分类模型评估

混淆矩阵指标：精确率 $P=TP/(TP+FP)$ 、召回率 $R=TP/(TP+FN)$ 、 $F1=2PR/(P+R)$ 平衡指标。

ROC与AUC：ROC曲线绘制真正例率vs假正例率，AUC衡量排序能力（0.5为随机，1为完美），PR曲线适用于类别不平衡场景。

回归与泛化评估

回归指标：MSE对大误差敏感，RMSE保持量纲一致，MAE更鲁棒； $R^2=1-SS_{res}/SS_{tot}$ 表示解释方差比例。

诊断方法：通过验证集曲线诊断过拟合（间隔大）与欠拟合（两者均高），指导正则化强度和模型复杂度选择。