

Contents

第二次作业

数据回归方法的理论体系与建模实践，涵盖从基础一元线性回归到复杂Logistic回归的完整技术路径。

01 回归方法概述

02 一元线性回归

03 多元线性回归

04 Logistic回归

05 对比与应用

数据回归方法

核心洞察：回归方法是处理变量间相关关系的数学方法，适用于无法建立精确机理模型的复杂系统。通过标准化的五大步骤（收集数据、选定模型、比较筛选、适用性判断、预测解释），回归分析能够从观测数据中提炼量化规律，是数据挖掘领域应用最广泛的基础技术之一。

01 核心定义

回归方法用于处理变量间的相关关系（非确定性函数关系），通过数学模型拟合观测数据，揭示自变量对因变量的影响规律。

02 适用场景

当客观事物内部规律复杂、人类认知受限无法建立机理模型时，借助统计方法从数据中学习规律，如年龄与血压的关系分析。

03 五大标准步骤

收集因变量与自变量数据 → 选定数学模型并估计参数（如最小二乘法） → 利用统计方法比较不同模型 → 判断模型对当前数据的适用性 → 利用模型进行预测或现象解释。

一元线性回归：模型与估计

一元线性回归通过 $Y = \beta_0 + \beta_1 x + \varepsilon$ 模型刻画单一自变量与因变量的线性关系，采用最小二乘法（OLS）估计参数，使残差平方和最小化。模型质量通过决定系数 R^2 、剩余标准差 s 和 F 统计量三维指标综合评估。

数学模型

$$Y = \beta_0 + \beta_1 x + \varepsilon$$

Y 为随机因变量， x 为非随机自变量， β_0 为截距， β_1 为斜率， ε 为随机误差项且满足 $E(\varepsilon)=0$ 、 $Var(\varepsilon)=\sigma^2$ 。

参数估计

最小二乘法原理

通过最小化残差平方和 $Q = \sum (y_i - \hat{y}_i)^2$ 求解参数，估计公式为 $\hat{\beta}_1 = L_{xy}/L_{xx}$ ， $\hat{\beta}_0 = \bar{y} - \bar{x}\hat{\beta}_1$ ，其中 $L_{xx} = \sum (x_i - \bar{x})^2$ ， $L_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y})$ 。

模型评价

$R^2 = 1 - SSE/SST$ ，值越接近1表示拟合优度越好

剩余标准差 $s = \sqrt{SSE/(n-2)}$ ，反映预测误差大小

F 统计量 $= (SSR/1)/(SSE/(n-2))$ ，用于检验线性关系显著性

多元线性回归：多变量建模与矩阵表达

多元线性回归扩展至多个自变量情形，采用矩阵形式 $Y=X\beta+\varepsilon$ 紧凑表达 n 个样本、 p 个特征的复杂关系。设计矩阵 X 包含全1列（截距项）与 p 个自变量列，参数向量 β 包含 $p+1$ 个待估系数，矩阵运算使高维数据的高效处理成为可能，是处理多因素问题的标准工具。

数学模型

标量形式：

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon$$

描述因变量受 p 个非随机因素与随机误差共同影响

矩阵形式：

$$Y = X\beta + \varepsilon$$

其中 Y 为 $n \times 1$ 观测向量， X 为 $n \times (p+1)$ 设计矩阵， β 为 $(p+1) \times 1$ 参数向量， ε 为 $n \times 1$ 误差向量

建模流程

01

变量选择与散点图初判

分析确定因变量与解释变量，绘制散点图观察线性趋势，如学者年薪与论文质量、研究时间的关系

02

参数估计与异常分析

输入数据计算参数估计，分析数据中的异常点，进行显著性检验与残差诊断（正态性、异方差检验）

Logistic回归：分类问题的概率建模

Logistic回归专门处理因变量为二分类（0/1）的定性问题，通过Sigmoid函数将线性组合映射为(0, 1)区间的概率值。核心技巧是Logit变换，将非线性概率估计转化为线性形式，既保持了线性模型的可解释性，又满足了概率输出的范围约束。

模型形式

$p(Y=1 | x_1, \dots, x_k) = \exp(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k) / (1 + \exp(\dots))$ ，输出为事件发生的概率，取值范围(0, 1)

Logit变换

对 $odds = p/(1-p)$ 取自然对数得到 $\ln(p/(1-p)) = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k$ ，将S型曲线关系转化为线性关系

参数估计

采用极大似然估计（MLE）而非最小二乘法，通过最大化似然函数求解参数，适用于定性因变量的概率建模

模型对比：线性回归 vs Logistic回归

01 • 因变量与目标

线性回归

因变量为**定量变量**（连续数值，如收入、温度），预测目标是具体数值大小

Logistic回归

因变量为**定性变量**（二分类0/1，如成功/失败），预测目标是事件发生的概率，进而实现分类

02 • 函数与变换

线性回归

采用直线或超平面 $Y = \beta X$ ，假设误差服从正态分布，输出范围为 $(-\infty, +\infty)$

Logistic回归

采用S型Sigmoid曲线，通过Logit变换 $\ln(p/(1-p))$ 将概率映射为线性形式，输出压缩至 $[0, 1]$

03 • 参数估计

线性回归

使用**最小二乘法**（OLS），最小化残差平方和 $\sum (y_i - \hat{y}_i)^2$ ，有解析解

Logistic回归

使用**极大似然估计**（MLE），最大化似然函数，通常需迭代算法求解，无解析解

核心洞察：线性回归与Logistic回归虽同属回归家族，但服务不同数据类型与预测目标。线性回归处理连续因变量，追求数值预测的精确性；Logistic回归处理分类因变量，通过概率映射实现类别判断。两者在误差假设、估计方法与评价指标上均存在本质差异。