

第三次作业

机器学习分类算法教学 • 第8章

01 分类方法概述

分类任务的基本概念与原理，训练集与测试集的划分策略

02 K-近邻算法

基于距离度量的惰性学习算法，银行客户购买意愿预测案例

03 朴素贝叶斯

基于贝叶斯定理的概率分类方法，文本分类与垃圾邮件过滤

04 神经网络与SVM

多层感知器与反向传播，支持向量机的最大间隔分类

05 决策树

基于信息增益的递归分割，ID3/C4.5/C5.0算法演进

06 评估与应用

精确率、召回率、F1-score与ROC曲线，分类选股法案例

分类方法概述

分类方法通过从标注数据中学习决策边界实现预测，核心在于平衡模型的拟合能力与泛化性能。训练集用于构建模型，测试集用于评估未知数据上的表现，这种划分策略确保了模型不仅在历史数据上表现良好，更能适应新样本。

分类的概念

- 分类是基于样本特征属性预测离散类别标签的 supervised 学习任务，输入为特征向量，输出为预定义类别标识，如将邮件标记为垃圾邮件或正常邮件
- 数据集划分为训练集与测试集，训练集用于学习模型参数，测试集用于评估泛化性能，两者严格分离以避免数据泄露

分类的原理

- 通过归纳学习从训练数据中提取决策规则或构建决策边界，形成从输入空间到类别空间的映射函数，用于描述数据分布规律
- 模型具备双重作用：描述性建模解释数据内在结构，预测性建模对新样本进行类别推断，两者共同支撑业务决策

常用方法概览

- 七大主流算法构成完整技术体系：K-近邻基于实例学习，朴素贝叶斯基于概率推理，神经网络模拟生物神经元，逻辑回归建立对数线性模型
- 判别分析利用统计距离分类，支持向量机追求最大间隔，决策树通过递归分割构建规则，各类方法在数据规模、特征类型、解释性需求上各有优势

K-近邻算法原理与实现

K-近邻算法通过局部邻域的相似性推断样本类别，无需显式训练过程，属于惰性学习。算法性能高度依赖距离度量方式与K值选择，欧氏距离适用于连续特征，而K值需通过交叉验证平衡偏差与方差，通常取奇数以避免投票平局。

核心原理

基于“物以类聚”的直观思想，通过计算测试样本与训练集各样本间的欧氏距离或曼哈顿距离，选取距离最近的K个样本构成邻域

采用多数表决机制确定最终类别，若K个邻居中某类占比最高，则预测样本属于该类；当K为偶数且平票时可随机选择或加权投票

算法步骤

第一步计算测试样本与所有训练样本的距离并排序，第二步选取距离最小的K个样本，第三步统计各类别在邻居中的出现频率

第四步将频率最高的类别赋给测试样本，整个过程无需显式训练模型，预测阶段计算开销大但实现简单直观

银行客户案例

使用16维特征预测客户是否购买理财产品，包含年龄、工作类别、婚姻状况、教育水平、存款余额、联系方式等数值与分类变量

通过MATLAB的cvpartition函数划分训练集与测试集，利用categorical函数处理离散变量，最终得到测试集上88.8%的准确率和11.2%的购买意愿识别率

朴素贝叶斯分类

基于概率推理框架，利用贝叶斯定理结合先验概率与似然函数计算后验概率。尽管特征条件独立的假设过于简化，但算法计算高效、对噪声鲁棒，特别适用于高维稀疏数据如文本分类。

算法原理

后验概率计算：基于贝叶斯定理计算给定特征下各类别的后验概率 $P(\text{类别}|\text{特征})$ ，选择后验概率最大的类别作为预测结果，实现最大后验概率决策。

条件独立性假设：核心假设是特征条件独立性，即各特征在类别确定时相互独立，将联合概率分解为各特征条件概率的乘积，大幅简化计算复杂度。

实现步骤

训练与应用流程：准备阶段计算各类别先验概率与特征条件概率，分类器训练阶段构建概率表，应用阶段对新样本计算各类别后验概率并选择最大值。

MATLAB实现：使用`NaiveBayes.fit`函数训练模型，通过`posteriors`方法获取概率分布，利用`confusionmat`函数评估分类效果，结合拉普拉斯平滑处理零概率问题。

算法特点

核心优势：算法简单高效，对孤立噪声点不敏感，小规模数据即可训练，适合多分类问题，特别适合文本分类与情感分析等高维稀疏数据场景。

主要局限：特征独立性假设往往不成立，特征间相关性会降低分类性能，对输入数据分布敏感，需要先验知识确定概率分布类型，类别特征缺失时效果受限。

神经网络分类

网络结构

多层前馈架构：输入层节点对应特征维度，隐藏层通过激活函数引入非线性变换，输出层给出类别概率或判别值。

感知器单元：接收加权输入与偏置项，经激活函数（sigmoid、ReLU）产生输出，多层结构可逼近任意复杂函数。

训练机制

双向传播算法：前向传播计算各层输出与损失值，反向传播计算梯度并按学习率更新权重，迭代优化直至收敛。

超参调优：学习率控制调整步长，过大导致震荡，过小收敛缓慢，通过验证集监控采用早停策略防止过拟合。

MATLAB实现

patternnet工具箱：设置隐藏层节点数、训练轮数、数据集划分比例，采用贝叶斯正则化算法提升训练稳定性。

性能评估：混淆矩阵显示测试集整体准确率约**90%**，需注意类别不平衡数据中少数类召回率。

核心洞察：神经网络通过多层非线性变换学习复杂模式，具备强大的函数逼近能力，适合图像识别、语音识别等复杂模式分类任务，但训练需要大量数据和计算资源，且模型可解释性较差。

支持向量机

支持向量机通过最大化分类间隔寻找最优超平面，间隔最大化确保模型泛化性能最优，仅依赖支持向量进行决策。核技巧将低维不可分问题映射到高维空间，线性核、多项式核、RBF核适应不同数据分布，是处理高维小样本数据的强大工具。



核心原理

最大间隔原理

在特征空间中寻找能将两类样本正确分开且间隔最大的超平面，间隔定义为两类最近样本到超平面的距离之和，最大化间隔等价于最小化结构风险

支持向量是位于间隔边界上的样本点，它们决定了超平面位置，移除非支持向量不会改变决策边界，体现了模型的稀疏性



关键技术

优化与核技巧

构建凸二次规划问题求解最优权重向量与偏置项，引入拉格朗日乘子处理约束条件，转化为对偶问题高效求解

核函数隐式计算高维特征空间内积，避免显式映射计算，线性核、多项式核、高斯RBF核分别适用于不同复杂度决策边界



性能评估

算法特点

泛化能力强，特别适合高维数据与小样本场景，最终模型仅依赖少量支持向量，存储与预测效率高

对核函数与参数敏感，大规模数据训练速度慢，缺失值处理困难，多分类需扩展策略，但分类精度通常优于传统方法

决策树分类

决策树通过递归分割构建层级决策规则，信息增益或基尼不纯度指导属性选择，ID3、C4.5、C5.0算法逐步优化分裂准则与剪枝策略。树形结构天然可解释，但易过拟合需通过预剪枝或后剪枝控制复杂度，适合特征可解释性要求高的场景。

构建原理

- 采用自顶向下的递归分割策略，选择最优属性作为节点分裂依据，将数据集划分为更纯的子集直至满足停止条件
- 信息增益衡量属性对类别不确定性的减少程度，基尼不纯度计算随机抽取样本被错分的概率，两者均用于选择最优分裂属性

算法演进

- ID3算法基于信息增益选择属性，但偏向取值多的特征；C4.5引入信息增益比修正偏向，处理连续属性与缺失值，采用后剪枝防止过拟合
- C5.0进一步优化效率与内存使用，支持boosting 集成，成为工业界常用决策树算法

剪枝策略

- 预剪枝在节点分裂前评估增益是否超过阈值，提前停止生长，计算高效但可能欠拟合；后剪枝先生成完整树再自底向上剪除不显著分支
- 通过验证集评估剪枝前后精度变化，保留泛化性能提升的分支，平衡模型复杂度与预测准确性，避免对训练数据的过度记忆

分类模型评估

分类模型评估需多维度综合考量，单一准确率无法反映类别不平衡下的真实性能。ROC曲线与AUC面积提供阈值无关的性能度量，混淆矩阵细化各类错误分布。

评估指标体系

准确率反映整体预测正确比例，但在类别不平衡时可能误导；精确率衡量预测为正例中真正正例比例，召回率衡量真正正例被正确识别比例

F1-score是精确率与召回率的调和平均，综合衡量模型性能；特异度反映负例识别能力，假正例率反映误报情况

ROC曲线分析

ROC曲线以假正例率为横轴、真正例率为纵轴，绘制不同阈值下的模型表现，曲线越靠近左上角性能越优，对角线代表随机猜测

AUC面积为曲线下方面积，取值0.5至1，越大表示模型区分能力越强，0.9以上优秀，0.8-0.9良好，0.7-0.8一般

六种分类算法正确率对比



SVM分类正确率最高达0.85，显著优于朴素贝叶斯的0.65

应用实例：分类选股法

01 / 案例背景

数据驱动预测框架

利用历史股票数据预测未来价格走势，将连续收益离散化为涨跌二分类问题，构建特征包括技术指标、基本面数据、市场情绪等。

数据集划分为训练集与测试集，训练集用于学习模式，测试集模拟真实交易环境，通过交叉验证确保模型稳健性。

02 / 实现方法

多算法对比验证

数据预处理包括特征标准化、缺失值处理、类别编码；模型训练阶段分别采用KNN、朴素贝叶斯、神经网络、SVM、决策树等算法。

通过混淆矩阵计算准确率、精确率、召回率，绘制ROC曲线比较AUC面积，选择泛化能力最强的模型作为最终选股策略。

03 / 结果分析

模型性能与实务考量

实验显示SVM与LDA在测试集上表现优异，AUC面积超过0.8，KNN与朴素贝叶斯稍逊，不同算法对特征空间的划分能力差异显著。

实际应用中需考虑交易成本、滑点、市场冲击，结合风险控制与资金管理，将分类结果转化为可执行的交易信号。

核心洞察： 分类选股法将机器学习应用于金融预测，通过历史行情数据训练分类模型预测股票涨跌，为投资决策提供量化依据。不同算法在准确率、召回率上表现各异，SVM与神经网络通常优于传统方法，但需防范过拟合与数据泄露，确保模型在真实市场环境中的稳健性。