

Contents

第四次作业

从基础概念到算法实现，系统掌握机器学习中的聚类分析方法

01 聚类基础概念

02 距离与相似性度量

03 K-means聚类算法

04 层次聚类（HC）

聚类基础：簇的概念与特征

聚类是无监督学习的典型代表，通过度量样本间相似性将数据集划分为若干簇，使簇内相似度最大化而簇间差异最大化。

聚类任务本质

将物理或抽象对象的集合分组为多个类，使同一类内的对象相似度高于不同类之间的相似度，是无监督学习的核心任务。

簇的多重定义


簇可以看作密度相连的区域、距离相近的点集、或层次结构中的分支，不同定义对应K-means、DBSCAN、层次聚类等不同算法。

与分类的本质区别

分类是监督学习需要标签，聚类是无监督学习无需标签；分类学习决策边界，聚类发现数据内在结构。

应用场景广泛

客户分群、文档归类、图像分割、基因表达分析等领域，聚类帮助发现隐藏的数据模式和异常点。



聚类前后数据点分组对比示意图

相似性度量：距离与相似系数

聚类算法的效果高度依赖于相似性度量的选择。不同度量方式适用于不同数据特征，选择错误会导致聚类结果严重偏离真实结构。

DISTANCE METRICS

欧氏距离与 闵可夫斯基距离

欧氏距离是最常用的距离度量，公式为 $d = \sqrt{\sum (x_i - y_i)^2}$ ，对应闵可夫斯基距离 $q=2$ 的特例，直观反映空间中的直线距离。

闵可夫斯基距离统一了曼哈顿距离 ($q=1$)、欧氏距离 ($q=2$) 和切比雪夫距离 ($q \rightarrow \infty$)，通过调整 q 值可适应不同数据分布特征。

SIMILARITY COEFFICIENT

余弦相似度与 夹角度量

余弦相似度 $\cos \theta = (x \cdot y) / (||x|| \cdot ||y||)$ 衡量向量方向一致性， $\theta = 0^\circ$ 时完全相似 ($\cos \theta = 1$)，适合文本和高维稀疏数据。

与距离度量不同，余弦相似度对向量的**绝对长度不敏感**，只关注方向相似性，常用于文档聚类和推荐系统。

ROBUST MEASURES

兰氏距离与 数据标准化

兰氏距离 $d = \sum |x_i - y_i| / (x_i + y_i)$ 要求所有特征值为正，对量纲差异具有鲁棒性，适合化学、生物等领域的数据分析。

实际应用中需先进行**数据标准化** (Z-score 或 Min-Max)，消除不同特征量纲和取值范围差异对距离计算的影响。

"选择错误的度量方式会导致聚类结果严重偏离真实结构"

K-means算法：原理与实现

通过迭代优化最小化簇内平方和，将n个样本划分为k个簇。算法虽简单高效，但存在明显局限：需要预先指定k值，对初始质心敏感易陷入局部最优。

核心思想

最小化簇内误差平方和，通过迭代优化使簇内样本到质心的距离平方和最小，形成紧凑的球形簇结构。

标准流程


随机初始化k个质心 → 分配样本到最近质心形成簇 → 重新计算质心（均值）→ 重复直至质心不再变化或达到最大迭代次数。

MATLAB实现

使用kmeans函数，指定距离度量（如'cosine'余弦距离），通过kmeans++初始化改善质心选择，避免局部最优。

算法局限与改进

对异常值敏感（可用k-medoids改进），假设簇为凸形（可用DBSCAN处理任意形状），需预设k值（可用肘部法则确定）。



K-means算法迭代过程：质心更新与样本分配

案例：债券数据的K-means聚类

在金融领域，K-means可用于债券投资组合的自动分类。通过票面利率、到期收益率等数值特征，算法将债券自动聚类，识别出风险收益特征相似的债券组。

- 1 数据准备：导入债券数据包含Type（债券类型）、Coupon（票面利率）、YTM（到期收益率）、CurrentYield（当前收益率）、Rating（信用评级）等9维特征
- 2 预处理策略：使用categorical处理分类变量，datetime转换日期格式，筛选有效数据后提取数值特征（Coupon, YTM, CurrentYield, RatingNum）
- 3 聚类实施：设置距离度量'dist_k = cosine' 处理不同量纲特征，使用kmeans(bonds, numClust, 'distance', dist_k)执行聚类
- 4 结果解读：通过三维散点图（Coupon-Rating-YTM）展示聚类结果，验证是否与专家评级（CC到AAA）一致，为自动化债券分类提供依据

Random initialization

For i = 1 to 100 {
 → Randomly initialize K-means.
 Run K-means. Get $c^{(1)}, \dots, c^{(m)}, \mu_1, \dots, \mu_K$.
 Compute cost function (distortion)
 → $J(c^{(1)}, \dots, c^{(m)}, \mu_1, \dots, \mu_K)$
}

Pick clustering that gave lowest cost $J(c^{(1)}, \dots, c^{(m)}, \mu_1, \dots, \mu_K)$

债券数据聚类结果可视化：Coupon-Rating-YTM三维散点图

💡 关键洞察

余弦距离度量适合处理不同量纲的金融指标，MATLAB的kmeans函数配合gscatter可视化，能清晰展示聚类结果与原始评级的关系，为资产配置提供数据支持。

层次聚类（HC）：原理与特点

💡 层次聚类通过构建树状图（Dendrogram）展示数据的层次结构，无需预先指定簇数。凝聚式（自底向上）从单样本簇开始逐步合并，分裂式（自顶向下）从整体不断分割。HC特别适合小规模数据集，能直观展示簇间的层次关系，但时间复杂度高（ $O(n^2)$ 或更高），不适合大规模数据。

算法流程与复杂度

- 凝聚式过程：初始每个样本为独立簇，计算簇间相似度矩阵，合并最相似的两个簇，更新相似度矩阵，重复直至所有样本归为一簇
- 复杂度分析：时间复杂度通常为 $O(n^2)$ 或 $O(n^3)$ ，空间复杂度 $O(n^2)$ ，因此仅适用于小规模数据集（通常 $n < 10000$ ）

簇间距离度量

- 单链接：取两簇间最近样本对的距离，适合发现非球形簇但对噪声敏感，可能产生链式效应
- 全链接：取两簇间最远样本对的距离，倾向于生成球形簇，对噪声较鲁棒但可能合并不同密度的簇
- 中心点距离：基于两簇质心间距离，计算简单但可能忽略簇的形状信息

核心优势与局限

- ✓ 优势：无需预设簇数，通过树状图直观展示层次结构，适合理解数据的内在组织方式和异常点检测
- ✗ 局限：计算和存储开销大，无法处理大规模数据；一旦合并无法撤销，对噪声和异常值敏感

树状图解读：确定聚类数目


通过观察垂直线的高度和分支结构，结合切割法则直观判断聚类的合理数目

结构原理：叶子代表单个样本，垂直线长度表示簇间距离或相似度，水平线代表簇的合并，高度反映合并时的距离阈值

切割法则：在纵轴某高度画水平线，统计与垂直线的交点数即为聚类数；上移至根节点得1个簇，下移至叶节点得n个簇

MATLAB实现：使用dendrogram函数绘制，设置'ColorThreshold'参数控制颜色分支，默认显示30个节点防止图形拥挤，linkage函数支持'ward'、'single'等距离度量

最佳实践：结合肘部法则、轮廓系数或业务场景确定切割高度，通常选择长垂直分支后的首次合并点，确保簇内距离小、簇间距离大



层次聚类树状图（Dendrogram）及切割线示意

聚类方法：从K-means到层次聚类

掌握聚类核心思想，灵活应用于数据分析实践

方法对比与选择

K-means适合大规模数据、球形分布、追求计算效率；层次聚类适合小数据集、需要层次结构、追求可解释性；实践中常结合使用，如先用K-means粗分再用HC细化

🔑 关键成功因素

数据标准化消除量纲影响、选择合适距离度量（欧氏/余弦/马氏）、确定最佳K值（肘部法则/轮廓系数/业务知识）、处理异常值和噪声

📖 拓展阅读建议

阅读《白话机器学习》K-means与决策树章节，理解算法背后的统计思想；实践MATLAB的统计工具箱，掌握kmeans、linkage、dendrogram等核心函数