

Contents

第五次作业

关联规则与Apriori算法技术汇报，涵盖应用场景、核心概念、算法原理及实践应用

01 关联规则应用场景

02 核心概念与度量

03 数据矩阵表示

04 Apriori算法原理

05 Python实现与知识图谱

06 行业关联选股法

关联规则的应用场景

通过发现项集间的共现模式，在零售、医疗、金融、工业等领域实现知识发现，为理解复杂数据关系提供系统化的分析框架。

商业与医疗应用

购物篮分析通过发现顾客购买行为模式优化商品陈列，经典案例显示啤酒与尿布的关联性可提升交叉销售额15-20%

医学规律发现在自闭症研究中通过药物共现网络识别跨治疗组的药物关联，辅助个性化治疗方案制定

保险行业应用通过识别具有特定关联特质的客户群体，实现精准风控

工业故障诊断

工程故障关联分析设备日志发现故障模式，如某部件异常往往伴随另一部件过热，实现预测性维护

通过关联规则挖掘降低设备维修成本，提前识别故障链，避免连锁反应导致的重大停机事故

制造领域应用关联规则优化生产流程，识别质量缺陷与工艺参数间的隐藏关联

金融证券分析

行业关联选股法利用关联规则分析股票行业间联动关系，当某些板块上涨时关联行业可能跟随上涨

构建知识图谱将发现的关联规则转化为图结构，节点表示实体，边表示关联强度，支持高维关系推理

量化交易应用通过历史数据挖掘行业轮动规律，为投资组合配置提供数据驱动的决策支持

“关联规则为理解复杂数据关系提供了系统化的分析框架，是构建知识图谱和实现智能推荐的重要基础”

关联规则的核心概念

关联规则挖掘建立在严格的数学定义之上：项与项集构成基本数据单元，支持度衡量规则的普遍程度，置信度衡量规则的可靠程度。频繁项集需满足最小支持度阈值，强关联规则则需同时满足最小支持度和最小置信度，这种双重阈值机制有效过滤了偶然共现的伪关联。

- 01 项 (Item) 与项集 (Itemset)** — 项是数据中的最小单位，如超市中的单个商品；项集是项的集合，如 {牛奶, 面包}；事务是一条交易记录，包含若干项，如顾客一次购买的商品清单。
- 02 支持度 (Support)** — 计算公式为 $P(X \cup Y)$ ，即同时包含 X 和 Y 的事务数除以总事务数，反映规则在整个数据集中的普遍程度，值越大说明关联越普遍。
- 03 置信度 (Confidence)** — 计算公式为 $P(Y|X)$ ，即同时包含 X 和 Y 的事务数除以包含 X 的事务数，反映规则的可靠性，值越大说明从 X 推出 Y 的可信度越高。
- 04 频繁项集与强关联规则** — 频繁项集指支持度大于等于最小支持度阈值的项集，是生成关联规则的基础；强关联规则需同时满足最小支持度和最小置信度两个阈值条件。

数据矩阵表示：行与列的定义

关联规则挖掘要求将原始交易数据转换为布尔矩阵形式，其中行代表事务（交易记录），列代表项（商品或特征），矩阵元素为0或1表示包含关系。这种表示方法是Apriori算法高效计算的基础。

- 01 矩阵的**行代表事务(Transaction)**，即一条完整的交易记录，如一次购物订单、一天的股票行情或一条医疗记录，每一行对应一个独立的观测样本。
- 02 矩阵的**列代表项(Item)**，即具体的商品、行业板块、症状或特征属性，每一列对应一个可能出现在事务中的元素。
- 03 矩阵元素取值为**布尔值0或1**，其中1表示该事务包含该项，0表示不包含，这种二元表示消除了数量差异，仅关注存在性。
- 04 **Python实现**中使用mlxtend库的TransactionEncoder，通过fit方法学习所有唯一项，通过transform方法将交易列表转换为布尔矩阵。

	A	B	C	D	E	F	G	H	I	J	K	L	M	N
1		I	like	you	my	dear	enjoy	playing	chess	with	friend	he	is	best
2	I	0	1	0	0	0	1	0	0	0	0	0	0	0
3	like	1	0	1	0	0	0	0	0	0	0	0	0	0
4	you	0	1	0	1	0	0	0	0	0	0	0	0	0
5	my	0	0	1	0	2	0	0	0	1	0	0	1	1
6	dear	0	0	0	2	0	0	0	0	0	1	0	0	0
7	enjoy	1	0	0	0	0	0	0	0	0	0	0	0	0
8	playing	0	0	0	0	0	0	0	1	0	0	0	0	0
9	chess	0	0	0	0	0	0	1	0	1	0	0	0	0
10	with	0	0	0	1	0	0	0	1	0	0	0	0	0
11	friend	0	0	0	0	1	0	0	0	0	0	0	0	1
12	he	0	0	0	0	0	0	0	0	0	0	1	1	0
13	is	0	0	0	1	0	0	0	0	0	0	1	0	0
14	best	0	0	0	1	0	0	0	0	0	1	0	0	0


图：关联规则挖掘中的0-1布尔矩阵数据结构示意

Apriori算法原理与过程

💡 **关键洞察：**Apriori算法基于先验性质——频繁项集的所有子集必须也是频繁的，反之非频繁项集的所有超集必定非频繁。这一性质支持高效的剪枝策略，显著降低计算复杂度。

- 1 先验性质是算法核心：若项集S是频繁的，则其所有子集也必定频繁；若项集S非频繁，则所有包含S的超集也必定非频繁，这是剪枝的理论基础。
- 2 连接操作(Join)将两个k-1项集L(k-1)进行自连接，生成k项候选集C(k)，例如L1={A, B, C}连接生成C2={AB, AC, BC}。
- 3 剪枝操作(Prune)检查候选k项集的所有k-1子集，若存在某个子集不在L(k-1)中，则删除该候选项集，大幅减少计算量。
- 4 迭代生成过程从k=1开始，反复执行连接与剪枝，计算支持度筛选频繁项集，直到无法生成新的频繁项集为止，最终得到所有频繁项集的完整集合。

The Apriori Algorithm—An Example



图：Apriori算法迭代流程示意图

Apriori算法执行步骤详解

Apriori算法通过七步迭代系统性地挖掘频繁项集：从扫描数据生成候选1-项集开始，经支持度筛选得到频繁1-项集，再通过连接与剪枝的循环迭代逐步构建高阶项集，直至无法生成新的频繁项集。

初始化与迭代过程

- ➔ 扫描全部数据产生候选1-项集C1，统计每个项的出现频次
- ➔ 根据最小支持度阈值从C1筛选出频繁1-项集L1，删除低于阈值的项
- ➔ 对k>1循环执行：由Lk连接生成候选(k+1)-项集C(k+1)，剪枝后统计支持度生成L(k+1)

终止与规则生成

- ✓ 当L(k+1)为空集时算法终止，此时已获得所有频繁项集的完整集合
- ✓ 根据最小置信度阈值从频繁项集生成强关联规则，过滤掉低置信度的弱规则
- ✓ 最终输出满足支持度和置信度双阈值的关联规则，用于业务决策和知识发现

Apriori算法迭代示例（最小支持度计数=2）

步骤	操作	结果项集
第1次扫描	生成C1并统计频次	$C1=\{A:2, B:3, C:3, D:1, E:3\} \rightarrow L1=\{A, B, C, E\}$
第2次扫描	L1连接生成C2，剪枝后统计	$C2=\{AB, AC, AE, BC, BE, CE\} \rightarrow L2=\{AB, AC, BC, BE, CE\}$
第3次扫描	L2连接生成C3，剪枝后统计	$C3=\{BCE\} \rightarrow L3=\{BCE\}$
第4次扫描	L3连接生成C4	$C4=\varnothing$ ，算法终止

通过迭代连接与剪枝，最终得到所有频繁项集 {L1, L2, L3}

Python实现：商品关联分析与知识图谱


通过mlxtend库实现Apriori算法，对100条电子产品交易记录进行分析，共发现83个2项频繁项集，其中笔记本电脑-路由器关联强度最高（支持度0.04）。

数据准备与算法实现

- ✓ 使用`TransactionEncoder.fit_transform`将交易列表转为布尔矩阵，100行25列对应100条交易和25种商品
- ✓ 调用`apriori(trans_df, min_support=0.02, max_len=2)`计算频繁项集，限制最大项集长度为2以关注直接关联
- ✓ 使用`association_rules`函数基于频繁项集生成关联规则，设置`min_threshold`过滤弱规则

结果分析与可视化

- 共发现83个满足条件的2项频繁项集，笔记本电脑-路由器出现4次（支持度0.04），关联强度最高
- 加湿器-智能手表、吸尘器-笔记本电脑等组合出现3次，反映电子产品间的互补购买模式
- 通过networkx构建知识图谱，节点表示商品，边表示关联强度，实现关联关系的可视化呈现



知识图谱可视化 • 节点大小映射出现频率，边粗细映射支持度

应用实例：行业关联选股法背景与实现

背景与数据构建

行业联动性：不同行业股票存在联动性，某些板块上涨时关联行业可能跟随上涨

矩阵构建：行代表交易日期，列代表银行、地产、医药、科技等行业板块

布尔转换：元素1表示该行业当日上涨，0表示下跌，便于Apriori算法挖掘

策略与风险控制

关联挖掘：设置最小支持度0.03和置信度0.6，挖掘频繁共涨的行业组合


投资策略：监测到规则前件（如银行、保险上涨）出现时，预测后件行业可能跟随上涨

风险控制：关联规则反映历史共现规律而非因果关系，需结合宏观基本面分析

2.1 最近一周因子表现

图3展示了上周各类因子在不同股票池内的 RankIC 表现情况。可以看到，在全样本内基本面因子仍然延续着近期的良好表现。Beta 因子在上周取得了接近-30%的 RankIC，相比于上周出现了很大程度回撤。另一方面，估值因子的 RankIC 为 19.01%取得了较为显著的效果，而基本因子的效果不再显著，在各个样本股中的 RankIC 不尽相同。

图 3：上周部分因子在主要指数上的 RankIC 表现（2020.2.21-2020.2.28）



数据来源：财通证券研究所，恒生聚源

股票行业板块关联分析示意图

总结与思考

Apriori算法以先验性质为基础，通过连接与剪枝迭代生成频繁项集，将原始交易数据转化为0-1矩阵，经支持度与置信度双重阈值筛选生成强关联规则，最终构建知识图谱实现可视化。从购物篮分析、故障诊断到医学发现、金融选股，关联规则为发现数据中的隐藏模式提供了强大工具。

核心机制与数据表示

先验性质支撑剪枝策略，连接与剪枝操作迭代生成频繁项集，支持度与置信度双重阈值筛选强规则

0-1矩阵清晰表达事务与项的关系，行为交易记录，列为商品或特征，便于高效计算支持度与置信度

应用场景与实践要点

-  从购物篮分析、故障诊断到医学发现、金融选股，关联规则是知识发现的重要工具
-  合理设置支持度与置信度阈值防范过拟合，关联不等于因果，需结合业务理解谨慎解释结果