

Contents

第六次作业

从矩阵运算到模型评估，系统掌握线性回归的核心原理与实现方法。

01 矩阵维度与向量化

02 模型参数获取

03 R^2 模型评估

04 数据划分策略

05 最小二乘法实现

矩阵维度约束：为何X必须是列向量结构


线性回归的矩阵运算要求X保持(n_samples, n_features)的二维结构，即使单变量回归也需reshape为(n, 1)而非(n,)。sklearn强制要求二维输入以确保矩阵乘法 $Y=X \cdot \beta$ 的数学一致性，一维行向量会导致维度不匹配错误。

- 01 数学原理：**线性回归公式 $Y=X \beta$ 要求X为 $M \times N$ 矩阵（M样本数，N特征数），权重 β 为 $N \times 1$ 向量，乘积结果为 $M \times 1$ 的预测值向量，符合矩阵运算维度匹配规则
- 02 sklearn约束：**fit() 和predict() 方法强制要求X.shape为(n_samples, n_features)，若传入一维数组(shape为(n,))会触发ValueError: Expected 2D array, got 1D array instead
- 03 单变量特例：**即使只有一个特征，X也需保持(n, 1)的二维结构而非(n,)的一维数组，确保模型能正确识别特征矩阵的维度信息
- 04 解决方案：**使用numpy的reshape(-1, 1)方法将一维特征转换为列向量，或通过ColumnTransformer处理混合类型数据，严格保持二维输入结构

模型参数提取：coef_与intercept_的实战应用

训练完成的线性回归模型通过`coef_`暴露回归系数（斜率），通过`intercept_`暴露截距项。以图片数据为例，系数9.91表示自变量每增加1单位因变量增加9.91单位，截距2.02表示基准值，共同构成预测方程 $y = 2.02 + 9.91x$ 。

- ➡ **系数获取：**调用`regressor.coef_`返回斜率数组，在单变量回归中为标量值，多变量回归中为长度等于特征数的数组，每个元素代表对应特征的边际效应
- ➡ **截距获取：**调用`regressor.intercept_`返回截距值2.02，表示当所有特征为0时的预测基准值，是回归直线与y轴的交点
- ➡ **方程构建：**基于提取的参数构建预测公式，可用于对新样本进行预测，体现自变量对因变量的线性影响关系
- ➡ **代码验证：**使用`regressor.predict(X_test)`生成预测值，与手工计算结果对比，验证参数提取的正确性




线性回归模型参数的几何意义：斜率表示变化率，截距表示基准值

R² 决定系数：模型解释力的量化评估

R² 通过 $1 - SS_{res} / SS_{tot}$ 计算模型对数据变异的解释比例，取值范围[0, 1]。训练集 R²=0.952、测试集 R²=0.945，表明模型解释了约95%的目标变量变化，且训练与测试性能接近，说明模型泛化能力优异无过拟合。

- 01 **计算公式：** $R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$ ，其中分子为残差平方和（预测误差），分母为总平方和（数据固有变异），比值越小说明模型解释力越强
- 02 **代码实现：**调用`regressor.score(X_train, Y_train)`获取训练集R² (0.9516)，调用`regressor.score(X_test, Y_test)`获取测试集R² (0.9455)，快速评估模型性能
- 03 **结果判读：**R² 接近1 (>0.9) 表示拟合效果优异，R² 在0.7-0.9表示良好，<0.3通常表示模型解释力弱需重新考虑特征或模型选择
- 04 **过拟合检测：**训练集R² (0.952) 与测试集R² (0.945) 差异仅0.007，远小于0.1的警戒线，证明模型未过拟合，对新数据具有稳定预测能力



数据划分策略：训练/测试比例对模型性能的影响

"训练/测试比例的选择需要在模型学习能力与评估可靠性间权衡。80/20是经验法则，在样本量充足时能保证模型充分学习且评估结果统计显著。"

⚠ 欠拟合风险

训练集比例<60%时，模型无法充分捕捉数据规律，训练 R^2 和测试 R^2 双低，模型处于欠拟合状态，预测能力弱。

评估不稳定

训练集比例>90%时，测试集样本过少（如25个样本中仅2-3个）， R^2 估计方差大，无法可靠反映真实泛化能力。

💡 经验法则

80/20划分在样本量25-1000范围内表现稳健，既保证模型有充足数据学习（20个样本中16个训练），又确保测试集有代表性（4个测试）。

⚙ 动态调整

小样本(<100)可采用70/30增加测试稳定性，大样本(>10000)可采用90/10最大化训练数据，或通过K折交叉验证充分利用全部数据。

最小二乘法：从数学公式到numpy代码实现

最小二乘法通过正规方程 $\beta = (X^T X)^{-1} X^T Y$ 直接求解全局最优解，避免迭代法的局部最优陷阱。使用numpy实现时，需先为X添加全1偏置列，再通过矩阵运算求解，结果与sklearn的coef_和intercept_误差小于1e-10，验证算法正确性。

数学原理：最小化残差平方和 $\|Y - X\beta\|^2$ ，对 β 求导并令导数为0，推导得正规方程 $\beta = (X^T X)^{-1} X^T Y$ ，直接获得解析解

numpy实现步骤：① `X_b = np.c_[np.ones((n, 1)), X]` 添加偏置列；② `theta_best = np.linalg.inv(X_b.T @ X_b) @ X_b.T @ Y` 计算最优参数，其中@表示矩阵乘法

结果验证：手动计算得到的系数[2.018, 9.911]与sklearn的intercept_(2.018)和coef_(9.911)完全一致，证明底层实现正确

适用边界：最小二乘法要求 $X^T X$ 可逆（特征间无多重共线性），样本量大于特征数，适用于中小规模数据；大规模数据建议使用sklearn的迭代优化算法

总结：线性回归的完整技术闭环

线性回归实践需遵循数据结构规范→参数提取→模型评估→数据划分→算法验证的完整流程。矩阵维度约束保证数学正确性， R^2 评估确保模型质量，最小二乘法验证算法原理，形成从理论到实践的闭环。

数据结构铁律

X必须保持(n_samples, n_features)的二维结构，使用`reshape(-1, 1)`处理单变量，确保矩阵运算维度匹配

参数可解释性

`coef_`反映特征边际效应(9.91)，`intercept_`提供基准值(2.02)，共同构建可解释的预测方程

评估指标体系

$R^2=0.95$ 表明模型解释95%变异，训练/测试 R^2 差异 <0.01 证明无过拟合，泛化能力优异