

Contents

第七次作业

多元线性回归与分类数据分析

01 数据特征观察

02 One-Hot编码过程

03 R^2 模型评估

04 系数与截距解读

05 分类变量影响分析

06 编码方式对比

数据特征观察：属性构成与分类变量识别


关键发现：50_Startups数据集包含5个属性，其中State为分类变量。箱线图显示三个城市的利润分布差异有限，中位数均在12-15万区间，表明地理位置对营收的直接影响较弱。

数据集结构

- 01 数据集共50条记录，包含4个特征变量（R&D Spend、Administration、Marketing Spend、State）和1个目标变量（Profit）
- 02 State为唯一分类变量，包含3个类别：New York（17例）、California（17例）、Florida（16例），需进行编码转换才能进入回归模型

可视化分析

- 01 箱线图显示三个城市的利润中位数差异不超过2万元，分布范围（IQR）重叠度高，说明State对Profit的独立解释力有限
- 02 散点图揭示R&D Spend与Profit呈明显正相关（ $r \approx 0.98$ ），是利润的核心驱动因素，远大于State的潜在影响



One-Hot编码过程：从文字标签到二进制矩阵

One-Hot编码通过LabelEncoder将State转为数字（0/1/2），再通过OneHotEncoder转为3列二进制向量（每列代表一个州），最终形成6列特征矩阵（3列One-Hot+3列数值）。这种转换消除了类别间的虚假序关系，使回归系数可解释为相对于基准类别的差异。

第一步 Label编码：使用LabelEncoder将'California'、'Florida'、'New York'映射为0、1、2，实现文字到数字的初步转换

第二步 One-Hot转换：通过OneHotEncoder将单个数字列拆分为3列二进制向量，如[1,0,0]表示California，[0,1,0]表示Florida，每列独立表示一个类别


第三步 ColumnTransformer整合：指定transformers参数仅对第4列（索引3）应用编码，remainder='passthrough'保留其他数值列，输出6列完整特征矩阵

第四步 编码结果验证：转换后矩阵维度为50×6，前3列为One-Hot编码（0/1值），后3列为原始数值（R&D、Admin、Marketing），可直接输入LinearRegression模型

R² 模型评估：决定系数的计算与解读

R² 决定系数通过 $1 - SS_{\text{res}} / SS_{\text{tot}}$ 计算，衡量模型解释数据变异的能力。本案例中 $R^2 = 0.9491$ ，表明模型解释了94.9%的利润变化，拟合效果优异；训练集与测试集 R^2 差异小于0.01，证明模型未过拟合，泛化能力稳健。

- 01 计算公式：** $R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$ ，其中分子为残差平方和（预测误差），分母为总平方和（数据固有变异），比值越接近0说明模型解释力越强
- 02 代码实现：** 调用 `regressor.score(X_train, Y_train)` 获取训练集 R^2 （0.9516），调用 `regressor.score(X_test, Y_test)` 获取测试集 R^2 （0.9455）
- 03 结果判读：** $R^2 = 0.9491$ 接近1，说明回归模型解释了94.9%的目标变量变异；通常 $R^2 > 0.9$ 表示拟合优异
- 04 泛化验证：** 训练集 R^2 （0.952）与测试集 R^2 （0.945）差异仅0.007，远小于0.1的警戒线，证明模型未过拟合



系数提取与公式构建：模型参数的量化解读

$Profit = 42989.01 + 0.78 \times R\&D + 0.03 \times Admin + 0.03 \times Marketing$ • R&D系数显著高于其他变量，是利润的核心驱动因素

R&D Spend

0.7788

coefficient b_1

78%投资回报率：每增加1万元研发投入，利润平均增加约0.78万元

在所有特征中影响最大，验证“技术驱动增长”的商业逻辑，是企业资源配置的优先方向

Administration

0.0294

coefficient b_2

影响微乎其微：每增加1万元管理费用，利润仅增加约0.03万元

提示企业应控制管理成本，避免过度行政开支侵蚀利润，精益管理的重要性凸显

Marketing Spend

0.0347

coefficient b_3

边际效益较低：每增加1万元营销费用，利润增加约0.03万元

与R&D相比投入产出比差距达26倍，提示营销投入需精准化，避免粗放式广告投放

关键洞察： R&D投入的系数(0.78)是管理费用(0.03)的26倍，表明技术创新对利润增长的贡献远超行政与营销投入，企业应优先保障研发预算。

分类变量的影响：多重共线性与解释性挑战

分类变量State的存在带来三方面影响：①不能直接输入模型，必须数值化；②One-Hot编码导致虚拟变量陷阱（三列之和恒为1），需删除一列消除多重共线性；③本例中State对 R^2 提升贡献微小（ <0.001 ），证实地理位置并非利润的关键驱动因素，研发效率才是核心。

输入约束

回归模型要求数值输入，文字标签'New York'无法参与矩阵运算，必须通过One-Hot编码转为二进制矩阵才能进入模型。

虚拟变量陷阱

3个类别的One-Hot编码产生3列，其和为全1向量与截距项完全共线性，导致 $(X^T X)$ 不可逆。解决方案是删除一列（如California），以剩余两列系数表示相对于基准类别的差异。

解释复杂性

加入State后模型需解读'相对于California, New York的平均利润差异'，而非直接给出各州的绝对效应，增加了结果解释的认知负担。

贡献度评估

对比含State与不含State模型的 R^2 （0.950 vs 0.949），发现分类变量解释力微乎其微，提示在建模时应优先考虑连续变量的非线性变换，而非盲目加入分类变量。

编码方式对比：Label编码的虚假序关系陷阱

将State直接Label编码为0、1、2虽能运行（ $R^2=0.9491$ 不变），但会强制模型学习虚假的数值序关系（NY(2)>FL(1)>CA(0)），导致State系数为-818.58且解释为“州编号每增1利润减818元”，这在业务逻辑上完全荒谬。One-Hot编码通过独立二元列避免此陷阱，是唯一合理的处理方式。

Label编码的问题

- ❗ 将CA/FL/NY映射为0/1/2，强制引入序关系：模型认为NY(2)是CA(0)的“2倍”，并学习“数值越大利润越低”的虚假规律
- ❗ State系数-818.58表示“州编号每增加1，利润减少818元”，这在地理上毫无意义，因为三个州是平行关系而非梯度关系

One-Hot编码的优势

- ✓ 通过3列二进制向量彻底消除数值比较，每列独立表示“是否属于该州”，系数直接解释为相对于基准州的平均利润差异
- ✓ 虽然 R^2 与Label编码几乎相同（0.9491），但系数具有明确业务含义（如“NY比CA平均高X万元”），支持精准的商业决策