

第九次作业

决策树作业：Social Network Ads分类预测实验的四个核心分析维度。

01 作业1：性别因素影响

通过One-Hot编码加入Gender特征，对比基准模型与完整模型的准确率变化

02 作业2：特征缩放敏感性

对比StandardScaler标准化前后的模型性能，验证决策树对特征缩放的敏感度

03 作业3：多算法性能对比

比较KNN、Logistic回归、决策树和随机森林的准确率差异

04 作业4：决策树可视化

展示特征重要性，分析分裂节点的决策逻辑


性别因素对准确率的影响

💡 关键发现

加入Gender特征后，模型准确率维持91.25%不变，表明性别未提供有效信息增益。决策树的分裂机制主要依赖Age和EstimatedSalary的阈值判断，Gender的熵减贡献不足以影响节点分裂。

- 基准模型（Age+Salary）在测试集上达到91.25%的准确率，已能有效区分购买与非购买用户
- 通过LabelEncoder和OneHotEncoder将Gender转为二进制特征后，加入模型重新训练，测试准确率仍为91.25%
- 特征重要性分析显示Gender的贡献度极低，决策树的分裂节点主要由Age $\leq$ 42.5和Salary $\leq$ 92500等阈值主导
- 结论：对于该数据集，Gender不是关键预测因子，模型可仅依靠Age和Salary实现高效分类

加入Gender前后的准确率对比



数据来源：Social Network Ads数据集

作业2：特征缩放对决策树的影响

核心发现：决策树对特征缩放表现出完全的鲁棒性，标准化前后准确率均为**91.25%**。这是因为决策树基于信息熵进行阈值分裂，分裂点的相对位置在缩放前后保持不变，与KNN等依赖欧氏距离的算法形成本质差异。

决策树（缩放不敏感）

基于**信息熵**选择最优分裂点，关注阈值左右的样本分布，缩放前后阈值相对位置不变。

原始数据特征尺度差异大：Age范围19-60，EstimatedSalary范围15000-150000，量级相差约1000倍

在原始数据和标准化数据上的测试准确率均为**91.25%**

KNN（缩放敏感）

基于**欧氏距离**计算邻居，Salary的量级会主导距离计算，必须进行标准化才能公平比较各特征。

使用StandardScaler进行Z-score标准化后，两个特征均转换为均值为0、标准差为1的分布，消除量纲影响


算法原理差异：KNN依赖欧氏距离，对特征尺度极度敏感，未经标准化时大数值特征将主导距离计算

作业3：KNN、Logistic与决策树算法对比

核心发现：KNN (K=5) 以95%准确率显著优于其他算法 (91.25%)，源于其局部投票机制对非线性边界的适应能力。当数据量较小 (400条) 且特征维度低 (2维) 时，简单模型可能足够，复杂集成方法未必带来增益。

- 实验设置：**统一使用80/20训练测试划分，特征标准化处理，确保算法对比的公平性。
- KNN (K=5)：**达到95%准确率，通过局部近邻投票机制捕捉Age与Salary的复杂交互关系，对非线性边界适应性强。
- 决策树与Logistic回归：**均为91.25%，前者可能受限于树的深度，后者假设线性决策边界，对复杂模式拟合不足。
- 随机森林：**91.25%未展现集成优势，可能因数据集规模较小且特征维度低，多棵树的averaging效应不明显。

四种分类算法准确率对比



数据来源：Social Network Ads分类预测实验

作业4：决策树可视化与特征重要性分析

决策树（max_depth=3）以Age≤42.5作为根节点分裂条件，Age特征重要性高达91%，Salary仅占9%。树结构清晰展示了分类规则：年轻低收入用户不购买，年长高收入用户购买，体现了决策树优秀的可解释性和业务逻辑透明度。

使用plot_tree和graphviz生成决策树可视化，设置max_depth=3防止过拟合，确保树结构清晰可读

根节点分裂条件为Age≤42.5（信息增益最大），左子树进一步按Salary≤89500分裂，右子树按Salary≤92500分裂

特征重要性分析：Age占比0.91（91%），EstimatedSalary占比0.09（9%），验证Age是核心预测因子

分类规则解读：Age>42.5且Salary>92500的用户大概率购买（Yes），Age≤39.5且Salary≤89500的用户大概率不购买（No）

