

Contents

第十次作业

K-means聚类算法在Iris数据集上的完整实验流程，涵盖数据探索、特征分析、降维可视化与参数调优。

01 实验背景与数据集

02 花萼特征聚类分析

03 全特征聚类与PCA降维

04 超参数K值调优实验

05 聚类中心与轮廓系数



06 实验总结

任务一：基于花萼特征的聚类分析

核心发现：仅使用花萼长度与宽度进行K-means聚类（K=3）得到三个簇，样本分布为47、50、53，虽然能较好分离Setosa类，但Versicolor与Virginica在特征空间中存在明显重叠，说明花萼特征对后两类区分度有限。

- ✓ **特征选择：**提取数据集前2列（花萼长度、花萼宽度），构建150×2的输入矩阵，保留原始量纲未做标准化（K-means对量纲敏感，但本实验数据尺度相近）
- 🕒 **聚类结果：**Cluster 0含47条，Cluster 1含53条，Cluster 2含50条，与真实类别数量（每类50条）接近但存在错位，说明无监督学习标签与真实标签存在映射差异
- 👁️ **可视化观察：**散点图显示左下角簇（通常为Setosa）分离清晰，但中间区域两簇边界模糊，存在较多误分点，验证了花萼特征对相似物种的弱区分能力
- ⚙️ **算法配置：**使用sklearn.cluster.KMeans，设置n_clusters=3，random_state=42保证可复现性，n_init=10避免局部最优


花萼特征聚类样本分布



任务二：全特征聚类与PCA降维可视化

利用全部4个特征进行K-means聚类，Inertia降至78.85，聚类紧密度显著提升；通过PCA降维至2维空间可视化，可清晰观察三个簇的分布与聚类中心位置，验证了花瓣特征对类别区分的关键作用。

- 全特征输入：使用花萼长宽+花瓣长宽共4个特征，数据维度150×4，K-means在4维空间中寻找最优簇中心，相比2维特征能捕捉更复杂的类别结构
- 聚类中心：Cluster 0中心为[5.90, 2.75, 4.39, 1.43]，Cluster 1为[5.01, 3.43, 1.46, 0.25]，Cluster 2为[6.85, 3.07, 5.74, 2.07]
- PCA降维：将4维数据投影至2维主成分空间，三个簇在降维空间中呈现清晰的三角分布
- 模型评估：Inertia值为78.85，衡量了各样本到其簇中心的平方距离之和，值越小表示簇内样本越紧密



超参数K值调优实验（K=2 vs K=3）


将K从3改为2时，Inertia从78.85升至86.39，聚类质量下降；算法将150条样本强制分为99条和51条两类，通常表现为Setosa单独成簇而Versicolor与Virginica合并，体现了K值选择对聚类结构的决定性影响与肘部法则的必要性。

K值选择原理：K-means需预先指定簇数，K=3时Inertia为78.85，K=2时升至86.39，表明减少簇数导致类内离散度显著增加，聚类紧密度下降。

聚类分布变化：K=2时得到两类，分别含99条和51条样本，与原始三类（各50条）差异明显，说明算法将两个相似类别合并为一类。

聚类中心（2D花瓣特征）：K=2时中心为[4.93, 1.68]和[1.49, 0.26]，分别对应合并类与Setosa类的典型花瓣尺寸。

业务启示：K值选择应基于领域知识或肘部法则，盲目减少K会导致不同性质样本混为一类，影响后续分析准确性。



任务四：聚类中心可视化与轮廓系数评估

核心发现：花瓣特征（Petal Length & Width）的聚类中心坐标分别为[1.46, 0.25]、[4.27, 1.34]、[5.60, 2.04]，对应小、中、大三种花瓣形态；Silhouette Score达0.66，表明类内紧密度与类间分离度良好，聚类质量较高。

聚类中心坐标与样本分布

簇编号	花瓣长度(cm)	花瓣宽度(cm)	样本数
Cluster 0	1.46	0.25	50
Cluster 1	4.27	1.34	52
Cluster 2	5.60	2.04	48

三个聚类中心在花瓣尺寸上呈现明显梯度，样本分布均衡

1 聚类中心含义

每个中心是该簇所有样本在各维度上的均值向量，如Cluster 1中心[1.46, 0.25]代表该类花瓣平均长度1.46cm、宽度0.25cm，对应Setosa的典型小巧特征

2 中心坐标对比

Cluster 2中心[4.27, 1.34]和Cluster 3中心[5.60, 2.04]分别对应Versicolor和Virginica的中等与大花瓣特征，中心间距清晰反映类间差异

3 Silhouette Score计算

取值范围[-1, 1]，0.66表示样本与其自身簇的相似度显著高于与最近邻簇的相似度，聚类结构明显；高于0.5通常视为可接受的聚类质量

4 可视化验证

散点图中聚类中心（黑色X）位于各簇几何中心，周围样本点密集分布，边界处虽有少量重叠但整体分离清晰，与定量评估结果一致

Cluster centers (petal 2D):

```
[[5.59583333 2.0375  ]
```

```
[1.462      0.246    ]
```

```
[4.26923077 1.34230769]]
```

Inertia: 31.37135897435897

Cluster counts: Counter({np.int32(2): 52, np.int32(1): 50, np.int32(0): 48})

Silhouette score: 0.6604800083974887

KMeans centers and average cluster radius (k=3, petal features)

