



南京工业大学
NANJING TECH
UNIVERSITY

数据挖掘与机器学习

信管2301

黄陈熙

202321054011





南京工业大学
NANJING TECH
UNIVERSITY

第一讲 数据挖掘的基本认知

信管2301

黄陈熙

202321054011



课后作业

阅读《白话机器学习算法》第1章，整理读书笔记。

一、章节核心定位

- 1.主题定位：阐明“大数据挖掘”的基本概念、数据挖掘与大数据的关系、数据挖掘的内容与应用场景，以及入门级的工具与流程。
- 2.目标读者与应用导向：面向本科/研究生层级的读者，强调理论结合实践，提供MATLAB等工具的实际应用示例，帮助理解数据挖掘的全生命周期。

课后作业

二、第1章的核心要点（按书中段落与要点梳理）

1.1 大数据与数据挖掘

大数据的核心特征：体量大（Volume）、数据多样性（Variety）、价值密度低（Low Value Density）、速度快（Velocity），简称常用的四个V概念。

大数据的价值：不仅在于数据量的放大，更在于通过挖掘从海量数据中发现有价值的模式和规律，从而支持决策与业务优化。

关系与区分：大数据是数据挖掘的一种外延表达，数据挖掘是在大数据背景下对数据进行知识发现的系统方法。

应用驱动的核心观点：大数据的最终价值来自于实际应用场景的落地与商业化价值，而非单纯的数据堆积。

1.1.1 什么是大数据

通过必胜客的CRM场景等故事阐明数据贯穿业务流程，强调数据的获取、存储、集成与使用的链条。

数据集成与统一管理的重要性：把分散数据整合，有利于后续的挖掘与分析。

降维与降维策略的初步提及：对海量数据在计算与分析中的可行性考虑，以及分层/逐步降维的思路。

1.1.2 大数据的价值

通过故事情节引出对价值的理解：数据在经过分析、学习后，能揭示隐含规律，指导未来决策。

大数据价值的持续性：价值不会因为使用而减少，可以在不同场景多次复用。

课后作业

1.2 数据挖掘的原理

数据挖掘是多学科的综合应用：数据库、统计学、应用数学、机器学习、可视化、程序开发等共同构成数据挖掘的基础。

数据挖掘的流程与输出：从输入数据到输出模型，经过训练、验证，最终用于预测与解释。

数据挖掘的核心目标：建立具有泛化能力的模型，能够对未知数据进行准确预测。

1.3 数据挖掘的内容

主要内容六大类核心方法：关联规则、回归、分类、聚类、预测、诊断（后文章中会展开每一类方法及对应算法）。

数据挖掘前期技术：数据准备（收集、质量分析、预处理）与数据探索（衍生变量、降维、可视化等）。

时序数据挖掘与智能优化：时间序列方法、遗传算法、模拟退火等。

数据挖掘过程的人文与流程性要素：商业目标设定、数据理解、数据质量、数据预处理、数据探索等环节的协同。

1.4 数据挖掘的应用领域与未来趋势（章节摘要）

数据挖掘在零售、银行、证券、能源、医疗、通信、汽车等行业的潜在应用场景。

对大数据时代的思考：要避免“技术驱动”而忽视应用，强调“数据驱动的应用”与行业知识的重要性。

对数据隐私、伦理、成本与平台建设的理性认知。

课后作业

1.5 大数据挖掘的要点（要点小结）

大数据思维：即便数据量大，也应关注能否从数据中提取有用信息与知识，强调开放、共享、协作的态度。

数据平台成本与架构的意识：大数据平台建设的成本、能耗、维护等要素需要在项目初期就被权衡。

数据挖掘的“艺术”与“科学”的结合：不仅要掌握算法，还要理解业务目标、数据特征及实际约束。

强调“人机协作”在数据挖掘中的角色：工具再强，人的商业判断、领域知识和决策能力仍然关键。

1.6 本章的阅读路径与学习建议

先建立对大数据与数据挖掘关系的宏观认知，再进入数据挖掘的流程与前期技术（数据准备、探索）。

逐步理解六大核心挖掘方法的基本原理与应用场景，结合书内 MATLAB 实例进行实践。

注重案例学习，将理论与实际数据结合，体会从数据准备到模型部署的完整过程。

课后作业

三、对学习的思路与笔记提炼要点

学习路线建议

阶段1：理解大数据与数据挖掘的关系、核心概念与价值定位。

阶段2：熟悉数据挖掘的流程（CRISP-DM/SEMMA等常见模型），掌握数据准备与数据探索的要点。

阶段3：初步掌握六大核心方法的基本思想与适用场景，关注算法的优缺点与适用条件。

阶段4：了解智能优化与时序数据挖掘的基本思路，初步接触 MATLAB 实现与工具（如分类学习机、PCA 等）。

阶段5：结合行业应用案例，分析业务目标、数据源、指标、评估方法等要素。

重要概念与术语

数据挖掘过程模型：CRISP-DM（Business Understanding、Data Understanding、Data Preparation、Modeling、Evaluation、Deployment）。

数据准备要素：数据收集、数据质量分析、数据预处理（清洗、集成、归约、变换）。

核心方法类别：关联规则、回归、分类、聚类、预测、诊断。

降维与变量处理：主成分分析（PCA）、衍生变量、离散化、规范化。

实践与工具

书中以 MATLAB 为工具，提供了“MATLAB 数据挖掘快速入门”和“MATLAB 集成数据挖掘工具 Classification Learner”等内容的实操导向。

关注代码实现与案例应用，理解从数据读取、预处理、建模到评估的完整流程。

课后作业

四、可操作的学习清单

阅读与笔记

梳理大数据四要素与价值的关系，摘录定义与场景。

列出数据挖掘六大核心方法的基本原理与常用算法，并标注适用场景。

记录CRISP-DM六大阶段的要点与具体活动。

实践部分

运行书中提供的 MATLAB 快速入门实例，完成数据读取、探索、预处理、建模的最小可行流程。

使用 Classification Learner 对一个小数据集进行分类任务，比较不同分类器的性能。

结合具体行业案例，尝试给出一个简短的数据挖掘计划草案（目标、数据源、评估指标、潜在风险）。

思考与应用

反思“技术驱动”与“应用驱动”的关系，写一段短评说明在实际项目中如何平衡两者。

思考数据质量、数据隐私与成本在大数据项目中的权衡点，并列出可执行的改进点。

课后作业

整理本章上页PPT“本章概念汇总”，形成笔记。

1. 大数据（Big Data）

理解要点（教材侧重点）：大数据的核心特征不只是“数据大”，而是与之相关的复杂性与价值获取方式。教材在“何为大数据/大数据特点”相关章节强调大数据具有体量大、多样性、价值密度低、速度快等特点（用于说明大数据分析与传统分析的差异）。

2. 数据挖掘（Data Mining）

教材给出了较典型的定义方向：

数据挖掘（DataMining）：从大量的、不完全的、有噪声的、模糊的、随机的实际应用数据中，提取隐含的、事先不知道的、有价值的信息/知识。

教材还进一步指出：数据挖掘的目标是发现隐藏规律，并在一定程度上自动化这一过程（相对传统 OLAP 的更手工/更偏分析报告的方式）。

课后作业

3. 数据降维（Dimensionality Reduction）

教材在“大数据的降维”中给出方法路线：

大数据量可能超过处理能力，因此处理后通常需要降维；

降维可以分级逐层做：

1) 抽样降维

2) 抽取有用变量

3) 再用经典降维方法（如 PCA）做进一步的“变形降维”（把高维映射/变换到低维）

教材也提到另一类思想：

分散式降维：将大数据映射为小单元计算，再对结果整合（与 Map-Reduce 框架思路相关）。

4. 有监督（supervised） / 无监督（unsupervised）

教材在“数据挖掘模型结构/流程”里给出了一个很实用的归纳：

数据挖掘常见的模型可分为 有监督模型 和 无监督模型。

有监督：训练数据中有“已知结果/标签”，模型学习输入到输出的映射（例如：分类、回归、预测等常对应有监督框架）。

无监督：训练时没有标签，主要做结构发现，例如 聚类、关联 等无监督任务。

教材在图示中列举了示例算法方向（例如：PCA 放在“数据降维”常联系的无监督结构里；聚类 K-means 等；有监督里回归/分类/预测等）。

课后作业

5. 结构化 / 半结构化 / 非结构化数据

教材在“数据的存在形式”里给了非常清晰的划分与例子：

结构化数据（Structured Data）：简单说就是数据库；典型场景：ERP、财务系统、医疗HIS、教育一卡通、政府审批等。

非结构化数据（Non-Structured Data）：视频、音频、图片、图像、文档、文本等；典型场景：医疗影像、教育视频点播、视频监控、GIS、文件服务器等。

半结构化数据（semi-Structured Data）：邮件、HTML、报表、资源库等；典型场景：邮件系统、WEB集群、教学资源库、档案系统等。

并且教材还把三者对应的系统需求也顺带给了：存储、备份、共享/归档等。

6. 数据预处理（Data Preprocessing）与数据清洗（Data Cleaning）

教材把数据准备/预处理作为数据挖掘的重点环节，并指出：

数据几乎不可能完美，现实世界会有缺失、噪声、错误、不一致等问题；为得到准确、完整、一致性较好的数据，必须做预处理。

课后作业

7. 数据标准化（Normalization）与数据归一化（你这里可能需要区分概念）

教材在“数据变换—标准化”部分给出了标准化（Normalization）的定义与常用方法：

标准化（Normalization）：把数据按比例缩放，使其落入一个小的特定区间，目的是去除单位限制/让不同量级指标便于比较与加权。

教材特别点了两类常用：

0-1 标准化（离差标准化）：映射到 $[0,1]$

Z-score 标准化（标准差标准化）：映射到标准正态（均值 0，标准差 1）

8. 衍生变量（Derived Variable）

教材在“衍生变量”章节给出定义：

衍生变量：由已有变量通过不同形式的组合/变换得到的新变量。

例如：已知质量、长度、体积，可以衍生密度 = 质量/体积、线密度 = 质量/长度

教材还强调在数据挖掘过程中通常需要衍生变量以获得更多可用信息。