
数据回归分析与模型探究

线性回归、Logistic回归及《白话机器学习》读书笔记

Data Regression Analysis




汇报目录

AGENDA

1. 数据回归方法与基本步骤
2. 一元与多元线性回归模型
3. Logistic回归模型及其特点
4. 线性与Logistic回归的区别与联系
5. 《白话机器学习》第六章读书笔记

建立回归模型的5个标准步骤



一元线性回归探究单一变量的线性影响

1. 模型含义

一元线性回归是最基础的数据回归模型，主要用于探究单一自变量对因变量产生的线性影响。

2. 变量释义

- Y ：因变量
- x ：自变量（非随机变量因素）
- β_0, β_1 ：未知的回归系数
- ε ：随机误差，满足均值 $E(\varepsilon) = 0$ ，方差 $\text{var}(\varepsilon) = \sigma^2$

基本数学模型

$$Y = \beta_0 + \beta_1 x + \varepsilon$$

经验模型（利用最小二乘法估计）

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

模型评估：决定系数

$$R^2 = 1 - \frac{SSE}{SST}$$

R^2 越接近 1，表示观测值与拟合值越靠近，回归效果越好。

多元回归引入多个变量以衡量综合影响

基本数学模型

$$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p + \varepsilon$$

矩阵表达形式

$$Y = X\beta + \varepsilon$$

矩阵构成

- $Y = [y_1, y_2, \dots, y_n]^T$
- $\beta = [\beta_0, \beta_1, \dots, \beta_p]^T$
- $\varepsilon = [\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n]^T$

多因素综合分析

现实世界中，结果往往受多个因素共同作用。多元线性回归通过引入 p 个非随机解释变量，大幅提升了复杂系统的刻画能力。

核心变量释义

- **观测向量** Y ：被解释变量组成的 n 维列向量
- **设计矩阵** X ：自变量观测值组成的数据矩阵
- **待估计向量** β ：包含全部回归系数
- **随机误差** ε ：假定 $\varepsilon \sim N(0, \sigma^2 I_n)$

Logistic回归通过指数映射解决分类预测

当因变量是**定性变量**（如 0 或 1，代表企业破产或健康、股票涨跌）时，普通线性回归不再适用。此时采用 Logistic 回归，以探究某分类现象发生的**概率 p** 与各因素的关系。

Logistic 回归基本形式（概率预测）

$$p(Y = 1|x_1, \dots, x_k) = \frac{\exp(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k)}{1 + \exp(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k)}$$

对数变换机制

对上述公式进行变形，即可将其转化为线性回归结构：

$$\ln\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k$$

实际映射处理

由于样本中 Y 只能取 0 或 1，直接求对数无意义。实际中常定义一种单调连续的概率函数 π ($0 < \pi < 1$)，将原始数据进行映射处理，最后反映射求出真实 p 值。

线性回归与Logistic回归的本质差异

普通线性回归 (Linear Regression)

预测目标

预测**定量的连续型变量**。例如：预测具体的房屋价格、下个季度的销售额、身高等。

数学联系

直接拟合自变量与因变量的线性关系方程式：

$$Y = X\beta + \epsilon$$

适用场景

适用于各变量间具有明确的线性相关性场景，用以解释系统变化规律。

逻辑回归 (Logistic Regression)

预测目标

预测**定性的离散型变量**。本质上是计算某一分类事件发生的**概率大小**，而非绝对数值。

数学联系

通过对数变换，巧妙地将概率 p 转化为线性回归问题求解。
两者在**参数估计上具有相似的数学处理逻辑**。

适用场景

广泛应用于疾病诊断（是否患病）、信用风险评估（是否违约）等“是与非”二分类预测任务。

《白话机器学习》笔记 (1): 趋势与优化思路

1. 寻找最佳趋势线

回归分析的核心在于寻找最佳拟合线（趋势线）。趋势线不仅是最直观的预测工具，还在本质上反映了数据演变的方向。

通过构建带权重的**组合预测变量**：

- 能够极大改善预测结果的准确度
- 使得直接比较各个预测变量的“强弱”影响成为可能，增强模型的可解释性

2. 梯度下降的优化哲学

当无法通过直接解方程获取最优权重时，梯度下降法提供了极为关键的通用求解思路。

算法运作机制：

它首先初步猜测一组权重，接着通过不断迭代调整权重——永远朝着使整体预测误差下降“最陡”的方向前进，最终抵达误差最低点。

*注：普通回归分析中极少陷入局部最优（凹坑），该方法稳健性较强。

《白话机器学习》笔记 (2): 系数认知与局限性

3. 标准化回归系数

回归系数代表变量的**相对增量影响**。但若度量单位不同，直接比较系数大小会导致严重误判。

标准化处理至关重要：

只有经过单位统一（标准化）后的“标准化回归系数”，才能准确比较不同变量的强弱。在单变量模型中，它直接等同于**相关系数**，反映了关联方向与强度。

4. 模型的局限性反思

在实际应用中，数据回归存在四项不可忽视的天然局限：

- **对异常值极度敏感：** 少数离群点可能拉偏整条趋势线
- **多重共线性问题：** 高度相关的预测变量组会导致各自的权重严重失真
- **仅限线性趋势：** 无法天然拟合复杂的弯曲演变
- **因果谬误：** 回归只揭示强“相关”，绝不代表两者间存在“因果”

感谢聆听

数据回归为理解世界提供了量化的视角