

Classification & KNN

机器学习分类算法与KNN原理

核心逻辑探究及《白话机器学习》读书笔记

汇报目录

AGENDA

1. 分类算法的基本概念

2. 分类算法的训练测试逻辑

3. KNN算法的核心思想

4. KNN算法的具体步骤

5. 读书笔记：KNN的调参与局限

6. 读书笔记：决策树的生成原理

7. 读书笔记：决策树的优劣与演进

分类算法的核心概念框架

分类 (Classification)

对现有数据进行学习，得到一个目标函数或规则，把每个属性集准确映射到一个预先定义的**类标号**。

训练集 (Training Set)

由已知特定类标签的数据记录组成。每一条记录包含若干属性构成的特征向量。它是系统生成模型的**经验输入**。

模型 (Classification Model)

通过学习得到的目标函数或规则。

- **描述性建模**：用于区分不同类对象的解释性工具。
- **预测性建模**：用于预测未知记录类别。

分类算法“两步走”的基础逻辑

在构造模型之前，首先需将带类标号的完整数据集随机划分为**训练数据集**和**测试数据集**。

第一阶段：训练 (归纳)

有指导的学习：

系统分析训练集中各属性描述的数据元组，归纳其与预定义类标号间的内在联系，从而建立能够准确拟合数据的**分类模型**。

第二阶段：测试 (评估)

检验泛化能力：

使用未参与训练的检验集 (Test Set) 对已生成的模型进行评估。测算该模型对未知记录的**分类准确率**。

最终应用：推论预测

投入真实业务场景：

若模型在测试阶段的准确率可接受，则将其应用于业务，对未来带有未知类标号的新输入数据进行正式的**预测判定**。

KNN算法基于邻近度的核心判别思想

1. 核心理念

“物以类聚，人以群分”。给定一个类标号未知的样例，找出距离它最近的 **K 个数据点**（即 K-最近邻）作为判定参考。其依据在于相同特征空间内的点往往具有相似的属性。

2. 判别准则

采取**多数表决方案**：如果这 K 个近邻中包含多个类标号，则将该未知样例指派到其最近邻中出现频率最高（多数）的类。若平局则可随机选择。

算法应用拓展

除了用于离散类别的**分类判定**外，KNN 也可用于**连续值预测**：

不再使用简单的多数表决，而是通过合计周围 K 个数据点的值进行**加权平均**（距离越近的邻居权重越大），从而预估目标数据点的真实连续数值。

KNN算法的距离计算与迭代步骤

Step 1

初始化配置：初始化距离变量为系统最大值，准备接收后续计算。

Step 2

距离计算：逐个计算未知样本与训练集中每个已知样本的距离 (dist)。

Step 3

维护近邻集：得到目前K个最近邻样本中的最大距离 maxdist。如果 dist 小于 maxdist，则将该训练样本作为新的 K-最近邻样本更新集合。

Step 4

循环迭代：重复上述计算与比较步骤，直到未知样本和所有训练样本的距离都计算完毕。

Step 5

多数表决：统计此时确定的 K 个最近邻样本中每个类别出现的次数。最终选择出现频率最大的类别作为未知样本的类别。

KNN调优权衡与适用维度的局限性

关键参数：K 值的选择

KNN 算法的性能高度依赖周围参考邻居的数量（K 值）：

- **K值太小**：预测目标极易产生变动性，随机噪声所产生的误差会被放大。
- **K值太大**：模型尝试与更远的“邻居”匹配，决策面过于平滑，导致数据中隐含的真实模式被忽略。

在实践中，最佳的 K 值（二分类常设为奇数以防平局）通常需要通过**交叉验证法**来确定，以期将预测误差降至最低。

算法的两大核心局限

1. 类别不平衡问题：

当各类样本规模悬殊时，属于最小类别的少数派数据极易被占据多数的大类数据所“掩盖”。

解决对策：引入加权投票法，距离越近权重越大。

2. 预测变量过多（维度灾难）：

高维空间下距离计算量剧增，且距离度量可能失效；同时，大量无用冗余变量会干扰判定。

解决对策：预先采用降维技术提取最具影响力的特征。

决策树通过递归拆分追求最大同质性

1. 生成逻辑：递归拆分


决策树通过询问一系列**二元选择题**（如：是否属于某一特征）不断向下分支。核心目标是把数据点进行拆分，并最大限度地提高每一次拆分后子群组的**同质性**（即同类数据聚集在一起）。

2. 具体生长步骤

- **步骤 1：** 确定一个最佳二元问题，将当前数据点一分为二。
- **步骤 2：** 针对产生的新节点重复步骤 1，以此类推。

3. 终止生长的条件

- 叶节点内的数据已全属同一类或完全同质；
- 节点内剩余的样本数量过少（如少于 5 个）；
- 进一步的分支已无法再提高群组同质性。



决策树的白盒优势与集成演进方向

模型的原生优势

- **解释性极强：**决策过程完全白盒化，极易实现可视化，非技术人员也能轻松理解树的判断逻辑。
- **耐扰性较高：**分支建立在最佳二元选择题之上，它能自动忽略那些不显著的变量，因而对少数异常值（离群点）有较好的天然抵抗力。

存在的核心痛点

- **极度不稳定：**数据样本的细微变动可能会让树的生长结构面目全非；为追求每个节点的最佳拆分，模型极易陷入“**过拟合**”陷阱。
- **贪心导致的次优解：**生成时遵循局部最优（贪心算法），每次都抓取当前最佳切割点，但这并不能保证整体生成的树具有全局最高准确率。

进阶演进：放弃单打独斗，拥抱集成模型

为了克服单棵树的不稳定与不准确，现代算法通过综合生成大量具有差异化的决策树组建“**随机森林**”，或采用“**梯度提升**”策略不断修正预测错误，从而在牺牲部分可视化的前提下，大幅增强模型的全局精度。

感谢聆听

掌握分类底层逻辑，构建稳健数据认知