

—


聚类分析

与K-means算法

无监督学习中的代表性方法

姓名：黄陈熙

学号：202321054011



目录

AGENDA

01 聚类与“簇”的概念

02 度量方法与距离

03 K-means原理与步骤

04 HC层次聚类流程

05 树状图与聚类解释

06 K-means读书笔记

07 K-means与HC对比

08 总结与Q&A

聚类与“簇”的概念

无监督条件下的数据探索与模式发现

01. 核心定义

聚类：在无监督条件下将数据划分为若干组，使组内相似度高、组间差异大。

簇：由相似样本构成的集合。

02. 为什么需要聚类


探索性分析：发现数据内在结构与模式（如用户分群、图像分割）。

表示学习：用簇作为代表点，实现数据压缩与降维。

03. 常见假设与优化目标


前提是样本间的**相似度可被定量度量**。

目标通常是使特定的目标函数（如簇内平方和）最小化，或形成最清晰的层次。



度量方法与距离

核心：如何定量衡量样本之间的“相似性”



欧式距离 (Euclidean Distance)

公式：空间中两点的直线距离。

直觉上就是几何距离。

特点：对数值“尺度”极敏感。

使用前必须进行标准化或归一化处理。

适用场景：连续数值型特征。

✓ 传感器数据、房价、尺寸预测等具备物理量纲的数值。

VS

余弦距离 (Cosine Distance)

公式：衡量两向量夹角，距离 = $1 - \cos(\theta)$

计算向量间的方向一致性。

特点：关注“方向”而非“长度/大小”。

对文本等特征的绝对频次不敏感。

适用场景：高维稀疏特征。

✓ 文本挖掘(TF-IDF)、词向量(Word Embedding)、推荐系统偏好。

K-means: 原理与步骤

最小化簇内平方和(SSE)的交替优化策略

初始化质心

选择簇数 K ，并随机或使用K-means++策略初始化 K 个质心。

分配样本 (Assignment)


计算每个样本到所有质心的距离，将其指派给距离最近的簇。

更新质心 (Update)

固定簇划分，用当前簇内所有样本的均值向量更新该质心位置。

判断收敛

若质心位置几乎不再变化，或达到最大迭代次数上限，则算法停止；否则返回步骤2。



HC：凝聚型层次聚类算法过程

自底向上构建层次化簇结构的过程



簇间距离 (Linkage) 选择策略

Single Linkage (最短距离)

两簇中最接近样本间的距离。易引发链式反应。

Complete Linkage (最远距离)

两簇中最远样本间的距离。产生的簇较紧凑。

Average Linkage (平均距离)

两簇所有样本间距离的平均。折中方案稳健性好。

Ward法 (离差平方和) 最常用

最小化合并后的簇内方差增量，常与欧式配合。

树状图与聚类划分

如何看懂Dendrogram并选择切割线(Cut Height)

树状图怎么读？

纵轴：表示合并距离（或相异度），合并时的纵轴高度越高，说明这两部分差异越大。

横轴：底部节点代表单个样本或非常小的初始簇。


“聚成5类”的几何意义

在树状图上画一条水平的**切割线(Cut line)**。当这条水平线从上往下移动，直到与树状图的交叉点（向下的竖线分支）正好为 **5** 个时，得到的就是 5 个簇。

实践切割建议

寻找最大跳跃：在纵轴上合并距离出现“最长一段无合并的空白区”切割最稳健。

结合业务可解释性：指标最优不等于业务最优，需配合实际分析。



《白话机器学习》读书笔记

K-means章节核心要点摘录与个人总结

“K-means 本质上是‘用 K 个中心点代表整个数据集’的迭代分配-更新方法，简单高效但十分依赖合理的 K 值选择与初值设定。”

直觉与迭代

质心就是簇的“代表”。让每个点不断向代表靠拢，代表再根据身边的人重新找中心。分配→更新→重复。

易错：距离主导问题

特征间尺度不一致时，数值大的特征会“吃掉”数值小的特征（距离主导）。聚类前必须进行数据标准化处理。

初始化“看脸”

如果初值落在了错误位置，容易陷入局部最优解。实务中应多次随机运行取SSE最小，或使用K-means++。

何时会失败？

偏好“近似球形、大小相近”的簇。当面对非球形（如环状）、或者密度/大小相差极大的分布时容易失效。

K-means 与 层次聚类(HC) 核心对比

理解算法边界，在实际业务中做正确的选择

对比维度	K-means	Hierarchical Clustering (HC)
输入需求	需提前指定 K 值并给定初始点	无需预先给定 K，事后切割决定
输出形式	对数据集的“一次性固定硬划分”	全连接的层次树状图（Dendrogram）
时空复杂度	通常为 $O(N)$ 级别，对大数据较友好	通常为 $O(N^2) \sim O(N^3)$ 级别，耗内存算力
簇形状假设	偏好“近似球形、尺寸相近”的簇	对形状无绝对假设（取决于选用的 Linkage），Single 更容忍不规则形状

选型建议：

数据量大、需要快速产出迭代时首选 **K-means**；想探索内在细致结构、样本量中小且注重解释性时优先 **HC (搭配Ward法)**。

三句总结 Takeaways

1. 聚类是无监督学习的核心工具，关键在于“相似度度量”的选择。
2. K-means 用质心迭代优化，适合大规模快速分群，但依赖 K 与初始化。
3. HC 提供层次结构与树状图，便于解释，但计算成本更高。