

事务矩阵中行与列的严谨定义

关联规则挖掘的基础是事务数据库（Transaction Database），它通常被抽象为一个布尔型矩阵。在这个矩阵中，行和列有着特定的业务含义。

行 (Row) 的定义

代表一个**独立的事务（Transaction）**，是分析的最小独立样本单位。

- **在商品关联分析中：**

一行代表一次顾客的购买行为，例如一张超市购物小票或一笔网络订单。

- **在关联选股分析中：**

一行代表一个特定的时间观察窗口，例如某一个具体的交易日或交易周。

列 (Column) 的定义

代表一个参与关联计算的**具体项目（Item）**。

- **在商品关联分析中：**

一列代表一种具体的商品品类，如“牛奶”、“面包”、“尿布”。

- **在关联选股分析中：**

一列代表一个具体的行业板块，或者单只股票。

注：矩阵内的元素值通常为1（项目在事务中出现/行业大涨）或0（未出现/未涨）。

Association Rules & Apriori

关联规则与Apriori 算法应用探究

关联选股、矩阵定义、商品图谱与算法流程



汇报目录

1. 行业关联选股的背景知识

2. 关联分析中矩阵行与列的定义

3. 商品关联分析：随机数据与知识图谱

4. Apriori算法的基本思想

5. Apriori算法的具体过程

利用行业联动滞后性进行关联选股

背景痛点

在复杂多变的股市中，精准选择个股难度极大。但由于资金轮动和产业链的上下游关系，行业板块之间往往存在明显的联动效应。

关联策略思路

- **挖掘强关联**：利用数据挖掘从历史交易数据中找出具有强“共涨”关系的行业组合。
- **捕捉滞后补涨**：当某一个或多个先导行业出现明显涨势时，若其强关联的跟随行业尚未启动，则在该跟随行业中选择典型代表股票买入。

先导行业 (启动)



跟随行业 (未动)



买入滞后行业的典型个股
等待补涨效应


商品关联分析：随机数据与知识图谱

从数据到可视化拓扑

单纯的二值化事务矩阵冰冷且难以直接洞察，构建知识图谱（共现网络）能将其转化为直观的网状结构。

图谱元素解析：

- **节点 (Node)**：代表具体的商品（如 Milk, Bread）。
- **连线 (Edge)**：代表两种商品在同一笔订单中同时出现过。
- **权重 (Weight)**：连线越粗，说明商品间共同被购买的次数越多，关联强度越高。



Apriori算法基于先验性质压缩搜索空间

Apriori 算法的目标是在庞大的事务数据库中高效找出支持度大于给定阈值的**频繁项集**。由于穷举所有项集组合会导致“组合爆炸”，算法巧妙地利用了一条**先验性质**来大幅裁剪搜索分支（剪枝）。

核心剪枝原理 (Apriori 性质)

如果一个项集是频繁的，那么它的**所有非空子集也必定是频繁的**。
反之，如果某一个子集是**非频繁的**，则包含它的任何超集**绝不可能是频繁的**。

逐层搜索策略

采用自底向上的迭代：先扫描出频繁 1-项集，以此为基础生成并筛选频繁 2-项集，直到无法再找到更高阶的项集为止。

剪枝的实际作用

避免对明显不可能达标的项集组合进行无意义的数据库扫描与支持度计数，极大提升了大数据集下的挖掘效率。

Apriori算法通过连接与剪枝逐层迭代

1. 扫描与初始化

扫描全部数据记录，统计单项出现次数。剔除未达最小支持度阈值的单项，保留下来的形成**频繁 1-项集 (L1)**。

2. 连接步 (Join)

基于上一轮找到的频繁 (k-1)-项集，将其与自身进行排列组合连接，以此构造出包含 k 个元素的**候选 k-项集 (Ck)**。

3. 剪枝与确认 (Prune)

利用先验性质预先筛除无效候选，再对剩余候选扫描数据库计数。达标者升级为**频繁 k-项集 (Lk)**。循环执行连接与剪枝直至为空。

4. 规则生成

在所有已发掘出的频繁项集中，根据设定的**最小置信度阈值**进行条件概率计算，最终提取出具有实际业务价值的强关联规则。

感谢聆听

关联规则发掘了数据背后隐藏的共现逻辑