

HOMEWORK

多元线性回归中的分类变量处理

第二部分作业解答：One-Hot 编码与系数解读

Q1: 观察数据集特征与分类变量

1. 数据集属性与分类变量

- 数据集中通常包含多个属性（特征）。根据描述，其中包含数值型变量（如广告费、员工数等）和分类变量。
- **分类变量 (Categorical Variable)**: 本例中为「城市」（如北京、上海、广州）。它表示不同的类别，而不是大小或连续的数量。

2. 可视化：分类变量 vs 因变量（营收）

要展示离散的「城市」对连续的「营收」的影响，最适合的可视化工具是**箱线图 (Boxplot)** 或 **小提琴图 (Violin Plot)**。


实现代码思路 (Seaborn):

```
import seaborn as sns
sns.boxplot(x='城市', y='营收', data=df)
plt.show()
```

Q2: 如何将分类变量转化为 One-Hot 编码?

One-Hot (独热) 编码过程总结:

将一个包含 N 个不同类别的变量，拆分为 N 个新的虚拟列 (Dummy Variables)。如果该行属于某个类别，则对应列标为 1，其余列均标为 0。



实现代码 (Pandas):

```
# 使用 get_dummies 自动转化
df_onehot = pd.get_dummies(
    df,
    columns=['城市']
)
```

Q3: 如何评估模型结果? (R^2)

```
r2_score = model.score(X_test, y_test)
```

评价标准说明:

- R^2 (决定系数) 衡量的是因变量的方差中有多少可以被我们的自变量模型所解释。
- 值域通常在 0 到 1 之间。
- **R^2 越接近 1**, 说明模型将分类变量及其它特征拟合得越好, 预测误差越小。

Q4: 获取系数、截距与最终数学公式

属性权重与截距的获取

- 获取截距 (**b0**): `model.intercept_`
- 获取权重 (**w**): `model.coef_` (返回一个数组, 对应每个特征的权重)

结果分析

经过 One-Hot 编码后, 模型会为每个城市类别分配一个独立的权重。某个城市的系数, 实际上代表了当样本属于该城市时, 对基准营收产生的**独立增量或减量影响**。

最终的数学公式

包含分类变量的多元线性回归公式扩展如下 (假设两个连续变量 x_1, x_2):

$$y = b_0 + w_1x_1 + w_2x_2$$

$$+ w_{\text{北京}} \times I(\text{北京})$$

$$+ w_{\text{上海}} \times I(\text{上海})$$

$$+ w_{\text{广州}} \times I(\text{广州})$$

其中 $I(\text{城市})$ 为指示函数 (即 One-Hot 后的 0 或 1)。对于特定城市的样本, 只有该城市的权重项会被激活并计入总和。

Q5: 分类变量的存在对多元回归带来的影响

本质影响：基准线的平移 (Intercept Shift)

分类变量的引入，相当于为不同的类别（例如不同的城市）提供了**各自独立的“基准起点”**。

- **没有分类变量时**：所有数据被迫在同一条多维超平面上拟合，忽视了群体间固有的客观差异（如上海的市场体量天然大于某个小城市），这会导致残差增大。
- **引入分类变量后**：相当于允许模型在空间中绘制**多条平行的超平面**。它们对数值型自变量（如广告费）的敏感度（斜率）可能一致，但它们在 Y 轴上的截距被 One-Hot 权重调整了，从而极大地提升了模型对异质性数据的解释力和准确率。

总结：分类变量让多元线性回归具备了“因地制宜”的能力，消除了类别差异带来的系统性偏差。

Q6: 为什么不能直接将城市 Label 化 (0, 1, 2)?

答案是：绝不合理。不能直接将无序的分类变量转化为 0、1、2 进行线性计算。

直接使用 0, 1, 2 的错误本质

数字 0, 1, 2 在数学上具备大小关系（序数属性）和等距关系。

如果你把北京设为0，上海设为1，广州设为2。模型在计算时会被迫认为：

- 广州的权重贡献是上海的 2 倍
- 上海位于北京和广州的“中间”

这种人工强加的数字大小和递进关系，完全违背了城市平等的现实逻辑，会严重干扰甚至破坏线性回归的斜率拟合。

One-Hot 编码的合理性

One-Hot 编码将一个变量展开成了多个互斥的布尔维度（0 或 1，即“是”或“否”）。

这样处理后，各个城市在数学上变为了**正交的、彼此独立的维度**。

模型可以为每个城市单独拟合一个权重系数，完美保留了分类变量（名义变量，Nominal）互不从属、不存在大小之分的纯粹属性。

解答完毕

感谢您的查阅与指正