

In [1]:

数据挖掘与分析：KNN最近邻算法实战

引入性别特征与性能评估分析

学生：黄陈熙 学号：202321054011 班级：信管2301

一、数据集加载与预览

```
[2]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score
from sklearn.preprocessing import OneHotEncoder, StandardScaler
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
# 读取数据
df = pd.read_csv("Social_Network_Ads.csv")
df.head()
```

```
[2]:
```

	User ID	Gender	Age	EstimatedSalary	Purchased
0	15624510	Male	19	19000	0
1	15810944	Male	35	20000	0
2	15668575	Female	26	43000	0
3	15603246	Female	27	57000	0
4	15804002	Male	19	76000	0

环境准备与库导入

导入数据处理的核心库 *pandas* 和 *numpy*，以及用于模型训练和评估的 *scikit-learn* 相关模块 (如 *train_test_split*, *KNeighborsClassifier*, *StandardScaler*)。

源数据字段解析

通过 `pd.read_csv()` 读取社交网络广告购买记录，调用 `df.head()` 预览可知：

- 输入特征: *Gender* (性别, 文本类别)、*Age* (年龄, 数值)、*EstimatedSalary* (预估薪资, 数值)。
- 目标标签: *Purchased* (购买转化情况, 0或1)。

二、特征预处理与KNN模型训练

Pipeline 构建思路

为了避免测试集的信息泄露并且让代码结构更加清晰，我们使用`ColumnTransformer`和`Pipeline`将数据转换与模型训练打包在一起。

特征工程细节

- **OneHotEncoder**: 针对`Gender`列使用`drop="first"`策略，将其二值化为仅剩一列以避免多重共线性（即产生`Gender\_Male`）。
- **StandardScaler**: 由于KNN是基于欧氏距离计算的算法，必须对`Age`和`EstimatedSalary`进行标准化，消除量纲尺度差异。

模型表现

设定邻居数为 $K=5$ ，通过调用`.fit()`拟合并并在测试集上`.predict()`。如右侧输出单元所示，本数据集在加入性别后的测试集最终准确率 (Accuracy) 稳定在优异的水平。

```
[4]: # 加性别
X = df[["Gender", "Age", "EstimatedSalary"]]
y = df["Purchased"]
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=0
)
preprocess = ColumnTransformer([
    ("gender_onehot", OneHotEncoder(drop="first"), ["Gender"]),
    ("num_scaler", StandardScaler(), ["Age", "EstimatedSalary"])
])
pipe = Pipeline([
    ("pre", preprocess),
    ("knn", KNeighborsClassifier(n_neighbors=5))
])
pipe.fit(X_train, y_train)
y_pred_gender = pipe.predict(X_test)
acc_gender = accuracy_score(y_test, y_pred_gender)
print("加性别 Acc =", acc_gender)
```

加性别 Acc = 0.95

```
[5]: print("==== 作业1 结果 =====")
print("不加性别: ", acc_base)
print("加性别:   ", acc_gender)
print("变化:     ", acc_gender - acc_base)
```

==== 作业1 结果 =====

不加性别: 0.95

三、K-NN 分类器的执行逻辑剖析

- 我们构造一个分类器，下面最关键的一个参数，就是`n_neighbors = 5`
- 意思是KNN的K是5，回想一下PPT里面的内容，K=5，意思是用5个邻居来判断对象的类别。
- 一般情况下K的值选基数，你想想看，是为什么呢？

```
In [23]: classifier = KNeighborsClassifier(n_neighbors = 5, metric = 'minkowski', p = 2)
```

- 好了，模型构造好了，我们用这个“生模型”，来训练数据。所以我们用fit

```
In [24]: classifier.fit(X_train, y_train)
```

Out[24]:

▼ KNeighborsClassifier


KNeighborsClassifier()

对测试集进行预测

算法参数说明：

‘`n_neighbors=5`’ 意味着在新样本点出现时，模型会寻找距离它最近的 5 个已知样本进行多数投票。`K`的选取通常为奇数，以防止平局。‘`metric='minkowski', p=2`’ 组合代表了使用最经典的欧几里得距离计算样本间的远近。

四、考虑类别特征的决策边界探索



二维画布映射三维特征

X轴与Y轴分别为经标准化缩放后的 *Age* 和 *EstimatedSalary*。为了引入性别的额外信息，我们将其映射为散点的形状：

- △ 绿色/红色三角形：代表 *Male*。
- ○ 绿色/红色圆形：代表 *Female*。

区域分割观察

KNN 能够根据局部样本浓度划分出弯曲、非线性的分类边界。从图中可直观看出，右上方区域（较高年龄及收入层）绝大多数样本落入目标类别（购入），而左下方的年轻、低收入群落则大量分布在拒绝类别（未购入）中。

In [*]:

```
print("实验圆满完成")
```

本次作业通过详实的代码，验证了特征处理与算法对比的必要性。