



决策树与多模型 对比解析

探讨特征缩放、特征选择及分类算法性能差异



新增特征对准确率的影响

在基础特征（年龄、薪资）之上，我们尝试加入“性别”这一新维度。

实验结果表明，模型的预测准确率并未如预期般提升，反而出现了**轻微的下降**（从 0.69 降至 0.68）。


核心启示



特征并非“越多越好”。如果新增的特征与目标变量关联度较低（即含有较大的噪声），决策树可能会在此类特征上进行无意义的分裂。


这不仅增加了树的深度和复杂度，还极大提高了**过拟合 (Overfitting)** 的风险，从而拖累了模型在测试集上的泛化表现。

准确率 (Acc)



决策树为何不需要特征缩放?

我们对同一组数据进行了特征缩放（StandardScaler）与保持原样的对比测试，结果如下：




为什么结果完全一致?

决策树的底层逻辑是寻找特征的相对排序与最佳切分阈值（如：当 Age > 35 且 Salary > 6w）。

无论是 Standardization（标准化）还是 MinMaxScaler（归一化），都属于单调的线性变换。这种变换不会改变数据点之间的拓扑关系与排序，因此也不会改变树结构的分裂逻辑。

结论：在单独使用决策树或随机森林等树模型时，通常可以省去特征缩放步骤。

四大分类算法表现对比



逻辑回归 (0.74) 表现最优

由于我们的虚拟数据集是基于一个带有少量随机噪声的线性方程 (Sigmoid 映射) 生成的, 数据本身具有**较强的线性可分倾向**。

逻辑回归天然擅长捕捉这种全局平滑的线性决策边界, 因此在本次测试中拔得头筹。

决策树 (0.68) vs 随机森林 (0.73)

单棵决策树由于试图通过正交切分 (垂直或水平切割) 去拟合一根倾斜的直线边界, 容易产生阶梯状的过拟合, 对局部噪声敏感。

而**随机森林**通过集成数百棵树并引入随机性, 有效平滑了决策边界, 使得泛化能力大幅提升, 紧追逻辑回归。

窥探黑盒：决策树的 if-else 规则

```
|--- Salary <= 65726.23
|   |--- Age <= 38.11
|   | |--- Salary <= 60024.57
|   | | |--- class: 0
|   | |--- Salary > 60024.57
|   | | |--- class: 1
|   | |--- Age > 38.11
|   | |--- Salary <= 46248.52
|   | | |--- class: 1
|   | |--- Salary > 46248.52
|   | | |--- class: 1
|   | |--- Salary > 65726.23
|   | |--- Age <= 26.46
|   | |--- Salary <= 74028.83
|   | | |--- class: 0
|   | |--- Salary > 74028.83
|   | | |--- class: 1
|   | |--- Age > 26.46
|   | |--- class: 1
```

极致的业务可解释性

如左侧原样输出所示，决策树的内部结构本质上是一系列嵌套的 **条件判断规则**。

相比于深度学习或 KNN 这类“黑盒模型”，决策树能够直接被翻译为人类可读的业务策略（例如：“薪资低于 6.5w 且年龄小于 38 岁的客户倾向于不会购买”）。

这种特性使其在金融风控、医疗诊断等对**决策合规性**和**可追溯性**要求极高的场景下，具有不可替代的价值。

感谢聆听

ANY QUESTIONS ON DECISION TREES?