



K-Means 聚类分析实战

基于鸢尾花 (Iris) 数据集的聚类实验与聚类中心可视化

DATA MINING ASSIGNMENT



Q1: 仅使用花萼长度与宽度 (K=3)


特征受限下的二维聚类

本任务仅利用了鸢尾花数据集的**前两列特征** (Sepal Length 和 Sepal Width)。


由于丢失了另外一半 (花瓣) 的关键信息, 不同种类鸢尾花在二维平面上的边界发生了**明显重叠**。

模型虽然成功找到了 3 个中心点 (图中的红色X), 但对于处于边界交界处的散点, 其分类的置信度较低。

Inertia (簇内误差平方和) 为 37.05。



Q2: 引入全部四个特征 (K=3)



高维特征的降维透视

当我们引入完整的花萼（长度+宽度）与花瓣（长度+宽度）特征后，模型在四维空间中计算欧氏距离。

左图为将四维聚类结果映射回前两个维度的透视图。此时，簇与簇之间的隐式边界更加清晰，模型捕捉到了更高维度的特征差异。

此时整体的 Inertia 上升至 78.85（因为空间维度增加，距离绝对值变大）。

Q3: 探索不同的簇数 (K=2)


强制合并: Inertia的飙升

将超参数 **K** 设定为 2 时, 算法由于配额受限, 强行将原本属于 Versicolor 和 Virginica 的两个相邻亚种合并为了一个单一的大簇 (黄色点)。

由于内部包含了两群具有特征差异的样本, 该簇的内部方差急剧扩大, 导致总 **Inertia** 飙升至 **152.34**。

这直观地证明了 K 值的选择直接决定了聚类的粒度。

K值过小会造成欠拟合 (不同类别被强行合并)。



Q4: 聚类中心代码与可视化解析

```
# 提取 K-Means 聚类中心代码
centers = kmeans.cluster_centers_
print(centers)

# 输出结果 (K=3, 全部4个特征):
[[5.901 2.748 4.393 1.433]
 [5.006 3.428 1.462 0.246]
 [6.850 3.073 5.742 2.071]]
```

几何中心与业务意义

代码提取的 `cluster\_centers\_` 属性返回了一个矩阵，其中每一行代表一个簇的**几何中心点（各维度的均值）**。

在前面的散点图中，我们使用了显眼的**红色“X”**对其进行了可视化标记。这个点代表了该类别鸢尾花的“典型特征画像”。

在新样本进行分类时，模型本质上就是在计算新样本距离哪一个“红X”更近，从而判定其归属。

感谢聆听

ANY QUESTIONS ON K-MEANS CLUSTERING?