

数据挖掘与机器学习第一次作业

南京工业大学 | 信管 2301

姓名

景浩伟

学号

202321054012

班级

信管 2301

主题

数据挖掘基本认知与机器学习入门笔记

课后作业要求

本次作业围绕数据挖掘与机器学习基础内容展开，具体要求如下：

1

阅读参考教材

阅读《参考教材 1 》第 1-2 章、 4-5 章

2

整理读书笔记

阅读《白话机器学习算法》第 1 章并整理读书笔记

3

整理概念汇总

整理第 1 讲 PPT" 本章概念汇总 "，形成笔记

4

作业结构安排


本作业按概念、流程、预处理、读书笔记和小结展开

大数据的基本认知

大数据指规模巨大、类型复杂、增长快速的数据集合。其核心不只是数据量大，而是能否从数据中发现价值。

对管理决策来说，数据越多越需要方法筛选和解释信息。大数据是数据挖掘和机器学习的重要数据基础。

i 大数据的意义不在于“大”本身，而在于从海量数据中提炼出对决策有价值的信息与规律。



大数据 4V 特征



Volume 体量

数据体量巨大，带来存储和计算压力



Variety 多样

类型多样，包括表格、文本、图像、日志等



Velocity 速度

产生和处理速度快，要求及时响应



Value 价值

价值密度低，需要从大量噪声中提炼有用信息

数据挖掘的概念

数据挖掘是从大量、不完全、有噪声的数据中提取潜在有用信息和知识的过程。它不是简单查询，也不是只做统计描述。

本质是把原始数据转化为可解释、可使用的知识。

常见任务类型

关联与预测


发现变量之间的关联关系，对未来趋势进行预测

分类与回归

将数据归入已知类别，或预测连续数值输出

聚类与诊断

发现数据内部自然分组，识别异常与问题根源



数据、信息、知识与决策

从原始数据到最终决策，是一条逐步提炼、逐步升华的认知链路。

1

数据

原始记录，例如订单、点击、分数、指标

2

信息

经过整理后呈现出的事实，例如地区销售结构

3

知识


从信息中总结出的规律，例如某类客户更可能购买

4

决策

根据知识采取行动，例如调整营销策略或风险控制措施

数据挖掘六阶段模型



01

目标定义

明确业务问题和分析目标

02

数据准备

选择数据、质量分析、清洗和转换

03

数据探索

用描述统计和可视化解数据特征

04

模型建立

选择算法并训练模型

05

模型评估

用指标和业务目标共同判断结果

06

模型部署

把模型或结论用于实际应用

数据准备与预处理

原始数据往往存在质量问题，预处理是建模前不可跳过的关键环节。

原始数据常见问题

缺失、异常、重复、格式不一致，这些问题若不处理将直接影响模型可靠性

数据清洗

能减少错误和噪声，提高模型可靠性，是预处理的核心步骤

标准化与归一化

可以消除量纲影响，使不同尺度的变量在建模中具有可比性

衍生变量

来自业务理解，是特征工程的重要部分，能显著提升模型表达能力

学习方式与数据形态

学习方式

有监督学习

训练数据带标签，常用于分类和回归

无监督学习

训练数据无标签，常用于聚类和降维

数据形态

结构化数据

字段固定，适合表格建模，直接用于算法训练

半结构化与非结构化数据

通常需要先解析或提取特征，再进行建模

i 学习方式的选择取决于数据是否带有标签；数据形态决定了预处理的复杂程度。两者共同影响建模路径的选择。

数据降维： PCA 与 t-SNE

降维是在尽量保留主要信息的前提下减少变量数量，是处理高维数据的重要手段。

PCA 主成分分析


通过线性变换形成主成分，适合连续数值变量压缩，保留最大方差方向

t-SNE

强调保持局部邻近关系，常用于高维数据可视化，揭示数据内部聚类结构

降维的局限

降维结果有助于观察结构，但不能替代业务解释，需结合领域知识使用



《白话机器学习算法》第 1 章读书笔记

第 1 章像机器学习入门地图，强调先理解数据和任务目标，而非直接套用算法。

完整学习链路

数据准备、算法选择、训练、调参、评价是一条完整链路，缺少任何一环都会影响最终结果的可信度

理解变量含义

不能只记算法名称，还要判断变量含义和数据类型，这是正确选择和使用算法的前提

变量选择的重要性

如果变量选择不合理，模型再复杂也难以得到可信结果，特征质量优先于模型复杂度

本章概念汇总

本章核心概念可归纳为以下四个层面，构成数据挖掘与机器学习的基础知识框架：

大数据与数据挖掘

大数据提供资源，数据挖掘提供发现规律的方法，两者相辅相成

建模前准备

数据清洗、标准化、归一化和衍生变量属于建模前准备，决定模型质量上限

学习方式

监督学习解决带标签预测问题，无监督学习发现内部结构，各有适用场景

降维方法

PCA、t-SNE 等降维方法帮助理解高维数据，辅助特征分析与可视化

学习小结

第一次作业帮助我建立了从数据到知识的整体框架。通过系统梳理各章节内容，对数据挖掘的全貌有了更清晰的认识。

- ✔ 比记住单个算法更重要的是理解目标、数据、模型和应用之间的关系。

后续回归、分类、聚类、关联规则都可以放入六阶段模型中理解，形成系统性认知。

- 📖 读书笔记要避免照抄概念，应结合实际问题说明方法价值，这是本次作业最重要的方法论收获。

