

数据挖掘与机器学习第二次作业

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

主题

回归分析基础与 Logistic 回归读书笔记

依据

作业说明第二项与《白话机器学习算法》第六章

重点

回归思想、数学模型、Logistic 与线性回归的联系区别

课后作业要求

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

01

基本方法与步骤

整理数据回归方法的基本方法、步骤 (J p125)

03

Logistic 回归模型

整理 Logistic 回归数学模型 (J p144), 说明它与普通回归的联系与区别

02

线性回归模型

整理一元线性回归 (J p126) 和多元线性回归 (J p136) 的基本数学模型

04

读书笔记

阅读《白话机器学习》第六章 "回归", 完成读书笔记

回归方法的基本思想

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

研究目标

回归用于研究变量之间的数量关系，并根据已知变量预测连续型结果

核心任务

找到一个函数，使预测值尽量接近真实值

建模关注点


需要关注变量含义、方向、显著性和解释合理性

实践原则

不能只追求拟合度，还要考虑模型能否服务实际问题

回归分析基本步骤

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301



回归分析需依次完成变量定义、数据清洗、探索性分析、模型建立与参数估计，最后通过 R^2 、残差、显著性和业务解释对模型进行综合评价。

一元线性回归模型

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

数学形式

$$y = b_0 + b_1x + \varepsilon$$

参数说明

- b0 (截距)**：x 为 0 时的理论预测值
- b1 (斜率)**：x 每增加 1 个单位时 y 的平均变化量
- e (误差项)**：模型无法解释的随机波动

适用场景

适合解释一个自变量与一个连续因变量之间的线性关系，是多元回归和 Logistic 回归的基础形式。

i 一元线性回归是最简单的回归形式，便于直观理解斜率与截距的业务含义。

多元线性回归模型

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

数学形式

$$y = b_0 + b_1x_1 + b_2x_2 + \cdots + b_nx_n + \varepsilon$$

多变量建模

同时考虑多个解释变量，更接近真实管理问题

系数解释

每个系数表示其他变量不变时，该变量对 y 的边际影响

多重共线性

变量相关性过强时可能出现多重共线性，影响系数解释

Logistic 回归模型

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

数学形式

$$P(y = 1) = \frac{1}{1 + e^{-(b_0 + b_1x_1 + \dots + b_nx_n)}}$$

输出含义

输出的是某一类别发生的概率，范围在 0 到 1 之间

适用问题

通常用于二分类问题，如是否购买、是否违约、是否流失

分类决策

通过阈值把概率转化为类别判断

Logistic 与线性回归的联系

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

→ 共同基础

二者都以线性组合 $b_0 + b_1x_1 + \dots + b_nx_n$ 为基础

→ 变量理解优先

都要求先理解变量含义，再讨论模型结果

→ 参数估计


都需要估计参数，并解释变量方向和影响大小

→ 思想延伸

Logistic 可看成回归思想在分类问题上的延伸

Logistic 与线性回归的区别

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301



核心差异说明

- 线性回归预测连续数值，Logistic 回归预测类别概率
- 线性回归可直接输出任意实数，Logistic 通过 Sigmoid 压缩到 0 到 1
- 线性回归常用 R^2 评价，Logistic 常用准确率、混淆矩阵、AUC 等评价
- Logistic 更适合二分类任务，不能简单当作普通线性回归使用

《白话机器学习》第六章读书笔记

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

1

回归的本质

第六章强调回归不是只画一条线，而是用数据描述变量关系

2

简单与多元

简单回归便于理解，多元回归更接近真实问题

3

模型评价

评价模型不能只看训练集效果，也要看预测和解释是否可靠

4

个人理解

回归的关键是把数学关系转化为可解释的业务语言

学习小结

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

整体收获

第二次作业让我理解了回归分析的基本框架

模型共性

一元、多元和 Logistic 回归虽然形式不同，但都围绕变量关系展开

后续实验

后续代码实验中， R^2 、系数、截距和混淆矩阵都要结合业务含义解释