

数据挖掘与机器学习第三次作业

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

主题

分类算法基本逻辑、KNN 与决策树读书笔记

依据

作业说明第三项

重点

分类概念、KNN 思想、决策树思想、分类与预测边界

课后作业要求

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

1

整理分类算法基本逻辑

整理分类算法的基本逻辑，整理分类算法的几个基本概念

2

掌握 KNN 算法

整理并掌握 KNN 算法的思想与算法步骤

3

阅读并做读书笔记

阅读《白话机器学习》第七章 KNN、第九章决策树，并做读书笔记

分类算法的基本逻辑

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

学习分类器

分类是根据已有带标签数据学习分类器，再判断新样本所属类别

有监督学习

训练数据中每条样本都有已知类别，这是分类区别于聚类的关键

预测性质

分类结果是一种预测，不是绝对肯定

泛化目标

模型目标是在未知样本上尽可能提高泛化准确率

分类中的基本概念

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

样本

被分类的具体对象

特征

描述样本的变量，如年龄、收入、文本词频

标签


样本的已知类别，如购买或不购买

分类器

从训练数据中学习得到的判断模型

分类算法的一般流程

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301



分类算法的一般流程涵盖数据准备、特征工程、模型训练、评估指标计算以及结合业务场景的结果解释，每个环节缺一不可。

KNN 算法思想

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

核心思想

KNN 的核心是近朱者赤：
新样本属于其邻近样本
中多数类别

距离计算

需要先计算待预测样本
与训练样本之间的距离

K 值含义

K 值表示参考最近邻样本
的数量

K 值影响

K 值过小容易受噪声影响，
K 值过大可能削弱局部结
构

KNN 算法步骤

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

01

确定参数

确定 K 值和距离度量方法

02

计算距离

计算新样本到训练集中每个样本的距离

03

选取近邻

选出距离最近的 K 个样本

04

多数投票

统计这 K 个样本的类别并进行多数投票


05

输出结果

输出票数最多的类别作为预测结果

决策树算法思想

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301



逐步划分

决策树通过一系列判断问题
逐步划分样本

节点含义

每个内部节点代表一个特征
判断，每条分支代表判断结果

叶节点输出

叶节点输出最终类别或预测
结果


优缺点

优点是可解释性强，缺点是
树过深时容易过拟合

KNN 与决策树比较

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

K-近邻算法 (KNN)



依赖特征距离。
需要特征归一化。



比较样本距离。




可解释性较低。



适合分类入门。
具体场景不同。

决策树算法 (Decision Tree)



依赖特征分裂规则。
对特征缩放不敏感。



沿直接路径判断。



可解释性极高。



适合分类入门。
具体场景不同。

特征依赖

KNN 依赖距离，通常需要标准化特征；决策树依赖特征分裂规则，对特征缩放不敏感

预测方式

KNN 预测时需要比较样本距离，决策树预测路径更直观

适用场景

二者都适合入门理解分类，但适用场景和解释方式不同

读书笔记： KNN 与决策树

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

KNN 章节收获

《白话机器学习》 KNN 章节帮助我理解距离和 K 值的影响

决策树章节收获

决策树章节说明机器学习也可以用接近人类判断的方式表达

阅读方法反思

读书时不能只看算法步骤，还要理解为什么要评价模型效果

分类问题核心

分类问题的核心是用已有标签经验判断未知样本

学习小结

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

基本认识建立

第三次作业建立了我对分类算法的基本认识

两种算法侧重

KNN 强调样本之间的距离，决策树强调可解释的判断规则

模型评价必要性

分类模型输出的是概率或类别判断，仍然需要用测试集评价