

数据挖掘与机器学习第四次作业

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

主题

聚类算法、距离度量、K-means 与 HC

依据

第 4 讲聚类算法 PPT 与作业说明

重点

簇、欧式距离、余弦距离、K-means 步骤、层次聚类图解释

课后作业要求

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

01

整理簇的概念

J p187-188

03

整理 K-means 算法原理和步骤

J p192

05

掌握 PPT 第 26 页 HC 聚类结果图

如果聚成 5 类，画一条直线

02

整理类度量的两种基本方法

欧式距离与余弦距离 (J p189-190)

04

整理 HC 算法过程

J p198

06

阅读《白话机器学习》 K-means 章

整理读书笔记

簇的概念

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

定义

簇是由相似对象组成的集合。

相似性原则

同一簇内对象相似度较高，不同簇之间差异较大。

学习类型

聚类是无监督学习，没有事先给定标签。

结果解释

聚类结果要结合业务背景解释，不能只看算法输出。

聚类与分类的区别

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

维度	分类	聚类
类别先验	事先知道类别	事先不知道类别
训练数据	训练数据有标签	需要从数据结构中探索分组
学习类型	有监督学习	无监督学习
目标	强调预测	强调发现结构

欧式距离

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

定义

欧式距离衡量两个点在空间中的直线距离。

适用场景

适合连续数值变量，但会受量纲影响，因此常需要标准化。

相似性判断

距离越小，表示样本越相似。

二维公式

$$d = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$$

多维推广

$$d = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

i 量纲不同时，需先对变量进行标准化处理，再计算欧式距离。

余弦距离

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

余弦相似度公式

$$\cos(\theta) = \frac{\vec{A} \cdot \vec{B}}{|\vec{A}| |\vec{B}|}$$

ⓘ 夹角越小，余弦值越接近 1，相似度越高。

关注方向

余弦相似度关注向量夹角，而不是绝对长度。

适用场景


常用于文本、用户偏好等高维稀疏数据。

与欧式距离对比

与欧式距离相比，它更强调方向上的相似，而非绝对距离。

K-means 算法原理

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301



K-means 通过反复迭代 " 分配—更新 " 两个步骤，使各簇内部的样本尽可能相似，直到聚类中心或样本归属基本稳定为止。

K-means 算法特点

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

优点：简洁高效

算法简洁、效率较高，适合较大数据集。

局限：K 值依赖

K 值需要人为设定，会影响最终聚类结果。

局限：初始敏感


初始中心不同，结果可能不同，存在局部最优问题。

局限：对异常值敏感

对离群点和变量尺度较敏感，需预处理数据。

HC 层次聚类过程

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301



层次聚类（HC）采用自底向上的凝聚策略，每次合并距离最近的两个簇，最终可用树状图（Dendrogram）完整展示样本的合并过程与层次结构。

HC 树状图理解

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

纵轴含义

树状图中纵向高度表示簇之间合并时的距离。

划分方法

如果要聚成 5 类，可在树状图上画一条水平线。

读图规则

水平线与多少条垂直分支相交，就得到多少个簇。

学习重点

PPT 第 26 页的关键是会看图，而不是只记函数名称。

📄 操作示例：聚成 5 类

在树状图上，从上往下找到第一条水平线，使其恰好与 5 条垂直分支相交，即可将样本划分为 5 个簇。水平线位置越低，簇内相似度越高；位置越高，簇的数量越少。

树状图的核心价值在于：可以直观地观察不同聚类数目下的样本分组情况，无需重新运行算法。

K-means 读书笔记

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

—— 读《白话机器学习》K-means 章节整理

核心思想

K-means 体现了先假设类别数，再迭代优化中心的思想，是无监督学习的典型范式。

实际使用建议

实际使用时要比较不同 K 值，并结合可视化和业务解释，避免机械套用算法。

理解无监督学习

它适合帮助我们理解无监督学习的基本逻辑：在没有标签的情况下，通过结构发现规律。

聚类的本质

聚类不是给出标准答案，而是提供观察数据结构的角度，结果需结合场景判断。

学习小结

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

核心认识

第四次作业让我理解了聚类的核心是相似性度量，选择合适的度量方式直接影响聚类效果。

距离度量

欧式距离和余弦距离体现了不同的相似性定义，前者关注空间距离，后者关注方向一致性。

算法对比

K-means 适合快速划分大数据集，HC 适合展示层次结构，两者各有适用场景。