

数据挖掘与机器学习第五次作业

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

作业主题

- 关联选股、商品关联分析与 Apriori 算法
- 依据：作业说明第五项

重点内容

- 背景知识
- 矩阵含义
- 随机数据
- 知识图谱
- Apriori 过程

课后作业要求

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

1

背景知识整理

整理有关关联选股的背景知识

2

矩阵定义说明

清楚说明矩阵行与列的定义

3

商品关联分析

生成随机数据，生成知识图谱

4

算法过程整理

整理 Apriori 算法过程

关联规则基本思想

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

核心概念

- 关联规则用于发现项目之间经常同时出现的关系
- 典型形式是 $X \Rightarrow Y$ ，表示出现X时也容易出现Y
- 常见案例是购物篮分析，例如啤酒与尿布
- 在选股场景中，可用于观察行业或股票表现的联动关系

购物篮分析

识别啤酒与尿布共现

关联规则两步法

关联选股观察

行业与股票联动检测

关联选股背景知识

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

股票联动性

股票不是孤立波动，行业、主题和资金风格会产生联动

关联选股关注点

关注哪些行业或股票经常同时上涨、同时下跌或同向变化

局限性说明

不能直接保证收益，但能提供候选组合和观察线索

实际应用要求

需要结合基本面、风险控制和回测验证

矩阵行与列的定义

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

行的含义

- 行可以表示交易日、观察窗口或样本期

列的含义

- 列可以表示行业、股票或商品项目

矩阵元素

- 矩阵元素通常是 0/1，表示某项目在该样本中是否出现
- 如果用于股票，可把涨幅超过阈值记为 1，否则记为 0

样本 / 项目	股票 A	股票 B	股票 C
交易日 1	1	0	1
交易日 2	0	1	1
交易日 3	1	1	0

示例：0/1 事务矩阵，1 表示涨幅超过阈值

随机商品数据示例

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

数据生成说明

- 随机生成若干笔交易，每笔交易包含不同商品
- 商品集合可包括牛奶、面包、鸡蛋、啤酒、尿布等
- 把交易记录转换为 0/1 事务矩阵
- 事务矩阵是 Apriori 算法寻找频繁项集的输入

交易	牛奶	面包	鸡蛋	啤酒	尿布
T1	1	1	0	0	0
T2	0	1	1	1	1
T3	1	0	0	1	1
T4	1	1	1	0	0


随机生成的 0/1 事务矩阵示例

知识图谱表达

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301


图谱构成要素

- 知识图谱可把商品或股票看成节点
- 频繁共现或强关联规则可看成边
- 边的粗细或权重可表示支持度、置信度或提升度
- 图谱表达有助于直观看出项目之间的关联结构



Apriori 算法过程

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301



01	02	03
设定阈值 设定最小支持度和最小置信度	扫描数据库 扫描事务数据库，找出频繁 1 项集	生成候选集 由频繁 k 项集生成候选 k+1 项集
04	05	
剪枝 利用频繁项集的子集也频繁这一性质进行剪枝	生成规则 生成满足阈值的关联规则	

支持度、置信度与提升度

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

支持度

规则中项目共同出现的频率

$$\text{Support}(X \Rightarrow Y) = \frac{|X \cup Y|}{N}$$

置信度

出现 X 时同时出现 Y 的条件概率

$$\text{Confidence}(X \Rightarrow Y) = \frac{|X \cup Y|}{|X|}$$

提升度

X 对 Y 出现概率的提升作用

$$\text{Lift}(X \Rightarrow Y) = \frac{\text{Confidence}(X \Rightarrow Y)}{\text{Support}(Y)}$$

 规则筛选不能只看一个指标，要结合业务含义综合判断。

教材错误与分析提醒

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

关联规则非因果关系

关联规则不是因果关系，只说明共现或条件关系

矩阵行列须先定义

矩阵行列含义必须先定义清楚，否则算法结果无法解释

随机数据仅用于演示

随机数据只用于演示流程，真实选股必须使用真实行情和回测

结论表达须谨慎

选股结论应谨慎表达，不能把关联规则写成稳赚策略

学习小结

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

关联规则的扩展应用

第五次作业把关联规则从购物篮扩展到行业联动理解

Apriori 核心机制

Apriori 的核心是频繁项集搜索与剪枝

知识图谱的作用与局限

知识图谱适合展示关联结构，但仍需结合业务和风险解释