

数据挖掘与机器学习第六次作业

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

实验主题

简单线性回归模型代码实验

数据集

studentscores.csv, 共 25 行

实验重点

X 列向量、回归方程、 R^2 、训练集比例影响

课后作业要求

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

1 列向量说明

说明为什么 X 必须是列向量，变成行向量会怎样

2 显示数学模型

说明如何显示生成的数学模型 $y=b_0+b_1x$

3 R^2 评估解释

解释 R^2 评估结果好坏及本实验 R^2 结果

4 调整训练比例

调整训练 / 测试比例，观察 R^2 变化

5 全量数据训练

剔除测试集，直接用全部数据训练模型

数据读取与 X 列向量

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

数据结构说明

数据列: Hours, Scores

X 形状: [25, 1], Y 形状: [25]

为什么必须是列向量

scikit-learn 要求特征 X 为二维矩阵。即使是单变量回归, 也要写成 $N \times 1$ 列向量, 而不是一维数组。若写成行向量 (形状为 [1, 25]), fit() 方法将报错, 因为样本数与标签数不匹配。

正确写法

```
X =  
dataset.iloc[:,0:1]  
.values
```

形状: [25, 1], 二维列
向量

错误写法

```
X =  
dataset.iloc[:,0].  
values
```

形状: [25], 一维数组,
scikit-learn 无法接受

关键代码：读取与划分

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

```
dataset = pd.read_csv('studentscores.csv')
X = dataset.iloc[:,0:1].values
Y = dataset.iloc[:,1].values
train_test_split(X, Y, test_size=0.2, random_state=0)
```

总样本量

25 行数据

训练集

20 行 (80%)

测试集

5 行 (20%)

随机种子

random_state=0 , 保证可复现

关键代码：训练与预测

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

```
from sklearn.linear_model import LinearRegression
regressor = LinearRegression()
regressor.fit(X_train, Y_train)
Y_pred = regressor.predict(X_test)
```

01

导入模块

从 sklearn.linear_model 导入 LinearRegression

03

拟合训练集

调用 fit(X_train, Y_train) 训练模型

02

实例化模型

创建 LinearRegression 对象 regressor

04

预测测试集

调用 predict(X_test) 得到预测分数 Y_pred

回归方程结果

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

测试集模型

$$y = 2.0182 + 9.9107x$$

全部数据模型

$$y = 2.4837 + 9.7758x$$

斜率含义


学习时间每增加 1 小时，
预测分数平均增加约 9.9
分（测试集模型）或 9.8
分（全量模型）

截距含义

截距是模型在 $x=0$ 时的
理论预测值，实际意义
有限，仅为数学上的基
准值


R² 评估结果

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301



测试集 R²

test_size=0.2，训练集 20 行，测试集 5 行



全部数据 R²


剔除测试集，直接用全部 25 行数据训练

R² 的含义

R² 越接近 1，说明模型对数据的解释能力越强。本实验中 R² 均超过 0.94，说明学习时长与分数之间存在较明显的线性关系，模型拟合效果良好。

训练集比例影响

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301



实验观察

test_size	R ²
0.2	0.9455
0.3	0.9568
0.4	0.9566

❗ 样本较少时，划分比例会明显影响测试集结果。不同的 random_state 也会导致 R^2 波动，因此不能仅凭单次结果判断模型优劣。

预测样例

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

Hours	实际分数	预测分数	误差
1.5	20.0	16.8841	-3.1159
3.2	27.0	33.7323	+6.7323
7.4	69.0	75.3570	+6.3570
2.5	30.0	26.7948	-3.2052

✔ 预测值和真实值接近，说明简单线性关系较清晰，模型在测试集上表现良好。

学习小结

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

1

矩阵输入格式

第六次作业让我理解了 scikit-learn 对特征矩阵的格式要求，X 必须为二维列向量 $[N, 1]$ ，不能使用一维数组。

2

回归方程输出

回归方程可以通过 `regressor.coef_` 和 `regressor.intercept_` 直接读取系数和截距并写出。

3

R^2 的局限性

R^2 不是固定真理，会随训练 / 测试划分比例及随机种子的变化而波动，需多次实验综合判断。

4

全量训练的意义

全部数据训练适合观察整体拟合关系，但不能替代测试集评价，无法反映模型的泛化能力。