

数据挖掘与机器学习第七次作业

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

主题

50_Startups 多元线性回归

数据集

50_Startups.csv , 共 50 行

重点内容

分类变量、one-hot、 R^2 、系数和数学公式

课后作业要求

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

1 观察数据集特征

观察 50_Startups 数据集特征，说明属性数量与分类变量

2 可视化分类变量关系

可视化分类变量 State 和因变量 Profit-Y 之间的关系

3 总结 One-hot 编码过程

总结分类变量转化为 one-hot 的过程，并写出示例代码

4 模型评估与公式

用 R^2 评估模型效果，获得系数和截距并写出数学公式

5 分析分类变量影响

分析分类变量影响，判断 label 编码是否合理

数据集特征观察

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

R&D Spend — X1

数值变量

Administration — X2

数值变量

Marketing Spend — X3

数值变量

State — X4

分类变量

Profit — Y

因变量

i 数据集共包含 4 个自变量（3 个数值变量 + 1 个分类变量）和 1 个因变量，共 50 条样本记录。

State 分类变量分布

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

State 字段包含三个类别：New York、California、Florida，样本分布较为均衡。

New York


17 条记录

California

17 条记录


Florida

16 条记录



城市与 Profit-Y 关系

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301



各城市平均利润

California

平均 Profit-Y : 103905.18

New York

平均 Profit-Y : 113756.45

Florida

平均 Profit-Y : 118774.02



城市均值可作初步观察，但不能脱离投入变量直接下结论。

One-hot 编码过程

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

应用 OneHotEncoder

生成 0/1 哑变量。

合并数值变量

与 R&D、Administration、Marketing 合并。

读取类别变量

读取 State-X4 分类变量。

删除参考列

去除一列以避免虚拟变量陷阱。

❏ 通常删除一列作为基准组，避免虚拟变量陷阱（Dummy Variable Trap），保证回归模型的可识别性。

One-hot 示例代码

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

```
from sklearn.compose import ColumnTransformer
from sklearn.preprocessing import OneHotEncoder
from sklearn.linear_model import LinearRegression

# Step 1: 构建列转换器, 对 State-X4 进行 one-hot 编码, drop='first' 避免虚拟变量陷阱
ct = ColumnTransformer(
    [('encoder', OneHotEncoder(drop='first'), ['State-X4'])],
    remainder='passthrough'
)

# Step 2: 对特征矩阵进行转换
X = ct.fit_transform(dataset.drop(columns=['Profit-Y']))

# Step 3: 训练线性回归模型
model = LinearRegression().fit(X_train, y_train)
```

💡 这样比直接 label 编码更适合无序分类变量, 避免模型误将类别顺序解读为数值大小关系。

模型评估结果

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

0.9347

测试集 R^2

模型对 Profit-Y 波动的解释能力

42554

截距 intercept

intercept = 42554.1676

✓ $R^2 = 0.9347$ ，说明投入变量和城市变量对利润有较强解释力，模型拟合效果良好。

主要系数与公式

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

变量	系数值
cat_State-X4_Florida	-959.2842
cat_State-X4_New York	699.3691
remainder__R&D Spend-X1	0.7735
remainder__Administration-X2	0.0329
remainder__Marketing Spend-X3	0.0366

数学公式（一般形式）：

$$\hat{Profit} = 42554.17 - 959.28 \ x_{Florida} + 699.37 \ x_{NewYork} + 0.7735 \ x_1 + 0.0329 \ x_2 + 0.0366 \ x_3$$

Label 编码是否合理

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

LABEL 编码

存在的问题

- Label 编码会把城市变成 0、1、2，暗含大小顺序
- State 本身是无序分类变量，不应直接当作连续数值
- 如果直接 label 编码，回归系数解释会产生误导

❌ 直接使用 label 编码，模型会错误地认为城市之间存在数值大小关系，导致系数解释失真。

ONE-HOT 编码

更合理的方式

- one-hot 更合理，因为它只表示类别是否出现
- 每个城市对应独立的 0/1 哑变量，无顺序含义
- 删除基准列后，系数表示相对于基准城市的利润差异

✅ 对于无序分类变量，one-hot 编码是线性回归中的标准处理方式。

学习小结

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

1

多元回归更接近真实业务问题

第七次作业说明多元回归更接近真实业务问题，需要同时处理数值变量与分类变量。

2

分类变量必须转换编码

分类变量进入回归前必须转换编码，推荐使用 one-hot 编码处理无序分类变量。

3

指标、系数与业务含义结合解释

模型指标、系数和业务含义要一起解释，不能只报告 R^2 ，需结合实际场景分析系数意义。