

# 数据挖掘与机器学习第八次作业

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

## 实验主题

KNN 与 Logistic 分类实验

## 数据集

Social\_Network\_Ads , 共 400 行

## 实验重点

Gender one-hot 编码、准确率对比、  
K 值和训练比例影响

# 课后作业要求

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

---

## 1 Logistic 回归加入 Gender

加入 Gender 特征并观察结果变化

## 2 KNN 加入性别因素

进行 one-hot 编码，比较准确率是否变化

## 3 KNN 与 Logistic 结果对比

在同一数据集上比较两种模型的差异

## 4 训练集比例与 K 值影响

观察对模型效果的影响，并说明过拟合现象

## 5 修改二维可视化

在 Age/EstimatedSalary 图中体现 Gender 信息

# 数据集与标签


南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

## 标签分布

Purchased 分布: {'0': 257, '1': 143}

Gender 分布: {'Female': 204, 'Male': 196}

📌 标签 Purchased 表示是否购买，属于二分类任务。类别 0（未购买）占多数，存在轻微类别不平衡。



## 特征说明

### Gender

分类变量, Male / Female, 需 one-hot 编码

### Age

数值变量, 表示用户年龄

### EstimatedSalary

数值变量, 表示用户预估薪资

### Purchased

目标标签, 0 或 1, 二分类任务

# Gender one-hot 处理

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

## 为什么需要 one-hot 编码

Gender 是无序分类变量，不能简单当作大小数值。若直接赋值 0/1，模型会误认为存在大小关系，引入错误的数值偏序。

## 编码方式

使用 OneHotEncoder 把 Male/Female 转成 0/1 虚拟变量，再与 Age、EstimatedSalary 合并进入 KNN 或 Logistic 模型。

- ❏ KNN 还需要对数值变量进行标准化，避免量纲差异影响距离计算。



# KNN 加入 Gender 前后比较

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

## 不加 Gender

Acc = 0.95

CM =  $\begin{bmatrix} 55 & 3 \\ 1 & 21 \end{bmatrix}$

## 加入 Gender

Acc = 0.95

CM =  $\begin{bmatrix} 55 & 3 \\ 1 & 21 \end{bmatrix}$

## 结果分析

### 准确率无变化


如果准确率变化不大，说明 Gender 在本次划分中贡献有限。

### 混淆矩阵解读

解释时要结合混淆矩阵，而不是只看一个准确率。混淆矩阵显示两种情况下预测结果完全一致。

# KNN 与 Logistic 结果对比

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301



## KNN (K=5)

Acc = **0.95**

更依赖局部邻近结构，对非线性边界有更强的适应能力。

## Logistic 回归


Acc = **0.9125**

CM = `[[56, 2], [5, 17]]`

给出线性决策边界，更便于解释概率方向。

# K 值对结果的影响

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301



## K 值选择原则

### K 过小 (如 K=1)

容易过拟合, 对训练集噪声敏感, 泛化能力弱。

### K 过大


可能欠拟合, 决策边界过于平滑, 忽略局部结构。

### 最优 K 值选择

应通过验证集或交叉验证选择合适 K 值。本实验 K=3 及以上趋于稳定。

# 训练集比例影响

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301



## 结论分析

**训练数据越多，效果越好**

test\_size=0.2 时训练样本最多，准确率最高（0.95）。

**划分方式影响评价结果**

训练 / 测试划分改变会影响评价结果，不同划分下结论可能不同。

**谨慎对待单次划分**

样本量有限时，单次划分结论要谨慎，建议使用交叉验证。



# 二维可视化修改思路

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

## 可视化设计方案

|                            |                                    |
|----------------------------|------------------------------------|
| 1                          | 2                                  |
| 横轴<br>使用 Age（年龄）           | 纵轴<br>使用 EstimatedSalary（预估薪资）     |
| 3                          | 4                                  |
| 颜色<br>表示 Purchased 标签（0/1） | 点形状 / 边框<br>表示 Gender（Male/Female） |

通过颜色区分购买标签，通过点形状或边框区分性别，这样能同时观察购买标签与性别因素在二维平面上的分布，直观呈现两个维度的信息。


## 可视化目标

在 Age/EstimatedSalary 二维空间中，同时体现 Purchased 标签与 Gender 因素，便于分析性别对购买行为的影响是否存在规律性分布。

# 过拟合理解

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

过拟合指模型对训练数据记得太细，但对新数据泛化较差。



## KNN 中的过拟合

KNN 中  $K=1$  通常更容易过拟合，因为每个预测点只参考最近的 1 个邻居，对训练集噪声极为敏感。

## 缓解过拟合的方法

- 提高  $K$  值，增加参考邻居数量
- 增加训练样本数量
- 使用交叉验证选择超参数

❏ 最终要以测试集表现和业务解释共同判断模型是否合适，不能只看训练集准确率。

# 学习小结

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

01

## 分类变量编码

第八次作业把分类变量编码与分类算法结合起来，Gender 的 one-hot 处理是关键预处理步骤。

02

## 两种模型对比

KNN 和 Logistic 都能解决二分类问题，但模型假设不同。KNN 依赖局部结构，Logistic 给出线性决策边界。

03

## 综合评估方法

准确率必须结合混淆矩阵、K 值和训练比例一起分析，单一指标不足以全面评价模型性能。

### 对比维度

准确率

决策边界

可解释性

Gender 影响

### KNN (K=5)

0.95

非线性，局部结构

较弱

加入后准确率无变化

### Logistic 回归

0.9125

线性，全局结构

较强，可输出概率

可通过系数分析影响