

数据挖掘与机器学习第九次作业

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

实验主题

决策树分类实验

数据集

Social_Network_Ads

实验重点

Gender 特征、特征缩放、模型比较、
树规则输出

课后作业要求

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

1

加入性别因素

加入 Gender 变量，观察准确率 Acc 的变化情况

2

不进行特征缩放

不进行特征缩放，观察预测准确性的变化

3

多模型比较

比较 KNN、Logistic、决策树、随机森林在该数据集上的表现

4

决策树规则输出

把决策树输出的规则展示出来，观察其结构

决策树基础设置

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

基础特征

使用 Age 和 EstimatedSalary 作为基础特征

标签变量


Purchased 表示是否购买 (0/1 二分类)

数据划分

test_size=0.2, random_state=0

分裂准则

决策树 criterion 使用 entropy, 便于理解信息增益思想



加入 Gender 前后比较

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

不加 Gender

Acc = 0.9

CM = [[53, 5], [3, 19]]

加入 Gender

Acc = 0.9125

CM = [[54, 4], [3, 19]]



本实验中可通过准确率和混淆矩阵判断性别变量的贡献。若变化不大，说明主要分裂仍来自 Age 和 EstimatedSalary，Gender 对模型提升有限。

是否需要特征缩放

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

进行缩放

Acc = 0.9

不缩放

Acc = 0.9

CM = [[53, 5], [3, 19]]

原因分析

决策树按阈值分裂，对量纲不敏感，因此特征缩放对其结果影响极小。


与 KNN 对比

决策树通常不像 KNN 那样强依赖标准化，KNN 基于距离计算，量纲影响显著。

多模型表现对比

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

模型



模型	Acc	混淆矩阵 CM
KNN_K5	0.95	[[55, 3], [1, 21]]
Logistic	0.925	[[57, 1], [5, 17]]
DecisionTree	0.9	[[53, 5], [3, 19]]
RandomForest	0.9375	[[55, 3], [2, 20]]



模型选择要兼顾准确率和解释性，不能只看单一指标。

决策树规则输出节选


南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

```
|--- Age_scaled <= 0.61
|   |--- EstimatedSalary_scaled <= 0.60
|   |   |--- Age_scaled <= -0.17
|   |   |   |--- class: 0
|   |   |--- Age_scaled > -0.17
|   |   |   |--- EstimatedSalary_scaled <= -0.07
|   |   |   |   |--- class: 0
|   |   |   |--- EstimatedSalary_scaled > -0.07
```

 树规则可以把模型判断路径直接展示出来，每一条从根节点到叶节点的路径对应一条分类规则，具有良好的可解释性。

决策树图形理解

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301



根节点

树的根节点代表最先使用的分裂条件，通常是信息增益最大的特征。

内部节点

内部节点继续按特征阈值划分样本，逐层细化分类边界。

叶节点


叶节点输出最终预测类别，代表该路径下的分类结果。

过拟合风险

树越深越容易拟合训练集细节，也越可能发生拟合。


随机森林补充理解

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301



SINGLE
DECISION
TREE

高可解释性
单一树结构
容易过拟合



RANDOM
FOREST

多树组合
投票机制
高准确率
低可解释性

组成结构

随机森林由多棵决策树组成，每棵树在随机子样本和随机特征子集上训练。

解释性代价

解释性不如单棵决策树直观，无法像单棵树那样直接输出可读规则。

集成优势

通过集成多个树的结果提升稳定性，准确率可能更高（本实验 $\text{Acc}=0.9375$ ）。

实验用途

本实验用于与 KNN、Logistic、单棵决策树进行横向对比。

学习小结

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

1

决策树优势

第九次作业说明决策树的优势在于可解释性，规则路径可直接输出和理解。

2

特征缩放影响

是否缩放对决策树影响很小，但对KNN影响明显，需根据模型特性决定预处理方式。

3

模型评估原则

模型比较不能只看一个指标，还要考虑解释性和具体应用场景的需求。