

数据挖掘与机器学习第十次作业

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

主题

Iris 鸢尾花 K-means 与层次聚类

数据集

Iris , 共 150 行, 4 个特征

重点内容

花萼两列、全部四列、 $K=2$ 、聚类中心

课后作业要求

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

1

花萼列聚类

用花萼（第 0 列和第 1 列）的数据来聚类

2

全部数据聚类

用所有数据来聚类（所有 4 列）

3

修改 K 值

这里 $K=3$ ，把 K 改成 2 试一试

4

聚类中心分析

查资料分析聚类的其他输出，比如聚类中心代码，并可视化聚类中心

Iris 数据集说明

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

样本数

150

特征列


sepal length (cm), sepal width (cm), petal length (cm), petal width (cm)

真实类别

setosa, versicolor, virginica

标签使用说明

本次聚类不使用真实标签训练，只用于结果对照和理解



花萼两列 K=3 聚类

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301


聚类数量分布

[47, 53, 50]

聚类中心

[[6.813, 3.074], [5.774, 2.692], [5.006, 3.428]]

只用花萼长度和花萼宽度时，类别分离度有限。二维结果便于画散点图观察。



全部四列 K=3 聚类

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

聚类数量分布

[62, 50, 38]

中心数量


共 3 个中心, 每个中心 4 个坐标

聚类中心 (簇 1 示例)

[5.902, 2.748, 4.394, 1.434]

特征完整性

加入花瓣长度和宽度后, 聚类信息更完整



K 从 3 改成 2

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

K=2 聚类数量分布


[97, 53]

K=2 聚类中心

簇 0 : [6.301, 2.887,
4.959, 1.696]

簇 1 : [5.006, 3.37, 1.56,
0.291]

K 值改变会改变类别划分方式。K=2 时模型倾向把 setosa 与非 setosa 区分开。



聚类中心代码

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

```
model = KMeans(n_clusters=3, random_state=42, n_init=20)
model.fit(X)
labels = model.labels_
centers = model.cluster_centers_
```

 centers 就是每个簇在特征空间中的平均位置

model.fit(X)

对特征矩阵 X 执行 K-means 拟合，迭代更新簇中心直至收敛

model.labels_

每个样本所属簇的标签数组，长度与样本数相同

model.cluster_centers_

形状为 (n_clusters, n_features) 的数组，存储每个簇的中心坐标

聚类中心可视化思路

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

散点图绘制样本


二维图中可用散点表示样本，不同颜色表示不同聚类标签

标注聚类中心

用更大的星形或叉号标出聚类中心，使其在图中突出显示

高维数据处理

若使用四维数据，可选取前两列或用 PCA 降维后展示



绘制散点

着色标签

标注中心

降维展示

K-means 与 HC 对照

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

K-means

需要预先指定 K 值

适合较大数据集，计算效率高

结果受初始中心影响，需多次运行

层次聚类（HC）

可以通过树状图观察层次结构

适合展示合并过程，无需预设 K

两种方法都需结合可视化和业务含义解释

对比维度

K-means

层次聚类（HC）

K 值设定

需预先指定

可从树状图后验确定

可视化

散点图 + 聚类中心

树状图（Dendrogram）

适用规模

较大数据集

中小数据集

学习小结

南京工业大学 | 景浩伟 | 202321054012 | 信管 2301

特征选择与 K 值的影响

第十次作业让我理解了聚类结果会受特征选择和 K 值影响。使用花萼两列与全部四列的结果存在明显差异，K=2 与 K=3 的划分方式也截然不同。

聚类中心的重要性

聚类中心是解释 K-means 结果的重要输出。通过 `model.cluster_centers_` 可以获取每个簇在特征空间中的平均位置，有助于理解各簇的特征分布。

无监督学习的理解

Iris 案例适合观察无监督学习如何从数据结构中发现类别。不依赖真实标签，仅通过特征距离即可将样本划分为有意义的组别。